

PROPOSAL SKRIPSI

**IMPLEMENTASI CONVOLUTIONAL NEURAL
NETWORK BERBASIS MOBILENETV2 PADA APLIKASI
FLUTTER UNTUK KLASIFIKASI NOMINAL UANG
KERTAS RUPIAH**

Oleh:

**BENNY HERNANDA PUTRA
2009106066**



**FAKULTAS TEKNIK
UNIVERSITAS MULAWARMAN**

**SAMARINDA
2026**

PROPOSAL SKRIPSI

IMPLEMENTASI CONVOLUTIONAL NEURAL NETWORK BERBASIS MOBILENETV2 PADA APLIKASI FLUTTER UNTUK KLASIFIKASI NOMINAL UANG KERTAS RUPIAH

Diajukan sebagai salah satu syarat untuk menyelesaikan pendidikan
pada Program Studi Strata 1 Informatika,
Fakultas Teknik, Universitas Mulawarman

Oleh:

**BENNY HERNANDA PUTRA
2009106066**



**FAKULTAS TEKNIK
UNIVERSITAS MULAWARMAN**

**SAMARINDA
2026**

PROPOSAL SKRIPSI

IMPLEMENTASI CONVOLUTIONAL NEURAL NETWORK BERBASIS MOBILENETV2 PADA APLIKASI FLUTTER UNTUK KLASIFIKASI NOMINAL UANG KERTAS RUPIAH

Oleh:

BENNY HERNANDA PUTRA
2009106066

Telah dibahas dalam Rapat Dosen Pembimbing pada [tgl, bln, tahun] dan dinyatakan
memenuhi syarat sebagai Skripsi, dengan Dosen Pembimbing:

Pembimbing I,

Pembimbing II,

{Nama Dosen Gelar Lengkap 12 pt}
NIP {18 digit angka tanpa spasi}

{Nama Dosen Gelar Lengkap 12 pt}
NIP {18 digit angka tanpa spasi}

Koordinator Program Studi S1 Informatika,
Fakultas Teknik, Universitas Mulawarman,

Awang Harsa Kridalaksana, S.Kom., M.Kom.
NIP 19731229 200501 1 002

KATA PENGANTAR

Puji syukur kepada Allah SWT, Tuhan Yang Maha Esa sehingga dapat menyelesaikan skripsi saya yang berjudul **“IMPLEMENTASI CONVOLUTIONAL NEURAL NETWORK BERBASIS MOBILENETV2 PADA APLIKASI FLUTTER UNTUK KLASIFIKASI NOMINAL UANG KERTAS RUPIAH”** untuk Program Studi S1 Informatika di Fakultas Teknik, Universitas Mulawarman.

Oleh karena itu, pada kesempatan ini penulis ingin mengucapkan terima kasih kepada semua pihak yang telah mendukung serta membantu penulis selama proses penyusunan skripsi, terkhusus kepada:

1. {Keluarga; boleh di No. 1, boleh juga di bawah No. 8}
2. Bapak Prof. Dr. Ir. H. Tamrin, M.T., IPU., ASEAN Eng., APEC Eng. selaku Dekan Fakultas Teknik, Universitas Mulawarman.
3. Bapak Awang Harsa Kridalaksana, S.Kom., M.Kom. selaku Koordinator Program Studi Informatika, Fakultas Teknik, Universitas Mulawarman.
4. {Bapak/Ibu} {Nama Dosen Gelar Lengkap} selaku Pembimbing I yang selalu memberikan arahan, masukan, dan dorongan terhadap penelitian ini.
5. {Bapak/Ibu} {Nama Dosen Gelar Lengkap} selaku Pembimbing II atas arahan dan masukan dalam penulisan terhadap penelitian ini.
6. {Bapak/Ibu} {Nama Dosen Gelar Lengkap} selaku Penguji I atas masukan dan arahan terhadap topik penelitian ini.
7. {Bapak/Ibu} {Nama Dosen Gelar Lengkap} selaku Penguji II atas masukan dalam penulisan terhadap penelitian ini.
8. Segenap Dosen Program Studi Informatika yang telah memberikan ilmu pengetahuan selama mengikuti perkuliahan.
9. {Honorable Mentions: Rekan Seperjuangan / Orang Spesial}.

Penulis menyadari bahwa skripsi ini tidak luput dari berbagai kekurangan. Oleh karena itu, semua kritik dan saran yang bersifat memperbaiki demi kesempurnaan sangat diharapkan.

Samarinda, {tgl pdd} 2026
Penulis

DAFTAR ISI

	Halaman
HALAMAN JUDUL	ii
KATA PENGANTAR.....	iv
DAFTAR ISI	v
DAFTAR TABEL	vii
DAFTAR GAMBAR.....	viii
DAFTAR ISTILAH/LAMBANG	ix
DAFTAR SINGKATAN.....	x
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Batasan Masalah.....	3
1.4 Tujuan Penelitian.....	4
1.5 Manfaat Penelitian.....	4
1.6 Kontribusi Penelitian.....	4
BAB II TINJAUAN PUSTAKA	6
2.1 Penelitian Terkait	6
2.2 Uang Kertas Rupiah	10
2.3 Kecerdasan Buatan dan Machine Learning.....	11
2.4 Deep Learning	12
2.5 Convolutional Neural Network	12
2.5.1 Convolution Layer	13
2.5.2 Fungsi Aktivasi ReLU	13
2.5.3 Pooling Layer.....	14
2.5.4 Global Average Pooling.....	14
2.5.5 Softmax	14
2.6 Transfer Learning	15
2.7 MobileNetV2.....	15
2.8 Computer Vision	16
2.9 Citra Digital.....	16
2.10 Preprocessing Citra	16
2.11 Augmentasi Data	17
2.12 Pembagian Dataset	17
2.13 Metrik Evaluasi Klasifikasi	17
2.13.1 Accuracy	18
2.13.2 Precision.....	18
2.13.3 Recall	18
2.13.4 F1-Score	19
2.13.5 Confusion Matrix	19
2.14 Android.....	19
2.15 TensorFlow Lite	20
BAB III METODOLOGI PENELITIAN.....	21
3.1 Tahapan Pelaksanaan Penelitian	21
3.2 Pengumpulan Data	22
3.3 Perancangan Data	23

3.4	Perancangan Proses/Algoritma	24
3.5	Perancangan Tampilan	27
3.6	Perancangan Pengujian	27
DAFTAR PUSTAKA.....		29
LAMPIRAN		32

DAFTAR TABEL

	<i>Halaman</i>
Tabel 3.1 Pembagian Dataset Citra Uang Kertas Rupiah	24

DAFTAR GAMBAR

	<i>Halaman</i>
Gambar 2.1 Spesimen Uang Kertas Rupiah Emisi 2022.	11
Gambar 2.2 Ilustrasi Tahapan Convolutional Neural Network.....	13
Gambar 3.1 Alur Tahapan Pelaksanaan Penelitian.	21
Gambar 3.2 Contoh Citra Dataset: (a) Sisi Depan, (b) Sisi Belakang, (c) Rotasi 90° Sisi Depan, (d) Rotasi 90° Sisi Belakang.	23
Gambar 3.3 Tahapan Perancangan Proses.	25
Gambar 3.4 Wireframe Aplikasi: (a) Wireframe Tampilan Home, (b) Wireframe Tampilan CameraX.....	27

DAFTAR ISTILAH/LAMBANG

<i>Istilah</i>	<i>Arti</i>
Algoritma	Prosedur langkah demi langkah untuk menyelesaikan masalah.
<i>Batch Size</i>	Jumlah data yang diproses dalam setiap iterasi <i>epoch</i> .
Citra digital	Representasi digital dari suatu gambar atau objek.
<i>Dataset</i>	Kumpulan data yang digunakan untuk melatih model ML.
<i>Epoch</i>	Satu siklus penuh saat seluruh data latih diproses melalui <i>neural network</i> .
<i>Framework</i>	kerangka kerja atau fondasi siap pakai yang berisi kumpulan kode, fungsi, dan aturan dasar
<i>Input</i>	Data masukan pada suatu sistem.
Klasifikasi	Tugas dalam <i>supervised learning</i> untuk memprediksi kelas data berdasarkan variabel independen dataset.
<i>Machine learning</i>	Bidang ilmu komputer yang berfokus pada pengembangan algoritma yang dapat belajar dari data tanpa diprogram secara eksplisit.
Metrik	Ukuran yang digunakan untuk mengevaluasi performa model ML.
Model	Sistem atau algoritma <i>Artificial Intelligence</i> yang dilatih untuk memprediksi atau menghasilkan luaran berdasarkan data yang diberikan.
<i>Output</i>	Data luaran pada suatu sistem.
<i>Package</i>	kumpulan kode, fungsi, kelas, atau widget siap pakai yang dapat digunakan kembali untuk mempercepat pembuatan aplikasi
<i>Parameter</i>	Nilai bobot dan bias yang dapat diubah untuk mengoptimalkan model.
Performa	Kemampuan model ML untuk menghasilkan <i>output</i> dengan akurat.
<i>Pre-trained weights</i>	Pembobotan dalam model yang telah dilatih.
<i>Supervised learning</i>	Jenis pendekatan ML jika model dilatih dengan data yang disertai label.
<i>Testing</i>	Proses mengevaluasi performa model ML dengan menggunakan data baru.
<i>Training</i>	Proses melatih model ML dengan menggunakan dataset.
<i>Validation</i>	Proses memantau dan mengevaluasi performa model selama proses pelatihan menggunakan data <i>validation</i> .

DAFTAR SINGKATAN

Singkatan

CNN

FN

FP

ML

ReLU

TN

TP

Arti

Convolutional Neural Network

False Negative

False Positive

Machine Learning

Rectified Linear Unit

True Negative

True Positive

BAB I

PENDAHULUAN

1.1 Latar Belakang

Uang kertas merupakan salah satu alat pembayaran yang sah dan digunakan dalam berbagai transaksi sehari-hari di Indonesia. Bank Indonesia menerbitkan uang kertas dalam berbagai pecahan, mulai dari Rp1.000 hingga Rp100.000, dengan desain dan karakteristik visual yang berbeda untuk setiap nominalnya. Setiap pecahan uang memiliki ciri khas tersendiri, seperti warna dominan, ukuran, gambar pahlawan, dan elemen keamanan yang membedakannya dari pecahan lain.

Penyandang tunanetra merupakan individu yang mengalami hambatan pada fungsi penglihatan sehingga menghadapi berbagai keterbatasan dalam menjalankan aktivitas sehari-hari, termasuk dalam mengenali nominal uang kertas rupiah. Bagi penyandang tunanetra, khususnya yang mengalami kebutaan total, proses identifikasi nominal uang umumnya dilakukan melalui indera peraba. Meskipun pada beberapa emisi uang kertas rupiah telah dilengkapi dengan *blind code* atau penanda khusus yang dirancang untuk memudahkan penyandang tunanetra dalam membedakan nominal uang, implementasinya masih belum sepenuhnya efektif (Bahar dkk., 2023).

Kesulitan dalam mengenali nominal uang kertas juga dapat terjadi ketika uang berada dalam kondisi lusuh, terlipat, atau mengalami perubahan bentuk. Selain itu, pencahayaan, sudut pengambilan citra, jarak kamera, dan latar belakang dapat memengaruhi proses pengenalan citra. Kondisi tersebut dapat menyebabkan kesalahan dalam membedakan nominal uang, baik oleh manusia maupun oleh sistem pengenalan berbasis citra. Oleh karena itu, diperlukan suatu sistem yang mampu membantu proses pengenalan nominal uang kertas secara otomatis, cepat, dan akurat.

Perkembangan teknologi *computer vision* dan *deep learning* telah mendorong pengembangan berbagai sistem pengenalan objek berbasis citra. *Computer vision* memungkinkan komputer untuk memperoleh dan menganalisis informasi dari sebuah citra, sedangkan *deep learning* mampu mempelajari pola serta karakteristik objek berdasarkan data yang digunakan dalam proses pelatihan.

Salah satu metode *deep learning* yang banyak digunakan dalam tugas klasifikasi citra adalah *Convolutional Neural Network* (CNN). CNN telah terbukti efektif dalam mengenali berbagai objek *visual*, termasuk uang kertas. Beberapa penelitian sebelumnya telah berhasil mengimplementasikan CNN untuk klasifikasi nominal uang kertas Rupiah dengan akurasi mencapai 98-100% (Yahya & Fauziah, 2026). Arsitektur CNN yang terdiri dari *convolution layer*, *pooling layer*, dan *fully connected layer* memungkinkan ekstraksi fitur visual secara otomatis tanpa memerlukan ekstraksi fitur manual.

Dalam penelitian ini, digunakan *Convolutional Neural Network* (CNN) dengan arsitektur MobileNetV2. MobileNetV2 dipilih karena memiliki arsitektur yang ringan dan efisien sehingga sesuai untuk diterapkan pada perangkat dengan sumber daya komputasi terbatas, seperti *smartphone*. Penggunaan MobileNetV2 diharapkan mampu menghasilkan model yang memiliki performa klasifikasi yang baik.

Model MobileNetV2 yang telah dilatih selanjutnya diintegrasikan ke dalam aplikasi Android. Aplikasi tersebut dirancang agar pengguna dapat mengambil citra uang kertas melalui kamera *smartphone*, kemudian memperoleh hasil klasifikasi nominal berdasarkan citra yang dimasukkan. Dengan implementasi ini, sistem tidak hanya menghasilkan model klasifikasi, tetapi juga menyediakan media penggunaan yang praktis dan mudah diakses dalam aktivitas sehari-hari.

Penelitian terdahulu telah menunjukkan bahwa CNN dapat digunakan untuk mengklasifikasikan nominal uang kertas berdasarkan citra. Namun, masih terdapat peluang pengembangan pada aspek implementasi model yang ringan dan efisien untuk perangkat mobile. Selain itu, penelitian ini membedakan diri dari penelitian sebelumnya melalui penerapan model pada aplikasi Android, sehingga proses klasifikasi dapat dilakukan menggunakan perangkat yang mudah dibawa dan digunakan dalam aktivitas sehari-hari. Oleh karena itu, diperlukan pemilihan arsitektur CNN yang sesuai dengan keterbatasan sumber daya komputasi pada perangkat Android.

1.2 Rumusan Masalah

Berdasarkan latar belakang penelitian, maka yang menjadi rumusan masalah dalam penelitian ini adalah “Bagaimana merancang dan mengimplementasikan metode *Convolutional Neural Network* (CNN) berbasis arsitektur MobileNetV2 pada aplikasi Android untuk mengklasifikasikan nominal uang kertas Indonesia secara akurat dan efisien?”.

1.3 Batasan Masalah

Penelitian ini disusun berdasarkan data-data yang diperoleh. Luasnya bidang yang dihadapi membuat penelitian ini harus dibatasi. Ruang lingkup masalah dibatasi pada:

1. Objek penelitian berupa citra uang kertas Rupiah dengan nominal Rp1.000, Rp2.000, Rp5.000, Rp10.000, Rp20.000, Rp50.000, dan Rp100.000.
2. Penelitian berfokus pada klasifikasi nominal uang kertas dan tidak mencakup pendeteksian keaslian atau pemalsuan uang.
3. Citra yang digunakan berupa citra berwarna dengan format JPG, JPEG, atau PNG yang diperoleh melalui kamera smartphone dan/atau dataset penelitian.
4. Model yang digunakan adalah CNN dengan arsitektur MobileNetV2 melalui pendekatan *transfer learning*.
5. Citra masukan diproses dengan ukuran 224 x 224 piksel dan melalui tahap *preprocessing*.
6. Model yang telah dilatih diimplementasikan ke dalam aplikasi Android menggunakan TensorFlow Lite.
7. Aplikasi digunakan untuk mengambil citra uang kertas melalui kamera *smartphone* dan menampilkan hasil klasifikasi nominal.
8. Penelitian tidak membahas deteksi uang palsu, sistem pembayaran, maupun integrasi dengan layanan perbankan.
9. Pengujian dilakukan pada citra uang kertas yang masih dapat dikenali secara visual dan tidak tertutup seluruhnya oleh objek lain.
10. Evaluasi dilakukan berdasarkan akurasi, *precision*, *recall*, *F1-score*, *confusion matrix*, dan waktu inferensi pada perangkat Android.

1.4 Tujuan Penelitian

Tujuan yang ingin dicapai dalam penelitian ini adalah membuat aplikasi Android untuk mengklasifikasikan nominal uang kertas Indonesia menggunakan metode *Convolutional Neural Network* (CNN) dengan arsitektur MobileNetV2 berdasarkan citra yang diambil melalui kamera *smartphone*.

1.5 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat pada berbagai pihak, khususnya:

b. Penulis

Manfaat penelitian bagi penulis adalah untuk menambah pengetahuan serta mengasah keterampilan dalam mengembangkan aplikasi Android berbasis *deep learning* dengan mengimplementasikan arsitektur MobileNetV2 untuk klasifikasi citra nominal uang kertas Indonesia.

2. Mahasiswa

Penelitian ini dapat memberikan pengetahuan mendalam mengenai penerapan metode *Convolutional Neural Network* (CNN) khususnya arsitektur MobileNetV2 yang ringan dan efisien untuk perangkat *mobile*, serta dapat menjadi referensi ilmiah bagi mahasiswa bidang Informatika dalam pengembangan sistem pengenalan objek berbasis citra.

3. Pengguna

Manfaat penelitian ini bagi pengguna adalah memberikan kemudahan dalam mengenali nominal uang kertas, khususnya bagi masyarakat umum. Aplikasi ini juga berpotensi membantu penyandang tunanetra jika dikembangkan lebih lanjut dengan fitur *output audio (text-to-speech)* untuk membacakan hasil klasifikasi.

1.6 Kontribusi Penelitian

Penelitian ini memberikan kontribusi pada bidang ilmu pengetahuan dan teknologi, khususnya dalam pengembangan sistem *computer vision* berbasis *deep learning* untuk mendukung aksesibilitas dan pengenalan objek secara otomatis. Sistem

klasifikasi nominal uang kertas Rupiah dibangun menggunakan *Convolutional Neural Network* (CNN) dengan arsitektur MobileNetV2 yang ringan, lalu diintegrasikan langsung ke dalam aplikasi Android agar dapat dijalankan dengan efisien di perangkat *smartphone*. Hasil penelitian ini diharapkan dapat menjadi acuan bagi pengembangan riset berbasis kecerdasan buatan pada perangkat *mobile* di masa depan, sekaligus memberikan solusi nyata untuk membantu masyarakat, khususnya penyandang tunanetra, dalam mengenali nominal uang kertas secara praktis, cepat, dan akurat.

BAB II

TINJAUAN PUSTAKA

2.1 Penelitian Terkait

Dalam rangka mendukung penelitian ini, maka dilakukan kajian dengan mempelajari penelitian-penelitian terkait yang telah dilakukan sebelumnya. Daftar penelitian terkait antara lain:

1. **Metode yang digunakan:** *Convolutional Neural Network*. **Temuan Penelitian:** Penelitian ini menyimpulkan bahwa model CNN yang digunakan untuk mengkarakterisasi gambar bumbu dan rasa yang terkomputerisasi adalah model dengan 2 lapisan konvolusional, dimana lapisan konvolusional pertama memiliki jumlah saluran sebanyak 10 dan lapisan konvolusional kedua memiliki jumlah saluran sebanyak 20. Pada setiap saluran terdapat jaringan bagian dengan jumlah saluran sebanyak 20. Ukuran 3x3. Ukuran saluran pada pooling layer adalah 3x3 dan jumlah neuron pada lapisan rahasia adalah 10. Kemampuan aktuasi pada lapisan konvolusional dan lapisan rahasia adalah tanh, dan kemampuan pengaktifan pada lapisan hasil adalah softmax. Pada model ini, nilai ketepatan informasi penyusunan sebesar 0,9875 dan nilai kemalangan sebesar 0,0769. Nilai presisi informasi pengujian sebesar 0,85 dan nilai kemalangan sebesar 0,4773. Sementara itu, pengujian dengan informasi baru, khususnya masing-masing 3 gambar untuk setiap kelas, menghasilkan ketepatan sebesar 88,89% (Boimau & Kaesmetan, 2024).
2. **Metode yang digunakan:** *Convolutional Neural Network*. **Temuan Penelitian:** Penelitian ini menyimpulkan bahwa model *Convolutional Neural Network* (CNN) dapat digunakan untuk mengklasifikasikan penyakit tanaman padi berdasarkan citra daun, dengan jumlah *epoch* sebagai salah satu faktor yang memengaruhi hasil pelatihan dan pengujian model. Berdasarkan tiga skenario pengujian yang dilakukan, terdapat perbedaan nilai akurasi dan hasil *confusion matrix* pada setiap skenario. Skenario 2 dengan penggunaan 50 *epoch* menghasilkan kinerja terbaik, yaitu akurasi pelatihan pada epoch terakhir sebesar 0,9905 dengan nilai *training loss* sebesar 0,0280, serta akurasi *validation* sebesar 0,8000 dengan nilai *validation*

loss sebesar 0,9222. Hasil evaluasi menggunakan *confusion matrix* menunjukkan bahwa model mampu memberikan prediksi yang sesuai dengan kelas asli data yang diuji. Berdasarkan *classification report*, kelas *Brown Spot*, *Bacterial Leaf Blight*, dan *Leaf Smut* memperoleh nilai *precision*, *recall*, dan *F1-score* sebesar 1,00. Dengan demikian, skenario 2 menunjukkan hasil yang lebih baik dibandingkan dengan skenario 1 dan 3, sehingga dapat disimpulkan bahwa variasi jumlah *epoch* berpengaruh terhadap performa model CNN dalam melakukan klasifikasi penyakit pada tanaman padi. (Rijal dkk., 2024).

3. **Metode yang digunakan:** *Convolutional Neural Network*. **Temuan Penelitian:** Penelitian ini melakukan klasifikasi penyakit mata menggunakan metode *Convolutional Neural Network* (CNN) dengan arsitektur *AlexNet*. Penelitian tersebut mengklasifikasikan citra mata ke dalam empat kelas, yaitu normal, *katarak*, *glaukoma*, dan *retina disease*. Tahapan penelitian diawali dengan pre-processing berupa pengubahan ukuran citra menjadi 224×224 piksel, kemudian dilanjutkan dengan ekstraksi fitur melalui tiga jenis lapisan, yaitu *convolutional layer*, *pooling layer*, dan *fully connected layer* sesuai dengan arsitektur yang digunakan. Implementasi model CNN dilakukan dengan 150 *epoch* dan menghasilkan akurasi sebesar 98,37% dalam mengklasifikasikan penyakit mata (Cahya dkk., 2021).
4. **Metode yang digunakan:** *Convolutional Neural Network* pra-latih MobileNetV2. **Temuan Penelitian:** Penelitian ini berhasil mencapai akurasi 94% pada data *testing* dengan dataset yang relatif terbatas untuk melakukan *training*, yaitu 4000 citra untuk 20 kelas. Hal ini menunjukkan efisiensi pendekatan *Transfer Learning* dalam mencapai performa kompetitif sekaligus mengatasi keterbatasan. Perbandingan dengan penelitian yang juga menggunakan *Transfer Learning* oleh penelitian sebelumnya menunjukkan bahwa penelitian ini, dengan dataset 4.000 citra dan 20 kelas mampu mencapai akurasi 94% sedikit lebih tinggi dari akurasi 90% yang dicapai penelitian sebelumnya yang hanya mengklasifikasikan 2 kelas dengan 1.138 citra (Hartono & Muslikh, 2025).
5. **Metode yang digunakan:** *Convolutional Neural Network* pra-latih MobileNetV2. **Temuan Penelitian:** Penelitian ini menunjukkan bahwa model MobileNetV2 memperoleh akurasi pengujian sebesar 95%, lebih unggul dibandingkan model CNN sederhana yang hanya mencapai akurasi 82%. MobileNetV2 juga mampu

mengidentifikasi kelas korosi dan nonkorosi dengan performa yang lebih baik. Meskipun ditemukan indikasi *overfitting* yang disebabkan oleh keterbatasan jumlah dataset, penerapan metode *transfer learning* terbukti dapat meningkatkan kinerja klasifikasi secara signifikan. Sistem yang dikembangkan memiliki potensi untuk diterapkan dalam proses pemantauan industri secara *real-time* sehingga dapat membantu mengurangi kerugian ekonomi akibat korosi (Pratama dkk., 2025).

6. **Metode yang digunakan:** *Convolutional Neural Network* pra-latih MobileNetV2. **Temuan Penelitian:** Penelitian ini menunjukkan bahwa model klasifikasi berbasis arsitektur MobileNetV2 memiliki kinerja yang sangat baik dalam membedakan tiga kategori daun, yaitu *Early Blight*, *Healthy*, dan *Late Blight*. Model tersebut memperoleh akurasi sebesar 95,31%, presisi sebesar 95,81%, *recall* sebesar 95,31%, dan *F1-score* sebesar 95,38%. Berdasarkan hasil *confusion matrix*, sebagian besar sampel berhasil diklasifikasikan sesuai dengan kelasnya, terutama pada kategori *Healthy* yang tidak mengalami kesalahan klasifikasi. Namun, masih ditemukan beberapa kesalahan prediksi pada kategori *Early Blight* dan *Late Blight*, sehingga diperlukan peningkatan lebih lanjut pada model. Secara keseluruhan, MobileNetV2 dinilai layak digunakan untuk melakukan klasifikasi citra daun karena mampu menghasilkan tingkat akurasi yang tinggi dengan persentase kesalahan yang relatif rendah (Gunawan dkk., 2025).
7. **Metode yang digunakan:** *Convolutional Neural Network*. **Temuan Penelitian:** Penelitian ini menghasilkan sebuah model *deep learning* berbasis *Convolutional Neural Network* (CNN) yang mampu mengklasifikasikan 14 jenis citra batik. Berdasarkan perbandingan beberapa parameter, arsitektur CNN dengan kinerja terbaik menggunakan ukuran citra 150×150 piksel, *batch size* 64, filter atau kernel berukuran 3×3, learning rate sebesar 0,0001, serta *optimizer Adam*. Model tersebut menerapkan fungsi aktivasi *ReLU* pada lapisan tersembunyi dan Softmax pada lapisan keluaran, dengan jumlah pelatihan sebanyak 30 *epoch*. Dataset yang digunakan terdiri atas 3.880 citra RGB dengan pembagian data sebesar 70% untuk pelatihan, 20% untuk *validation*, dan 10% untuk pengujian. Hasil evaluasi menunjukkan bahwa model terbaik mampu mencapai akurasi sebesar 91,24% pada data *testing* (Wona dkk., 2023).

8. **Metode yang digunakan:** *Convolutional Neural Network* pra-latih *VGG16*. **Temuan Penelitian:** Penelitian ini menunjukkan bahwa proses pembelajaran menggunakan metode *Convolutional Neural Network* (CNN) pada citra bunga dipengaruhi oleh arsitektur yang digunakan. Setelah dilakukan sebanyak 50 iterasi, arsitektur I menghasilkan akurasi sebesar 0,62, sedangkan arsitektur II yang menerapkan VGG16 memperoleh akurasi sebesar 0,80 (Intyanto, 2021).
9. **Metode yang digunakan:** *Convolutional Neural Network*, *Support Vector Machine*.. **Temuan Penelitian:** Penelitian ini membandingkan kinerja metode *Convolutional Neural Network* (CNN) dan *Support Vector Machine* (SVM) dengan beberapa jenis kernel, yaitu RBF, linear, dan polynomial. Hasil pengujian menunjukkan bahwa CNN serta SVM dengan kernel RBF, linear, dan polynomial mampu memperoleh nilai *accuracy*, *precision*, *recall*, dan *F1-score* masing-masing sebesar 100%. Pada penerapan SVM, proses klasifikasi diawali dengan ekstraksi fitur tekstur menggunakan metode GLCM. Namun, penggunaan kernel sigmoid menghasilkan performa yang jauh lebih rendah dibandingkan kernel lainnya (Zalvadila, 2023).
10. **Metode yang digunakan:** *Convolutional Neural Network*, *Support Vector Machine*. **Temuan Penelitian:** Penelitian ini mengembangkan sistem berbasis *website* dengan metode *Convolutional Neural Network* (CNN) untuk mengklasifikasikan lima genus anggrek yang umum dibudidayakan, yaitu *Cattleya*, *Dendrobium*, *Oncidium*, *Phalaenopsis*, dan *Vanda*, berdasarkan citra daun. Hasil pengujian menunjukkan bahwa model terbaik adalah MobileNetV2 dengan penambahan *dropout*, optimizer Adam, dan *learning rate* 0,0001 pada skenario data pelatihan tanpa *background noise*, yang memperoleh akurasi pengujian sebesar 90,44% pada citra lapangan dan 80,54% pada citra internet dengan ukuran model 101 MB. Sementara itu, model MobileNetV2 tanpa modifikasi dengan optimizer Adam dan *learning rate* 0,0003 menghasilkan akurasi sebesar 83,12% pada citra lapangan dan 80,00% pada citra internet dengan ukuran model 9 MB. Secara keseluruhan, arsitektur MobileNetV2 mampu memberikan performa klasifikasi yang baik, sedangkan penggunaan *dropout*, pemilihan hyperparameter yang sesuai, penghilangan *background noise*, dan augmentasi data dapat meningkatkan akurasi serta membantu mengurangi *overfitting*. Meskipun demikian, kesalahan klasifikasi

masih ditemukan akibat kemiripan bentuk dan warna daun antar genus, terutama pada genus *Cattleya* dan *Oncidium*, sehingga dapat disimpulkan bahwa model CNN yang dikembangkan efektif untuk klasifikasi genus anggrek, tetapi tingkat keberhasilannya tetap dipengaruhi oleh karakteristik dan kualitas citra yang digunakan (Allaam & Wibowo, 2021).

Perbedaan dengan Penelitian Sebelumnya

Berdasarkan referensi yang terkait, maka didapatkan perbedaan penelitian yang terdahulu sebagai dasar penelitian ini:

1. Penelitian sebelumnya mengimplementasikan model *machine learning* ke website menggunakan *flask* sebagai *framework* (Mawaddah, 2023), pada penelitian ini model *machine learning* diimplementasikan ke dalam aplikasi android.
2. Penelitian sebelumnya menggunakan model CNN yang dilatih untuk melakukan klasifikasi citra (Mawaddah, 2023), sedangkan penelitian ini menggunakan arsitektur MobileNetV2 dengan pendekatan *transfer learning*. MobileNetV2 dipilih karena memiliki arsitektur yang lebih ringan dan efisien untuk diterapkan pada perangkat mobile.
3. Penelitian sebelumnya memproses citra dengan ukuran 150×150 piksel (Mawaddah, 2023), sedangkan penelitian ini menggunakan ukuran citra 224×224 piksel yang disesuaikan dengan konfigurasi model MobileNetV2.
4. Penelitian sebelumnya, proses klasifikasi dilakukan melalui website dengan model yang dijalankan pada sisi server, sedangkan pada penelitian ini model diintegrasikan ke dalam aplikasi Android sehingga proses klasifikasi dapat dilakukan langsung melalui perangkat *mobile*.

2.2 Uang Kertas Rupiah

Uang kertas adalah uang yang terbuat dari kertas dan merupakan alat pembayaran yang sah. Menurut Undang-Undang Nomor 23 Tahun 1999 tentang Bank Indonesia, uang kertas berarti uang yang berbentuk kertas sebanyak lembar atau bahan lain yang berbentuk kertas. Uang kertas Rupiah merupakan uang kertas atau uang negara

Indonesia, uang kertas Rupiah sendiri mempunyai banyak pecahan, diantaranya adalah 1000, 2000, 5000, 10000, 20000, 50000, 100000. Pada masing-masing pecahan tersebut mempunyai ciri yang berbeda-beda.(Alfita dkk., 2022). Spesimen yang digunakan dalam penelitian ini terdapat pada Gambar 2.1.



Gambar 2.1 Spesimen Uang Kertas Rupiah Emisi 2022.

2.3 Kecerdasan Buatan dan Machine Learning

Kecerdasan buatan adalah bidang ilmu komputer yang mempelajari cara membuat sistem agar komputer bisa melakukan pekerjaan yang biasanya memerlukan kemampuan manusia. Tugas tersebut mencakup mengenali pola, memahami informasi, membuat prediksi, serta mengambil keputusan (Sharifani & Amini, 2023).

Salah satu cabang dari kecerdasan buatan adalah *Machine Learning*. Mitchell menjelaskan bahwa *machine learning* adalah bidang yang mempelajari algoritma komputer yang mampu meningkatkan kemampuannya bekerja secara otomatis melalui pengalaman. Sehingga, sistem tidak hanya menerapkan aturan yang dibuat secara manual, tetapi juga belajar dari pola-pola yang terdapat dalam data yang diberikan (Mitchell, 2013).

Secara umum, *machine learning* dapat dibagi menjadi tiga pendekatan, yaitu *supervised learning*, *unsupervised learning*, dan *reinforcement learning*. *Supervised learning* menggunakan data yang telah memiliki label. *Unsupervised learning* mempelajari pola dari data tanpa label, sedangkan *reinforcement learning* mempelajari

tindakan berdasarkan umpan balik berupa penghargaan atau penalti (Rahmadden dkk., 2026).

Penelitian ini menggunakan pendekatan *supervised learning* karena setiap citra uang kertas telah dikelompokkan berdasarkan nominalnya. Model menerima citra sebagai data masukan dan label nominal sebagai target yang harus dipelajari. Setelah proses pelatihan, model diharapkan dapat memprediksi nominal dari citra baru yang belum pernah digunakan dalam pelatihan.

2.4 Deep Learning

Deep learning merupakan bagian dari *machine learning* yang menggunakan jaringan saraf dengan banyak lapisan untuk mempelajari representasi data. Setiap lapisan dapat mempelajari karakteristik yang berbeda dari data masukan (Taye, 2023).

Pada pengolahan citra, lapisan awal umumnya mempelajari fitur sederhana, seperti garis dan tepi. Lapisan berikutnya dapat mempelajari fitur yang lebih kompleks, seperti bentuk, tekstur, warna, dan pola objek. Kemampuan untuk mempelajari fitur secara otomatis membuat *deep learning* banyak digunakan dalam klasifikasi citra. Goodfellow, Bengio, dan Courville menjelaskan konsep dasar *deep learning*, jaringan saraf, dan pembelajaran representasi dalam buku *Deep Learning* (Goodfellow dkk., 2016).


Dalam penelitian ini, *deep learning* diterapkan melalui arsitektur *Convolutional Neural Network* (CNN), khususnya MobileNetV2, untuk mempelajari karakteristik visual pada citra uang kertas. Hubungan antara kecerdasan buatan, *machine learning*, *deep learning*, CNN, dan MobileNetV2 ditunjukkan pada Gambar 2.1.

2.5 Convolutional Neural Network

Convolutional Neural Network (CNN) merupakan salah satu arsitektur *deep learning* yang banyak digunakan untuk pengolahan dan klasifikasi citra. CNN dapat mempelajari fitur visual secara otomatis melalui beberapa lapisan yang tersusun secara berurutan (GeeksforGeeks, 2026).

Pada proses klasifikasi citra, CNN menerima citra sebagai masukan, kemudian melakukan ekstraksi fitur melalui lapisan konvolusi dan *pooling*. Fitur yang diperoleh selanjutnya diproses oleh lapisan klasifikasi untuk menghasilkan prediksi kelas.

Pada Gambar 2.2 merupakan gambaran alur *Convolutional Neural Network*.



Gambar 2.2 Ilustrasi Tahapan Convolutional Neural Network.

CNN sesuai digunakan pada penelitian ini karena citra uang kertas memiliki karakteristik visual yang dapat dipelajari, seperti warna, bentuk, tekstur, tulisan, dan pola. Dengan demikian, CNN dapat digunakan untuk membedakan citra uang kertas berdasarkan nominalnya.

2.5.1 Convolution Layer

Convolution layer merupakan lapisan yang melakukan operasi konvolusi terhadap citra masukan menggunakan filter atau kernel. Filter digeser pada bagian-bagian citra untuk menemukan fitur tertentu (Cao dkk., 2022). Hasil proses tersebut disebut feature map.

Pada lapisan awal, filter dapat mendeteksi fitur sederhana, seperti garis, tepi, dan perubahan warna. Pada lapisan yang lebih dalam, filter dapat mempelajari fitur yang lebih kompleks.

2.5.2 Fungsi Aktivasi ReLU

ReLU atau *Rectified Linear Unit* merupakan fungsi aktivasi yang banyak digunakan dalam jaringan CNN. Fungsi ini mengubah nilai negatif menjadi nol, sedangkan nilai positif tetap dipertahankan.

Secara matematis, ReLU secara matematis dituliskan pada persamaan 2.1.

$$f(x) = \max(0, x) \dots\dots\dots(2.1)$$

Penggunaan ReLU memberikan sifat nonlinier pada model sehingga jaringan dapat mempelajari pola yang lebih kompleks.

2.5.3 Pooling Layer

Pooling layer digunakan untuk mengurangi ukuran *feature map* dengan tetap mempertahankan informasi penting. Salah satu metode *pooling* yang umum digunakan adalah *max pooling*, yaitu memilih nilai terbesar dari area tertentu.

Pooling layer memiliki beberapa manfaat dalam arsitektur CNN. Lapisan ini dapat mengurangi ukuran data atau *feature map* sehingga beban komputasi menjadi lebih ringan. Selain itu, pooling juga membantu mengurangi jumlah parameter yang diproses oleh model serta meningkatkan kemampuan model dalam mengenali fitur meskipun terjadi perubahan posisi pada citra.

2.5.4 Global Average Pooling

Global Average Pooling digunakan untuk merangkum setiap *feature map* menjadi satu nilai sehingga menghasilkan vektor fitur yang lebih ringkas. Vektor fitur tersebut kemudian diteruskan ke lapisan *dropout* untuk mengurangi risiko *overfitting*. Setelah itu, *dense layer* mengolah fitur yang diperoleh dan menghubungkannya dengan tujuh kelas nominal uang kertas. Lapisan keluaran menggunakan fungsi aktivasi *softmax* untuk menghasilkan probabilitas pada setiap kelas.

2.5.5 Softmax

Softmax digunakan pada lapisan keluaran untuk menghasilkan nilai probabilitas pada setiap kelas. Nilai probabilitas tersebut menunjukkan tingkat keyakinan model terhadap masing-masing nominal. Kelas dengan nilai probabilitas paling tinggi dipilih sebagai hasil prediksi model.

2.6 Transfer Learning

Transfer learning merupakan teknik yang memanfaatkan pengetahuan atau bobot dari model yang telah dilatih sebelumnya untuk menyelesaikan tugas baru. Model yang telah dilatih menggunakan dataset berukuran besar dapat digunakan sebagai model dasar untuk tugas klasifikasi yang lebih spesifik. Pendekatan ini memungkinkan model memanfaatkan fitur yang telah dipelajari sebelumnya sehingga proses pelatihan pada dataset baru dapat dilakukan secara lebih efisien (Goodfellow dkk., 2016).

Pada penelitian ini, model MobileNetV2 digunakan melalui pendekatan *transfer learning*. Lapisan dasar MobileNetV2 berfungsi sebagai ekstraktor fitur, sedangkan lapisan klasifikasi akhir disesuaikan dengan tujuh kelas nominal uang kertas.

Tahapan *transfer learning* dapat dilakukan dengan memuat model MobileNetV2 yang telah dilatih sebelumnya (*pretrained*), lalu menghilangkan lapisan klasifikasi bawaannya agar dapat disesuaikan dengan tugas baru. Sebagian lapisan dasar model kemudian dibekukan agar bobotnya tidak berubah selama pelatihan awal, sementara lapisan klasifikasi baru ditambahkan di atas fitur yang diekstrak oleh *backbone*. Lapisan klasifikasi ini dilatih menggunakan dataset uang kertas hingga konvergen, dan jika performa masih belum optimal, *fine-tuning* dapat dilakukan dengan membuka sebagian lapisan akhir (misalnya 20 lapisan terakhir) model dasar untuk menyesuaikan representasi fitur lebih lanjut dengan karakteristik dataset target.

2.7 MobileNetV2

MobileNetV2 merupakan arsitektur CNN yang dirancang untuk perangkat mobile dan sistem dengan sumber daya komputasi terbatas (Fransisca & Matondang, 2023). Arsitektur ini dikembangkan untuk menghasilkan model yang memiliki keseimbangan antara kemampuan klasifikasi dan efisiensi komputasi.

MobileNetV2 menggunakan konsep *inverted residual* dan *linear bottleneck*. *Inverted residual* menggunakan struktur blok yang memperluas representasi fitur pada bagian tengah, kemudian meringkasnya kembali. Sementara itu, *linear bottleneck* digunakan untuk mempertahankan informasi penting pada representasi berdimensi rendah (Sandler dkk., 2018).

MobileNetV2 dipilih dalam penelitian ini karena model akan diimplementasikan pada aplikasi Android. Arsitektur yang ringan dapat membantu mengurangi ukuran model dan beban komputasi ketika proses klasifikasi dijalankan pada smartphone.

2.8 Computer Vision

Computer vision merupakan bidang yang mempelajari kemampuan komputer dalam memperoleh dan menganalisis informasi visual dari citra atau video. Informasi visual tersebut dapat berupa bentuk, warna, tekstur, pola, dan posisi objek (Zhao dkk., 2024).

Dalam penelitian ini, *computer vision* digunakan untuk menganalisis citra uang kertas Rupiah. Citra yang dimasukkan ke dalam sistem akan diproses untuk memperoleh fitur visual yang membedakan satu nominal dengan nominal lainnya. Hasil dari analisis tersebut kemudian dipakai oleh model untuk menentukan jenis uang kertas yang sesuai.

2.9 Citra Digital

Citra digital merupakan representasi visual yang tersusun atas sejumlah piksel. Setiap piksel memiliki nilai tertentu yang menunjukkan intensitas atau warna pada posisi tertentu (Dijaya & Setiawan, 2023).

Citra berwarna umumnya memiliki tiga kanal warna, yaitu merah, hijau, dan biru atau RGB. Dalam penelitian ini, citra uang kertas digunakan sebagai data masukan untuk model klasifikasi.

2.10 Preprocessing Citra

Preprocessing merupakan tahap persiapan citra sebelum digunakan dalam proses pelatihan dan pengujian. Tahap ini dilakukan agar citra memiliki bentuk dan skala yang sesuai dengan masukan model.

Tahap *preprocessing* yang dapat digunakan dalam penelitian ini meliputi:

1. Mengubah ukuran citra menjadi 224×224 piksel.
2. Mengubah citra menjadi format RGB.
3. Melakukan normalisasi nilai piksel.

4. Menyesuaikan format citra dengan kebutuhan MobileNetV2.

2.11 Augmentasi Data

Augmentasi data merupakan proses menghasilkan variasi baru dari citra yang sudah tersedia. Teknik ini dapat dilakukan melalui rotasi, perubahan ukuran, pembalikan, pergeseran, pembesaran, dan perubahan tingkat pencahayaan (Gunardi, 2023).

Augmentasi dapat membantu model mengenali citra dalam kondisi yang lebih beragam. Pada penelitian ini, dataset yang digunakan sudah memiliki variasi rotasi (0° , 90° , 180° , 270°) untuk setiap lembar uang kertas, sehingga tidak dilakukan augmentasi tambahan.

2.12 Pembagian Dataset

Dataset dapat dibagi menjadi tiga bagian, yaitu data *training* yang digunakan untuk melatih model, data *validation* yang berfungsi untuk memantau performa model selama proses *training* berlangsung, dan data *testing* yang digunakan untuk mengukur performa model pada data yang tidak pernah digunakan selama *training*, sehingga dapat memberikan evaluasi yang objektif terhadap kemampuan generalisasi model.

Pembagian dataset harus dilakukan secara hati-hati agar data yang sama atau sangat mirip tidak masuk ke bagian *training* dan *testing* secara bersamaan.

TensorFlow menyediakan contoh alur klasifikasi citra, mulai dari pemuatan dataset, pembangunan model, *training*, hingga evaluasi (Martín Abadi dkk., 2015).

2.13 Metrik Evaluasi Klasifikasi

Metrik evaluasi digunakan untuk mengukur kemampuan model dalam melakukan klasifikasi citra uang kertas. Metrik yang digunakan dalam penelitian ini meliputi *accuracy*, *precision*, *recall*, *F1-score*, dan *confusion matrix*. *Accuracy* menunjukkan proporsi prediksi yang benar terhadap seluruh data, sedangkan *precision*, *recall*, dan *F1-score* digunakan untuk menilai performa model pada setiap kelas. *Confusion matrix*

digunakan untuk melihat hubungan antara label sebenarnya dan label hasil prediksi pada tujuh kelas nominal uang kertas.

2.13.1 Accuracy

Accuracy merupakan perbandingan antara jumlah prediksi yang benar dan jumlah seluruh data pengujian. Pada klasifikasi multikelas, nilai *accuracy* dapat dihitung dengan membandingkan jumlah sampel yang diklasifikasikan dengan benar terhadap seluruh sampel pengujian (Vickers dkk., 2023). Untuk rumus dapat dihitung pada menggunakan rumus pada persamaan 2.2.

$$\text{Accuracy} = \frac{\text{Jumlah prediksi benar}}{\text{Jumlah seluruh data pengujian}} \dots\dots\dots(2.2)$$

2.13.2 Precision

Precision menunjukkan proporsi data yang diprediksi sebagai suatu kelas dan benar-benar termasuk dalam kelas tersebut. Nilai *precision* dihitung dengan membagi jumlah *true positive* dengan jumlah *true positive* dan *false positive* (Vickers dkk., 2023), *precision* dapat dihitung menggunakan rumus pada persamaan 2.3.

$$\text{Precision} = \frac{TP}{TP+FP} \dots\dots\dots(2.3)$$

Keterangan:

- *TP*: data positif yang diprediksi benar.
- *FP*: data negatif yang diprediksi sebagai positif.

2.13.3 Recall

Recall menunjukkan kemampuan model dalam menemukan data yang sebenarnya termasuk dalam suatu kelas. Nilai *recall* dihitung dengan membagi jumlah *true positive* dengan jumlah *true positive* dan *false negative* (Vickers dkk., 2023), *Recall* dapat dihitung menggunakan rumus pada persamaan 2.4.

$$\text{Recall} = \frac{TP}{TP+F} \dots\dots\dots(2.4)$$

Keterangan:

- *FN*: data positif yang diprediksi sebagai negatif.

2.13.4 F1-Score

F1-score merupakan rata-rata harmonis antara *precision* dan *recall*. Metrik ini digunakan untuk memberikan ukuran gabungan terhadap ketepatan prediksi dan kemampuan model dalam menemukan data dari suatu kelas, *F1-score* dapat dihitung menggunakan rumus pada persamaan 2.5.

$$F1\text{-score} = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \dots\dots (2.5)$$

2.13.5 Confusion Matrix

Confusion matrix merupakan tabel yang menunjukkan hubungan antara label sebenarnya dan label hasil prediksi. Pada penelitian ini, baris dan kolom mewakili tujuh kelas nominal uang kertas. Nilai pada diagonal utama menunjukkan jumlah prediksi yang benar, sedangkan nilai di luar diagonal menunjukkan kesalahan klasifikasi antar kelas. *Confusion matrix* digunakan sebagai dasar untuk menganalisis kesalahan prediksi pada masing-masing kelas (Vickers dkk., 2023).

2.14 Android

Android merupakan platform sistem operasi yang digunakan pada berbagai perangkat mobile. Dalam penelitian ini, Android digunakan sebagai platform untuk mengimplementasikan model klasifikasi uang kertas.

Aplikasi Android dapat memanfaatkan kamera untuk mengambil citra uang kertas. Citra tersebut kemudian diproses dan diberikan kepada model untuk memperoleh hasil klasifikasi.

Pengembangan aplikasi dapat dilakukan menggunakan Visual Studio Code sebagai editor code dengan menggunakan bahasa Dart dan *framework* Flutter. Untuk pengambilan citra, aplikasi memanfaatkan *package* Flutter seperti *camera* atau *image_picker*. Model TensorFlow Lite dijalankan di aplikasi menggunakan plugin *tflite_flutter*.

2.15 TensorFlow Lite

TensorFlow Lite merupakan teknologi yang digunakan untuk menjalankan model *machine learning* pada perangkat mobile dan perangkat dengan sumber daya terbatas. Model yang telah dilatih menggunakan TensorFlow atau Keras dapat dikonversi ke format TensorFlow Lite dengan ekstensi .tflite (Martín Abadi dkk., 2015).

Dalam penelitian ini, model MobileNetV2 dikonversi ke format TensorFlow Lite dan dimasukkan ke dalam aplikasi Android. Aplikasi kemudian menggunakan model tersebut untuk melakukan proses inferensi terhadap citra uang kertas.

Tahapan penggunaan TensorFlow Lite meliputi:

1. Melatih model menggunakan TensorFlow atau Keras.
2. Mengonversi model ke format .tflite.
3. Memasukkan model ke dalam proyek Android.
4. Memuat model menggunakan *interpreter*.
5. Menyesuaikan citra dengan format masukan model.
6. Menjalankan inferensi.
7. Membaca hasil prediksi dan menampilkan nominal uang.


TensorFlow Lite menyediakan dukungan untuk menjalankan model TensorFlow pada aplikasi Android (Martín Abadi dkk., 2015), sedangkan proses inferensi merupakan proses menjalankan model untuk menghasilkan prediksi berdasarkan data masukan.

BAB III

METODOLOGI PENELITIAN

3.1 Tahapan Pelaksanaan Penelitian

Penelitian ini dilaksanakan melalui beberapa tahapan proses yang dilakukan sebelum memasuki tahap klasifikasi, sebagaimana dapat dilihat pada Gambar 3.1.



Gambar 3.1 Alur Tahapan Pelaksanaan Penelitian.

Berdasarkan Gambar 3.1, tahapan penelitian dapat dijelaskan sebagai berikut:

1. Studi Literatur

Mempelajari referensi mengenai *machine learning*, *deep learning*, CNN, MobileNetV2, *transfer learning*, *fine-tuning*, TensorFlow Lite, Android, dan evaluasi model.

2. Penyiapan Dataset

Memperoleh dataset sekunder citra tujuh nominal uang kertas Rupiah dari penelitian atau sumber terdahulu, kemudian memeriksa label dan kualitas citra.

3. Perancangan Data

Melakukan *preprocessing* citra dengan mengubah ukuran menjadi 224×224 piksel, menyesuaikan format RGB, melakukan normalisasi, serta membagi dataset menjadi *training*, *validation*, dan *testing*. Dataset yang digunakan sudah memiliki variasi rotasi (0° , 90° , 180° , 270°) untuk setiap lembar uang kertas, sehingga pada penelitian ini tidak dilakukan augmentasi tambahan.

4. **Perancangan Proses**

Merancang model MobileNetV2 menggunakan *transfer learning*. Model terdiri atas MobileNetV2 sebagai *feature extractor*, *Global Average Pooling*, *dropout*, *dense layer*, dan *softmax*. Selanjutnya, 20 lapisan terakhir dibuka untuk proses *fine-tuning*.

5. **Perancangan Tampilan**

Merancang antarmuka aplikasi Android yang mencakup kamera, tombol pengambilan citra, tombol klasifikasi, dan tampilan hasil prediksi.

6. **Implementasi**

Melatih dan melakukan *fine-tuning* model, menyimpan model terbaik, mengonversinya ke format TensorFlow Lite, serta mengintegrasikannya ke dalam aplikasi Android.

7. **Pengujian**

Menguji performa model menggunakan *accuracy*, *precision*, *recall*, F1-score, dan *confusion matrix*. Aplikasi diuji menggunakan metode *black-box* untuk memeriksa fungsi kamera, klasifikasi, dan tampilan hasil.

8. **Kesimpulan**

Menarik kesimpulan berdasarkan hasil pengujian untuk mengetahui keberhasilan model dalam mengenali tujuh nominal uang kertas Rupiah serta memberikan saran untuk penelitian selanjutnya.

3.2 **Pengumpulan Data**

Tahap pengumpulan data dilakukan dengan memperoleh dataset sekunder dari penelitian terdahulu. Dataset yang digunakan dalam penelitian ini berupa citra uang kertas Rupiah yang diperoleh dari Rahmiatul Mawaddah pada tahun 2023 melalui tautan Google Drive berikut:

https://drive.google.com/drive/folders/1HmsMI11GHNxvCjema6mafU2vwaBvEW9_?usp=drive_link

Dataset tersebut terdiri atas citra tujuh kelas nominal uang kertas Rupiah, yaitu Rp1.000, Rp2.000, Rp5.000, Rp10.000, Rp20.000, Rp50.000, dan Rp100.000. Dataset digunakan sebagai data masukan dalam proses klasifikasi nominal uang kertas

menggunakan arsitektur MobileNetV2 dengan pendekatan transfer learning dan fine-tuning.

Setiap kelas memuat citra sisi depan dan sisi belakang uang kertas. Dataset juga memiliki variasi orientasi dengan rotasi dalam kelipatan 90° , yaitu 0° , 90° , 180° , dan 270° . Sisi depan, sisi belakang, dan citra yang mengalami rotasi dari nominal yang sama tetap dimasukkan ke dalam satu kelas nominal.



Gambar 3.2 Contoh Citra Dataset: (a) Sisi Depan, (b) Sisi Belakang, (c) Rotasi 90° Sisi Depan, (d) Rotasi 90° Sisi Belakang.

Citra pada dataset disusun ke dalam folder berdasarkan kelas nominal uang kertas. Nama folder digunakan sebagai label kelas, sedangkan nama file tidak diubah karena hanya berfungsi sebagai identitas masing-masing citra.

3.3 Perancangan Data

Perancangan data dilakukan dengan menyiapkan dataset agar sesuai dengan kebutuhan pelatihan dan pengujian model MobileNetV2. Dataset terdiri atas tujuh kelas nominal uang kertas Rupiah, dan setiap kelas memiliki 800 citra. Dengan demikian, jumlah keseluruhan dataset yang digunakan adalah 5.600 citra.

Dataset kemudian dibagi ulang secara proporsional pada setiap kelas menjadi 70% data *training*, 15% data *validation*, dan 15% data *testing*. Berdasarkan jumlah tersebut, Setiap kelas terdiri atas 560 citra *training*, 120 citra *validation*, dan 120 citra *testing*.

Dengan demikian, keseluruhan dataset terbagi menjadi 3.920 citra *training*, 840 citra *validation*, dan 840 citra *testing*.

Data *training* digunakan untuk melatih model, data *validation* digunakan untuk memantau kinerja model dan menentukan model terbaik, sedangkan data *testing* digunakan untuk mengevaluasi kemampuan akhir model terhadap data yang tidak digunakan selama proses pelatihan. Pemisahan data pelatihan dan pengujian diperlukan agar performa model dapat diukur secara lebih objektif.


Tabel 3.1 Pembagian Dataset Citra Uang Kertas Rupiah

No.	Kelas Nominal	Total Gambar	Training 70%	Validation 15%	Testing 15%
1	Rp1.000	800	560	120	120
2	Rp2.000	800	560	120	120
3	Rp5.000	800	560	120	120
4	Rp10.000	800	560	120	120
5	Rp20.000	800	560	120	120
6	Rp50.000	800	560	120	120
7	Rp100.000	800	560	120	120
	Total	5.600	3.920	840	840

Setelah pembagian data, citra disesuaikan dengan kebutuhan MobileNetV2 melalui proses *preprocessing*. Proses tersebut meliputi perubahan ukuran citra menjadi 224×224 piksel, penyesuaian format citra menjadi RGB, dan normalisasi nilai piksel. Dataset kemudian siap digunakan dalam proses *transfer learning*, *fine-tuning*, dan pengujian model.

3.4 Perancangan Proses/Algoritma

Dataset yang telah disiapkan kemudian diterapkan pada arsitektur CNN MobileNetV2 menggunakan pendekatan *transfer learning* dan *fine-tuning*. Ilustrasi proses penerapan dataset ke dalam model MobileNetV2 dapat dilihat pada Gambar 3.3.



Gambar 3.3 Tahapan Perancangan Proses.


Berdasarkan Gambar 3.3, proses klasifikasi dapat diuraikan sebagai berikut:

1. Dataset citra uang kertas yang diperoleh dari Rahmiatul Mawaddah (2023) dimasukkan ke dalam program berdasarkan folder nominal. Nama folder digunakan sebagai label kelas, sedangkan nama file citra tidak diubah.
2. Citra dibagi menjadi 70% data *training*, 15% data *validation*, dan 15% data *testing*. Dari 800 citra pada setiap kelas, diperoleh 560 citra *training*, 120 citra *validation*, dan 120 citra *testing*. Secara keseluruhan, dataset terdiri atas 3.920 citra *training*, 840 citra *validation*, dan 840 citra *testing*.
3. Citra melalui proses *preprocessing* dengan mengubah ukuran menjadi 224×224 piksel, menyesuaikan format warna menjadi RGB, dan melakukan normalisasi nilai piksel. Dataset juga memiliki variasi citra sisi depan, sisi belakang, serta rotasi dalam kelipatan 90° .

4. Citra hasil *preprocessing* dimasukkan ke dalam MobileNetV2 yang digunakan sebagai *feature extractor*. MobileNetV2 menggunakan bobot *pretrained* dan lapisan klasifikasi bawaannya disesuaikan dengan kebutuhan penelitian.
5. Lapisan klasifikasi baru ditambahkan setelah MobileNetV2, yang terdiri atas *Global Average Pooling*, *dropout*, *dense layer*, dan fungsi aktivasi *softmax*. Lapisan tersebut digunakan untuk menghasilkan probabilitas dari tujuh kelas nominal uang kertas.
6. Pada tahap awal *transfer learning*, lapisan dasar MobileNetV2 dibekukan sehingga bobotnya tidak berubah. Pelatihan dilakukan pada lapisan klasifikasi baru menggunakan data *training*, sedangkan data *validation* digunakan untuk memantau performa model dan menentukan model terbaik.
7. Setelah pelatihan awal selesai, 20 lapisan terakhir MobileNetV2 dibuka untuk proses *fine-tuning*. Proses ini dilakukan agar model dapat menyesuaikan fitur yang telah dipelajari dengan karakteristik citra uang kertas. Selanjutnya, model dilatih kembali menggunakan *learning rate* yang lebih rendah.
8. Model diuji menggunakan 840 citra *testing* yang tidak digunakan selama proses pelatihan. Hasil pengujian digunakan untuk memperoleh nilai *accuracy*, *precision*, *recall*, F1-score, dan *confusion matrix*. Tahap pengujian dilakukan untuk mengetahui kemampuan model dalam mengklasifikasikan tujuh nominal uang kertas. Proses pelatihan dan pengujian model dilakukan dengan memisahkan data pelatihan dari data pengujian agar hasil evaluasi lebih objektif.
9. Model dengan performa terbaik disimpan dan dikonversi ke format TensorFlow Lite dengan ekstensi *.tflite*. TensorFlow menyediakan *TFLiteConverter* untuk mengonversi model Keras ke format TensorFlow Lite.
`tensorflow.python.keras.backend.save_model(model, 'model.tflite', save_format='TF_Lite')`
10. Model TensorFlow Lite diintegrasikan ke dalam aplikasi Android. Aplikasi menerima citra dari kamera, melakukan *preprocessing* sesuai dengan format input model, menjalankan proses inferensi, dan menampilkan nominal uang kertas berdasarkan probabilitas tertinggi.

3.5 Perancangan Tampilan

Perancangan tampilan dilakukan untuk menentukan struktur antarmuka aplikasi Android yang digunakan dalam proses klasifikasi nominal uang kertas. Rancangan ini dibuat dalam bentuk *wireframe* untuk memberikan gambaran awal mengenai tata letak komponen, navigasi, dan fungsi utama pada aplikasi. *Wireframe* yang dirancang terdiri atas tampilan *Home* sebagai halaman utama dan tampilan *CameraX* sebagai halaman pengambilan citra uang kertas. Kedua rancangan tampilan tersebut ditunjukkan pada Gambar 3.4.



Gambar 3.4 Wireframe Aplikasi: (a) Wireframe Tampilan Home, (b) Wireframe Tampilan CameraX.

3.6 Perancangan Pengujian

Tahap pengujian dilakukan untuk mengetahui kinerja model MobileNetV2 dan fungsi aplikasi Android. Pengujian model dilakukan menggunakan 840 citra *testing* dari tujuh kelas nominal dengan membandingkan label sebenarnya dan hasil prediksi model.

Metrik yang digunakan meliputi *accuracy*, *precision*, *recall*, F1-score, dan *confusion matrix*. Pengujian aplikasi dilakukan menggunakan metode *black-box* terhadap fungsi pembukaan aplikasi, izin kamera, pengambilan citra melalui *camera* atau *image_picker*, proses klasifikasi, dan penampilan hasil prediksi. Hasil pengujian dianalisis untuk mengetahui kemampuan model dan kesesuaian fungsi aplikasi dengan rancangan yang telah dibuat

DAFTAR PUSTAKA

1. Alfita, R., Ibadillah, A. F., & Prianto, A. (2022). Identifikasi Nilai Nominal Uang Kertas Berdasarkan Warna Berbasis Image Processing Menggunakan Metode Template Matching. *Jurnal Teknik Elektro dan Komputer TRIAC*, 9(1), 28–32. <https://doi.org/10.21107/triac.v9i1.12487>
2. Allaam, M. R. R., & Wibowo, A. T. (2021). Klasifikasi Genus Tanaman Anggrek Menggunakan Metode Convolutional Neural Network (CNN). *e-Proceeding of Engineering*, 8(2), 3147–3179.
3. Bahar, B., Raban, R. D. Yc., & Arnie, R. (2023). Model Pendeteksi Nominal Uang Kertas Rupiah Menggunakan Teknologi Optical Character Recognition. *Jurnal Ticom: Technology of Information and Communication*, 12(1), 8–13. <https://doi.org/10.70309/ticom.v12i1.101>
4. Boimau, R. A., & Kaesmetan, Y. R. (2024). Klasifikasi citra digital bumbu dan rempah dengan algoritma convolutional neural network (CNN). *Repeater: Publikasi Teknik Informatika dan Jaringan*, 2(3), 26–34.
5. Cahya, F. N., Hardi, N., & Riana, D. (2021). Klasifikasi penyakit mata menggunakan convolutional neural network (CNN). *SISTEMASI: Jurnal Sistem Informasi*, 10(3), 618–626.
6. Cao, J., Li, Y., Sun, M., Chen, Y., Lischinski, D., Cohen-Or, D., Chen, B., & Tu, C. (2022). Do-conv: Depthwise over-parameterized convolutional layer. *IEEE Transactions on Image Processing*, 31, 3726–3736.
7. Dijaya, R., & Setiawan, H. (2023). Buku ajar pengolahan citra digital. *Umsida Press*, 1–85.
8. Fransisca, P. S., & Matondang, N. (2023). Deteksi Citra Digital Penyakit Cacar Monyet menggunakan Algoritma Convolutional Neural Network dengan Arsitektur MobileNetV2. *Jurnal Ilmu Komputer dan Agri-Informatika*, 10(2), 200.
9. GeeksforGeeks. (2026). *Introduction to Convolution Neural Network*. GeeksforGeeks. <https://www.geeksforgeeks.org/machine-learning/introduction-convolution-neural-network/>
10. Goodfellow, I., Bengio, Y., Courville, A., & Bengio, Y. (2016). *Deep learning* (Vol. 1, Nomor 2). MIT press Cambridge.
11. Gunardi, M. F. (2023). Implementasi Augmentasi Citra pada Suatu Dataset. *J. Inform*, 9(1), 1–5.
12. Gunawan, R., Salim, F., Wahyudhy, A. I., Wibowo, A. Y., Yordan, G., & Filamori, R. F. (2025). Klasifikasi Penyakit Daun Kentang dengan Transfer Learning

Menggunakan CNN optimalisasi Arsitektur MobileNetV2. *Jurnal CoSciTech (Computer Science and Information Technology)*, 6(2), 254–258.

13. Hartono, A. C., & Muslikh, A. R. (2025). Penerapan Transfer Learning MobileNetV2 Pada Klasifikasi Citra Jenis Buah-Buahan. *Journal of Information System and Application Development*, 3(2), 103–111.
14. Intyanto, G. W. (2021). Klasifikasi citra bunga dengan menggunakan deep learning: CNN (Convolution Neural Network). *Jurnal Arus Elektro Indonesia*, 7(3), 80–83.
15. Martín Abadi, Ashish Agarwal, Paul Barham, Eugene Brevdo, Zhifeng Chen, Craig Citro, Greg S. Corrado, Andy Davis, Jeffrey Dean, Matthieu Devin, Sanjay Ghemawat, Ian Goodfellow, Andrew Harp, Geoffrey Irving, Michael Isard, Jia, Y., Rafal Jozefowicz, Lukasz Kaiser, Manjunath Kudlur, ... Xiaoqiang Zheng. (2015). *TensorFlow: Large-Scale Machine Learning on Heterogeneous Systems*. <https://www.tensorflow.org/>
16. Mawaddah, R. (2023). *KLASIFIKASI NOMINAL MATA UANG KERTAS INDONESIA MENGGUNAKAN CONVOLUTIONAL NEURAL NETWORK* [Skripsi]. Mulawarman.
17. Mitchell, T. M. (2013). *Machine learning* (Nachdr.). McGraw-Hill.
18. Pratama, M. H. R., Akrom, M., Santosa, A. P., Rosyid, M. R., & Mawaddah, L. (2025). Klasifikasi otomatis korosi menggunakan Convolutional Neural Network dan transfer learning dengan model MobileNetV2. *Jurnal Algoritma*, 22(1), 138–148.
19. Rahmaddeni, R., Adrianto, S., Muhammad, M., Hidayatullah, R., & Daulay, S. (2026). *Pengantar Lengkap Machine Learning: Supervised, Unsupervised, dan Reinforcement Learning Dengan Python*. Serasi Media Teknologi.
20. Rijal, M., Yani, A. M., & Rahman, A. (2024). Deteksi Citra Daun untuk Klasifikasi Penyakit Padi menggunakan Pendekatan Deep Learning dengan Model CNN. *Jurnal Teknologi Terpadu*, 10(1), 56–62.
21. Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., & Chen, L.-C. (2018). MobileNetV2: Inverted Residuals and Linear Bottlenecks. *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 4510–4520. <https://doi.org/10.1109/CVPR.2018.00474>
22. Sharifani, K., & Amini, M. (2023). Machine learning and deep learning: A review of methods and applications. *World information technology and engineering journal*, 10(07), 3897–3904.
23. Taye, M. M. (2023). Understanding of machine learning with deep learning: Architectures, workflow, applications and future directions. *Computers*, 12(5), 91.

24. Vickers, P., Barrault, L., Monti, E., & Aletras, N. (2023). *We need to talk about classification evaluation metrics in NLP*. 498–510.
25. Wona, M. M. A., Asyifa, S. A., Virgianti, R., Hamid, M. N., Handoko, I. M., Septiani, N. W. P., & Lestari, M. (2023). Klasifikasi Batik Indonesia Menggunakan Convolutional Neural Network (CNN). *Jurnal Rekayasa Teknologi Informasi (JURTI)*, 7(2), 172–179.
26. Yahya, H., & Fauziah, E. (2026). Implementasi CNN Transfer Learning MobileNetV2 untuk Klasifikasi Mata Uang Rupiah bagi Tunanetra. *RIGGS: Journal of Artificial Intelligence and Digital Business*, 5(2), 20754–20763. <https://doi.org/10.31004/riggs.v5i2.12446>
27. Zalvadila, A. (2023). Klasifikasi Penyakit Tanaman Bawang Merah Menggunakan Metode SVM dan CNN. *Jurnal Informatika: Jurnal Pengembangan IT*, 8(3), 255–260.
28. Zhao, X., Wang, L., Zhang, Y., Han, X., Deveci, M., & Parmar, M. (2024). A review of convolutional neural networks in computer vision: X. Zhao et al. *Artificial Intelligence Review*, 57(4), 99.

LAMPIRAN

Lampiran 1. Judul Lampiran



url QR code

- Untuk membuat lampiran, dapat ke tab References > Insert Caption. Lampiran harus Align Left 11 pt. Setiap isi lampiran yang terpotong, diberi suffix “(Lanjutan)”.
- Untuk mengupdate angka caption, dapat klik kanan angkanya, kemudian Update Field.
- QR Code minimal 3x3 cm dan maksimal 6x6 cm, boleh diletakkan di tengah atau kiri. Untuk membuatnya Anda dapat menggunakan situs gratis seperti <https://genqrcode.com> yang tidak memiliki link referral ke website penyediaanya.
- Untuk memperpendek link yang terlalu panjang misal link folder dari GDrive dst, Anda dapat gunakan <https://home.s.id> karya anak bangsa.

Lampiran 2. Tabel Peringkat Hasil Pengujian Model pada Data Validasi

Urutan	mAP ₅₀₋₉₅ (%)		mAP ₅₀ (%)		Mean Recall (%)	
1	YOLOv8-L	77,12	YOLOv8-L	97,86	YOLOv8-L	96,13
2	YOLOv8-S	76,98	YOLOv8-S	97,84	YOLOv11-X	95,50
3	YOLOv8-M	76,95	YOLOv8-X	97,80	YOLOv8-X	94,85
4	YOLOv8-X	76,91	RT-DETR-L	97,58	YOLOv11-M	94,71
5	YOLOv11-L	76,75	YOLOv9-S	97,50	YOLOv11-L	94,65
6	YOLOv11-S	76,06	YOLOv11-X	97,46	YOLOv8-M	94,49
7	YOLOv11-M	76,02	YOLOv11-S	97,32	YOLOv11-S	94,48
8	YOLOv11-X	75,52	YOLOv11-L	97,16	YOLOv9-E	94,37
9	YOLOv9-E	74,78	YOLOv8-M	97,04	YOLOv8-N	93,82
10	YOLOv9-M	74,28	YOLOv11-M	96,95	YOLOv8-S	93,25
11	YOLOv9-S	73,57	YOLOv9-M	96,75	RT-DETR-L	92,78
12	RT-DETR-L	73,20	YOLOv9-E	96,59	YOLOv9-C	91,32
13	YOLOv8-N	73,01	RT-DETR-X	96,08	RT-DETR-X	90,85
14	RT-DETR-X	72,58	YOLOv8-N	95,75	YOLOv9-M	89,99

Lampiran 6. Tabel Peringkat Hasil Pengujian Model pada Data Validasi (Lanjutan)

Urutan	mAP ₅₀₋₉₅ (%)		mAP ₅₀ (%)		Mean Recall (%)	
15	YOLOv11-N	69,42	YOLOv9-M	94,54	YOLOv10-S	91,26
16	RT-DETR-L	68,95	YOLOv11-N	94,00	YOLOv10-M	91,21
17	YOLOv9-T	68,92	YOLOv10-B	93,75	YOLOv8-N	90,66
18	YOLOv10-M	67,71	RT-DETR-L	93,74	RT-DETR-X	90,18
19	YOLOv10-B	67,22	YOLOv10-L	93,53	YOLOv11-N	88,97
20	YOLOv10-S	66,82	YOLOv10-X	93,04	YOLOv10-B	88,85
21	YOLOv10-L	66,51	YOLOv8-N	92,56	YOLOv9-T	88,75
22	YOLOv10-X	66,11	YOLOv9-T	91,53	YOLOv10-X	88,16
23	YOLOv10-N	57,67	YOLOv10-N	88,03	YOLOv10-N	81,93