

**KLASIFIKASI MOTIF TENUN SAMARINDA
MENGUNAKAN CNN-SVM DAN CONTENT-BASED
IMAGE RETRIEVAL UNTUK MENAMPILKAN CITRA
SERUPA**

SKRIPSI

Oleh:

**Muchlas Andrey Pahlevi
2209106082**



**FAKULTAS TEKNIK
UNIVERSITAS MULAWARMAN**

**SAMARINDA
2026**

KLASIFIKASI MOTIF TENUN SAMARINDA MENGUNAKAN CNN-SVM DAN CONTENT-BASED IMAGE RETRIEVAL UNTUK MENAMPILKAN CITRA SERUPA

Diajukan sebagai salah satu syarat untuk menyelesaikan pendidikan
pada Program Studi Strata 1 Informatika,
Fakultas Teknik, Universitas Mulawarman

Oleh:

**Muchlas Andrey Pahlevi
2209106082**



**FAKULTAS TEKNIK
UNIVERSITAS MULAWARMAN**

**SAMARINDA
2026**

PERNYATAAN KEASLIAN SKRIPSI

Saya menyatakan dengan sesungguhnya bahwa skripsi dengan judul:

**KLASIFIKASI MOTIF TENUN SAMARINDA MENGGUNAKAN CNN-SVM
DAN CONTENT-BASED IMAGE RETRIEVAL UNTUK MENAMPILKAN
CITRA SERUPA**

yang dibuat sebagai salah satu syarat untuk menyelesaikan pendidikan pada Program Studi S1 Informatika, Fakultas Teknik, Universitas Mulawarman, sejauh yang saya ketahui bukan merupakan tiruan atau duplikasi dari skripsi yang sudah dipublikasikan dan atau pernah dipakai untuk mendapatkan gelar kesarjanaan di lingkungan Universitas Mulawarman maupun di Perguruan Tinggi atau instansi manapun, kecuali bagian yang sumber informasinya dicantumkan sebagaimana mestinya.

Samarinda, Tgl bln thn

Materai

(Nama Mahasiswa)

NIM. ...

KLASIFIKASI MOTIF TENUN SAMARINDA MENGUNAKAN CNN-SVM DAN CONTENT-BASED IMAGE RETRIEVAL UNTUK MENAMPILKAN CITRA SERUPA

Oleh:

Muchlas Andrey Pahlevi
2209106082

Telah dibahas dalam Rapat Dosen Pembimbing pada [tgl, bln, tahun] dan dinyatakan memenuhi syarat sebagai Skripsi, dengan Dosen Pembimbing:

- I. Rosmasari, S.Kom., M.T
- II. Awang Harsa Kridalaksana, S.Kom., M.Kom.

Koordinator Program Studi S1 Informatika,
Fakultas Teknik, Universitas Mulawarman,

Awang Harsa Kridalaksana, S.Kom., M.Kom.
NIP 19731229 200501 1 002

Persembahan untuk

Muchlas Andrey Pahlevi

2209106082

Program Studi Informatika

Dosen Pembimbing

I. Rosmasari, S.Kom., M.T

II. Awang Harsa Kridalaksana, S.Kom., M.Kom

KLASIFIKASI MOTIF TENUN SAMARINDA MENGGUNAKAN CNN-SVM DAN CONTENT-BASED IMAGE RETRIEVAL UNTUK MENAMPILKAN CITRA SERUPA

ABSTRAK

Motif tenun Samarinda merupakan warisan budaya yang perlu dilestarikan, namun dokumentasi dan pengenalannya secara digital masih terbatas sehingga menyulitkan identifikasi dan penelusuran motif serupa. Penelitian ini bertujuan membangun sistem klasifikasi motif tenun Samarinda menggunakan pendekatan CNN-SVM sekaligus menampilkan citra serupa melalui *Content-Based Image Retrieval* (CBIR). Ekstraksi fitur dilakukan menggunakan arsitektur VGG16 pra-terlatih (ImageNet) pada lapisan Block4_pool yang diikuti *Global Average Pooling* sehingga menghasilkan vektor fitur yang terdiri dari 512 nilai fitur. Vektor fitur diklasifikasikan menggunakan *Support Vector Machine* dengan skema *One-vs-Rest* (kernel linear, $C=0.001$) yang parameternya ditentukan melalui *Grid Search* dengan validasi silang *5-fold*. Proses *retrieval* menggunakan jarak *Euclidean* dengan membandingkan fitur citra *query* terhadap seluruh citra pada galeri tanpa membatasi berdasarkan kelas hasil prediksi. Sistem diuji pada tiga kelas motif, yaitu Hatta, Pucuk Rebung, dan Cumi. Hasil pengujian menunjukkan model CNN-SVM mencapai akurasi sebesar 100%, dengan nilai *precision*, *recall*, dan *F1-score* yang seimbang antarkelas, serta *Mean Precision@5* sebesar 96,33% pada tahap *retrieval*. Hasil ini menunjukkan bahwa kombinasi CNN-SVM dan CBIR mampu mengklasifikasikan sekaligus menampilkan citra motif tenun Samarinda yang serupa secara akurat, sehingga dapat mendukung pelestarian dan dokumentasi digital motif tenun Samarinda.

Kata kunci: Tenun Samarinda, klasifikasi citra, VGG16, Support Vector Machine, Content-Based Image Retrieval

Muchlas Andrey Pahlevi

2209106082

Informatics Study Program

Supervisors

I. Rosmasari, S.Kom., M.T

II. Awang Harsa Kridalaksana, S.Kom., M.Kom

Classification of Samarinda Weaving Motifs Using Hybrid CNN-SVM and Content-Based Image Retrieval for Similar Image Display

ABSTRACT

Samarinda woven fabric (tenun) motifs are a cultural heritage that needs to be preserved; however, their digital documentation and recognition remain limited, making it difficult to identify motifs and retrieve similar ones. This study aims to develop a classification system for Samarinda tenun motifs using a CNN-SVM approach while also displaying similar images through Content-Based Image Retrieval (CBIR). Feature extraction is performed using a pre-trained VGG16 architecture (ImageNet) at the Block4_pool layer followed by Global Average Pooling, producing a one-dimensional feature vector consisting of 512 feature values. The feature vectors are classified using a Support Vector Machine with a One-vs-Rest scheme (linear kernel, $C=0.001$), whose parameters were determined through Grid Search with 5-fold cross-validation. The retrieval process uses Euclidean distance by comparing the query image features against all images in the gallery without restricting the search based on the predicted class. The system was tested on three motif classes, namely Hatta, Pucuk Rebung, and Cumi. The experimental results show that the CNN-SVM model achieved an accuracy of 100%, with balanced precision, recall, and F1-score across classes, and a Precision@5 of 96.33% in the retrieval stage. These results demonstrate that combining CNN-SVM and CBIR can accurately classify and retrieve similar Samarinda tenun motif images, thereby supporting the digital preservation and documentation of Samarinda tenun motifs.

Keywords: Samarinda tenun, image classification, VGG16, Support Vector Machine, Content-Based Image Retrieval

KATA PENGANTAR

Puji syukur kehadiran Tuhan Yang Maha Esa atas rahmat dan karunia-Nya sehingga penulis dapat menyelesaikan skripsi yang berjudul ” **KLASIFIKASI MOTIF TENUN SAMARINDA MENGGUNAKAN CNN-SVM DAN CONTENT-BASED IMAGE RETRIEVAL UNTUK MENAMPILKAN CITRA SERUPA**”. Skripsi ini disusun sebagai salah satu syarat untuk menyelesaikan studi di Program Studi Informatika, Fakultas Teknik, Universitas Mulawarman.

Penelitian ini dilakukan di Universitas Mulawarman dan pengumpulan data dilaksanakan pada bulan Januari hingga April 2026. Penulis menyadari bahwa penyusunan skripsi ini tidak lepas dari bantuan dan dukungan berbagai pihak. Oleh karena itu, pada kesempatan ini penulis ingin mengucapkan terima kasih kepada semua pihak yang telah mendukung serta membantu penulis selama proses penyusunan proposal skripsi, kepada:

1. Orang tua dan Saudara-saudara saya atas do’a, bimbingan serta kasih sayangnya.
2. Bapak Prof. Dr. Ir. Tamrin, ST.,MT., IPU., APEC Eng selaku Dekan Fakultas Teknik, Univertas Mulawarman.
3. Bapak Awang Harsa Kridalaksana, S.Kom., M.Kom. selaku Koordinator Program Studi Informatika.
4. Ibu Rosmasari, S.Kom., M.T selaku Pembimbing I yang selalu memberikan arahan dan masukan terhadap penelitian ini.
5. Bapak Awang Harsa Kridalaksana, S.Kom., M.Kom selaku Pembimbing II yang selalu memberikan arahan dan masukan terhadap penelitian ini.
6. Bapak Gubtha Mahendra Putra, S.Kom, M.Eng selaku Penguji I atas saran dan masukan terhadap penelitian ini.
7. Bapak Anton Prafanto, M.T selaku Penguji II atas saran dan masukan terhadap penelitian ini.
8. Segenap Dosen Program Studi Informatika, yang telah memberikan ilmu pengetahuan selama mengikuti perkuliahan.
9. Rekan-rekan seperjuangan yang terus memberikan dukungan semangat demi terselesainya tugas ini.

Saya menyadari bahwa proposal skripsi ini tidak luput dari berbagai kekurangan. Oleh karena itu, semua kritik dan saran yang bersifat memperbaiki demi kesempurnaan sangat diharapkan.

Samarinda,..... 2026

Penulis

DAFTAR ISI

halaman

HALAMAN JUDUL	i
PERNYATAAN KEASLIAN SKRIPSI.....	i
HALAMAN PENGESAHAN.....	iii
HALAMAN PERSEMBAHAN	iv
ABSTRAK	v
ABSTRACT	vi
KATA PENGANTAR.....	vii
DAFTAR ISI	viii
DAFTAR TABEL	x
DAFTAR GAMBAR.....	xi
DAFTAR LAMPIRAN	xii
DAFTAR ISTILAH	xiii
DAFTAR SINGKATAN.....	xv
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang.....	1
1.2 Rumusan Masalah.....	3
1.3 Batasan Masalah	4
1.4 Tujuan Penelitian	4
1.5 Manfaat Penelitian	5
1.6 Kontribusi Penelitian	5
BAB II TINJAUAN PUSTAKA	7
2.1 Penelitian Terkait.....	7
2.2 Tenun Samarinda	15
2.3 Pengolahan Citra Digital	16
2.4 Ekstraksi Fitur Citra.....	17
2.5 Data Mining dan Klasifikasi	18
2.5.1 Pengertian Data Mining	18
2.5.2 Teknik-Teknik Klasifikasi	19
2.5.3 Evaluasi Klasifikasi	20
2.6 Machine Learning.....	21
2.6.1 Pengertian Machine Learning.....	21
2.6.2 Deep learning.....	22
2.6.3 Convolutional Neural Network	23
2.6.4 Arsitektur VGG16	24
2.6.5 Support Vector Machine.....	25
2.6.6 CNN-SVM Hybrid Model	26
2.7 Content-Based Image Retrieval (CBIR).....	26
2.8 Pengukuran Kemiripan Citra	28
2.9 Evaluasi Retrieval.....	29
BAB III METODOLOGI PENELITIAN	31
3.1 Tahapan Pelaksanaan Penelitian.....	31
3.2 Pengumpulan Data.....	34
3.3 Perancangan Data	34

3.3.1	Struktur Dataset	34
3.3.2	Spesifikasi Data Citra	35
3.3.3	Distribusi Data	35
3.3.4	Pelabelan Data	36
3.3.5	Data Splitting	37
3.4	Perancangan Proses/Algoritma	38
3.4.1	Perancangan Sistem Klasifikasi dan Retrieval	38
3.4.2	Perancangan Alur Proses Sistem	40
3.4.3	Perancangan Preprocessing	41
3.4.4	Perancangan Ekstraksi Fitur Menggunakan CNN	42
3.4.5	Perancangan Training Model SVM	45
3.4.6	Perancangan Proses Klasifikasi	47
3.4.7	Perancangan Proses Retrieval	49
3.4.8	Perancangan Evaluasi Sistem	51
3.5	Perancangan Tampilan	53
3.6	Perancangan Pengujian	55
BAB IV HASIL DAN PEMBAHASAN		57
4.1	Pengolahan Data	57
4.1.1	Dataset Penelitian	57
4.1.2	Preprocessing Citra	58
4.1.3	Pembagian Data (Training dan Testing)	58
4.2	Implementasi Sistem	59
4.2.1	Implementasi CNN-SVM	59
4.2.2	Implementasi Content-Based Image Retrieval	60
4.2.3	Implementasi Antarmuka Streamlit	60
4.3	Hasil Pengujian Sistem	62
4.3.1	Hasil Klasifikasi CNN-SVM	63
4.3.2	Hasil Pengujian Retrieval	64
4.3.3	Evaluasi Precision@5	65
4.3.4	Hasil Pengujian Robustness	66
4.3.5	Hasil Pengukuran Waktu Pemrosesan	67
4.4	Pembahasan	68
4.4.1	Analisis Pemilihan Layer VGG16	69
4.4.2	Analisis Hasil Retrieval	70
4.4.3	Analisis Ketahanan Model terhadap Variasi Kondisi Citra	71
4.4.4	Analisis Waktu Pemrosesan	72
BAB V KESIMPULAN DAN SARAN		73
5.1	Kesimpulan	73
5.2	Saran	74
DAFTAR PUSTAKA		75

DAFTAR TABEL

	<i>Halaman</i>
Tabel 3.1 Distribusi Data	36
Tabel 3.2 Splitting data	37
Tabel 3.3 Arsitektur VGG16 untuk Ekstraksi Fitur	44
Tabel 3.4 Parameter Grid untuk Hyperparameter Tuning	46
Tabel 4.1 Distribusi Dataset Penelitian	57
Tabel 4.2 Perbandingan Citra Sebelum dan Sesudah Preprocessing	58
Tabel 4.3 Pembagian Data Latih dan Data Uji	59
Tabel 4.4 Hasil Analisis Model CNN-SVM pada Data Uji	63
Tabel 4.5 Confusion Matrix Model CNN-SVM pada Data Uji	64
Tabel 4.6 Hasil Evaluasi Precision@5 Sistem CBIR	66
Tabel 4.7 Hasil Pengujian Robustness terhadap Variasi Kondisi Citra	66
Tabel 4.8 Hasil Pengukuran Waktu Pemrosesan per Citra	68
Tabel 4.9 Perbandingan Performa Layer VGG16 sebagai Feature Extractor	69

DAFTAR GAMBAR

	<i>Halaman</i>
Gambar 3.1 Diagram Tahapan Pelaksanaan	31
Gambar 3.2 Struktur Direktori.....	35
Gambar 3.3 Citra Tiap Kelas: (a) Hatta, (b) Pucuk Rebung, (c) Cumi	36
Gambar 3.4 Use Case Diagram Sistem Klasifikasi Motif Tenun Samarinda	39
Gambar 3.5 Flowchart Alur Proses Sistem.....	40
Gambar 3.6 Diagram Proses Arsitektur VGG16 Untuk Ekstraksi Fitur CNN	45
Gambar 3.7 Flowchart Proses Training SVM	47
Gambar 3.8 Flowchart Proses Klasifikasi.....	49
Gambar 3.9 Flowchart Proses Retrieval Menggunakan CBIR	50
Gambar 3.10 Rancangan Tampilan Utama Aplikasi	54
Gambar 4.1 Tampilan Antarmuka Sistem	62
Gambar 4.2 Hasil Retrieval Citra Query Motif Hatta.....	65
Gambar 4.3 Hasil Retrieval Citra Query Motif Pucuk Rebung.....	65
Gambar 4.4 Hasil Retrieval Citra Query Motif Cumi/Bunga Dayak	65

DAFTAR LAMPIRAN

	<i>Halaman</i>
Lampiran 1 <i>contents</i>	42

DAFTAR ISTILAH

Arti

Contents

<i>Content-Based Image Retrieval</i>	Sistem pencarian/pengelompokkan citra berdasarkan kemiripan fitur visual (warna, tekstur, bentuk).
<i>Feature Extraction</i>	Proses transformasi data mentah menjadi representasi fitur bermakna.
<i>Deep Features</i>	Fitur tingkat tinggi yang diekstraksi oleh CNN dari layer konvolusi/FC.
<i>Preprocessing</i>	Tahapan persiapan citra sebelum ekstraksi fitur/klasifikasi (resize, normalisasi, dll.).
<i>Convolution</i>	Operasi konvolusi (menggeser filter/kernel) untuk membentuk feature map.
<i>Feature Map</i>	Hasil keluaran operasi konvolusi yang merepresentasikan keberadaan fitur.
<i>Pooling</i>	Proses reduksi dimensi spasial <i>feature map</i>
<i>Max Pooling</i>	Mengambil nilai maksimum pada area tertentu untuk mempertahankan fitur dominan.
<i>Average Pooling</i>	Mengambil nilai rata-rata pada area tertentu untuk mereduksi ukuran fitur.
<i>ReLU</i>	Fungsi aktivasi yang mempertahankan nilai positif dan meniadakan nilai negatif.
<i>Transfer Learning</i>	Memanfaatkan model CNN yang sudah dilatih (pre-trained) untuk tugas/dataset baru.
<i>Pre-trained model</i>	Model yang bobotnya sudah dilatih pada dataset besar.
<i>Frozen Layer</i>	Layer yang bobotnya “dibekukan” saat <i>fine-tuning</i> .

<i>Hyperparameter</i>	Parameter yang diatur sebelum pelatihan.
<i>Grid Search</i>	Metode pencarian kombinasi hyperparameter terbaik berdasarkan ruang parameter.
<i>Cross Validation</i>	Skema evaluasi dengan pembagian data berulang.
<i>Confusion Matrix</i>	Tabel evaluasi klasifikasi (TP, TN, FP, FN).
<i>Overfitting</i>	Kondisi model sangat baik di data latih tapi menurun di data uji.
<i>C</i>	Parameter penalti SVM untuk mengatur trade-off margin vs kesalahan klasifikasi.
<i>γ (gamma)</i>	Parameter pada kernel RBF untuk mengatur jangkauan pengaruh data.
<i>Euclidean Distance</i>	Ukuran jarak (metrik) untuk menghitung kemiripan fitur.

DAFTAR SINGKATAN

Arti

Content

CBIR	<i>Content-Based Image Retrieval</i>
CNN	<i>Convolutional Neural Network</i>
SVM	<i>Support Vector Machine</i>
VGG16	<i>Visual Geometry Group</i>
GLCM	<i>Gray Level Co-occurrence Matrix</i>
LBP	<i>Local Binary Pattern</i>
RGB	<i>Red Green Blue</i>
RBF	<i>Radial Basis Function</i>
OvR	<i>One-vs-Rest</i>
TP	<i>True Positive</i>
TN	<i>True Negative</i>
FP	<i>False Positive</i>
FN	<i>False Negative</i>
ATBM	<i>Alat Tenun Bukan Mesin</i>
JPEG	<i>Joint Photographic Experts Group</i>
GPU	<i>Graphics Processing Unit</i>

BAB I

PENDAHULUAN

1.1 Latar Belakang

Tenun Samarinda merupakan salah satu warisan budaya khas Kalimantan Timur yang memiliki nilai estetika dan filosofis tinggi. Setiap motif yang dihasilkan mengandung makna simbolik yang merepresentasikan identitas budaya masyarakat setempat. Namun, perkembangan industri tekstil modern serta menurunnya jumlah pengrajin tradisional menyebabkan keberadaan Tenun Samarinda semakin terpinggirkan. Salah satu tantangan yang dihadapi adalah masih terbatasnya dokumentasi dan pengenalan motif Tenun Samarinda secara digital, sehingga pengetahuan mengenai ragam motif berpotensi berkurang dari waktu ke waktu (Agusma, 2021). Selain itu, upaya digitalisasi juga menjadi penting dalam mendukung pelestarian budaya dan pengembangan ekonomi kreatif berbasis teknologi (Rosmasari et al., 2026).

Kondisi tersebut menjadi salah satu faktor yang mendorong penelitian ini dilakukan. Dalam proses pengenalan motif Tenun Samarinda, identifikasi motif masih banyak bergantung pada pengamatan visual oleh pengrajin, penjual, atau pihak yang memiliki pengetahuan mengenai karakteristik motif. Cara tersebut tidak hanya membutuhkan pengalaman khusus, tetapi juga cenderung subjektif dan sulit diterapkan apabila jumlah citra motif yang harus dikenali semakin banyak. Selain itu, beberapa motif memiliki kemiripan dari segi pola, warna, dan tekstur, sehingga pengguna yang belum memahami karakteristik motif dapat mengalami kesulitan dalam membedakannya. Kondisi ini menunjukkan perlunya sistem otomatis yang mampu membantu proses pengenalan motif secara cepat, konsisten, dan objektif. Dalam konteks tersebut, teknologi pengolahan citra digital dan kecerdasan buatan dapat dimanfaatkan untuk mendukung proses identifikasi motif (Varshney et al., 2024).

Salah satu pendekatan yang dapat digunakan untuk mengenali motif adalah klasifikasi citra. Pada penelitian ini, klasifikasi digunakan untuk menentukan kelas motif Tenun Samarinda dari citra masukan. Untuk memperoleh representasi visual yang baik, penelitian ini memanfaatkan Convolutional Neural Network (CNN) sebagai feature extractor. CNN dipilih karena mampu mengekstraksi fitur citra secara otomatis dan mendalam tanpa memerlukan perancangan fitur manual, serta telah terbukti efektif pada

berbagai tugas pengenalan pola visual, termasuk pada citra tekstil dan kain tradisional (Li & Zhu, 2024; Sha et al., 2024). Selanjutnya, fitur hasil ekstraksi CNN diklasifikasikan menggunakan Support Vector Machine (SVM), yang dikenal efektif dalam menangani data berdimensi tinggi dan membentuk batas pemisah kelas yang optimal (Tang et al., 2024).

Sejumlah penelitian terdahulu menunjukkan bahwa pendekatan CNN maupun kombinasi CNN-SVM memiliki potensi yang baik dalam pengenalan citra kain tradisional. Penelitian oleh (Muhartini et al., 2024) menunjukkan bahwa model CNN seperti VGG16 dan DenseNet121 mampu menghasilkan akurasi tinggi dalam klasifikasi sarung Samarinda berdasarkan jenis alat tenun. Penelitian lain oleh (Kelen & Baso, 2023) juga memperlihatkan bahwa SVM efektif untuk klasifikasi motif tenun. Selain itu, beberapa studi menyatakan bahwa kombinasi CNN sebagai feature extractor dan SVM sebagai classifier mampu meningkatkan performa klasifikasi dibandingkan penggunaan CNN murni, khususnya dalam hal generalisasi model pada dataset terbatas (Biswas & Islam, 2023; Ikhsan & Rahardi, 2025; Serin et al., 2024; Wu et al., 2023).

Selain kebutuhan untuk mengenali kelas motif, penelitian ini juga dipengaruhi oleh kebutuhan pengguna terhadap referensi visual. Dalam pengenalan motif kain, hasil berupa label kelas saja belum selalu cukup, karena pengguna juga membutuhkan contoh citra lain yang memiliki kemiripan visual sebagai pembandingan. Kebutuhan ini relevan dalam proses dokumentasi digital, pencarian arsip motif, dan penyajian referensi visual bagi pengguna. Untuk memenuhi kebutuhan tersebut, digunakan pendekatan Content-Based Image Retrieval (CBIR), yaitu metode pencarian citra berdasarkan isi visual citra seperti warna, tekstur, bentuk, atau representasi fitur lainnya (Tena et al., 2021; Zhang & Liu, 2023). Dalam konteks ini, CBIR tidak berfungsi untuk menentukan kelas motif, melainkan untuk melakukan retrieval citra yang paling mirip dengan citra *query* berdasarkan fitur visualnya.

Pada penelitian ini, CBIR diterapkan setelah tahap klasifikasi selesai. Sistem terlebih dahulu menentukan kelas motif citra input menggunakan kombinasi CNN dan SVM. Selanjutnya, proses retrieval dilakukan dengan membandingkan fitur citra *query* terhadap fitur seluruh citra pada galeri tanpa membatasi pencarian berdasarkan kelas hasil klasifikasi. Sistem menghitung tingkat kemiripan antara citra *query* dan seluruh citra pada

galeri menggunakan jarak *Euclidean*, kemudian menampilkan lima citra teratas dengan jarak terdekat. Pendekatan ini memungkinkan sistem menemukan citra yang memiliki kemiripan visual berdasarkan karakteristik fiturnya, termasuk ketika citra yang paling mirip berasal dari kelas motif yang berbeda. Pendekatan retrieval berbasis fitur visual seperti ini juga sejalan dengan konsep CBIR pada citra tekstil yang menekankan pentingnya representasi fitur untuk membedakan pola yang kompleks (Tena et al., 2021; Varshney et al., 2024).

Berdasarkan uraian tersebut, penelitian ini dilakukan karena adanya kebutuhan untuk membantu proses identifikasi motif Tenun Samarinda yang masih banyak dilakukan secara manual, terbatasnya dokumentasi dan pengenalan motif secara digital, serta perlunya sistem yang tidak hanya memberikan hasil klasifikasi, tetapi juga menyediakan citra pembandingan yang serupa. Oleh karena itu, penelitian ini membangun sistem pengenalan motif Tenun Samarinda yang menggabungkan klasifikasi dan CBIR dalam satu alur proses. Klasifikasi dilakukan untuk menentukan kelas motif menggunakan CNN sebagai *feature extractor* dan SVM sebagai *classifier*, sedangkan CBIR digunakan untuk menampilkan citra-citra yang paling mirip berdasarkan fitur visual dari seluruh galeri. Dengan demikian, sistem yang dihasilkan tidak hanya mampu mengenali motif Tenun Samarinda, tetapi juga mampu menyediakan referensi visual yang relevan guna mendukung digitalisasi, dokumentasi, dan pelestarian budaya lokal.

1.2 Rumusan Masalah

Berdasarkan latar belakang penelitian, maka yang menjadi rumusan masalah dalam penelitian ini adalah

1. Bagaimana membangun sistem klasifikasi motif Tenun Samarinda menggunakan CNN sebagai *feature extractor* dan SVM sebagai *classifier*?
2. Bagaimana mengimplementasikan *Content-Based Image Retrieval* (CBIR) untuk menampilkan lima citra teratas yang paling mirip?
3. Bagaimana performa model CNN-SVM dalam klasifikasi motif Tenun Samarinda berdasarkan *accuracy*, *precision*, *recall*, dan *F1-score*, serta performa CBIR dalam menampilkan citra serupa berdasarkan *Precision@5*?

1.3 Batasan Masalah

Penelitian ini disusun berdasarkan data-data yang diperoleh. Luasnya bidang yang dihadapi membuat penelitian ini harus dibatasi. Ruang lingkup masalah dibatasi pada:

1. Sistem klasifikasi yang dikembangkan menggunakan CNN sebagai feature extractor dan SVM sebagai classifier.
2. CBIR pada penelitian ini digunakan setelah proses klasifikasi untuk menampilkan citra yang memiliki kemiripan visual dengan citra *query*. Proses *retrieval* dilakukan terhadap seluruh citra pada galeri tanpa membatasi pencarian berdasarkan kelas hasil klasifikasi. CBIR tidak digunakan untuk menentukan kelas motif.
3. Dataset yang digunakan terbatas pada citra digital motif Tenun Samarinda dengan tiga kelas motif yaitu Hatta, Pucuk Rebung, dan Cumi. Pemilihan tiga kelas motif dilakukan berdasarkan ketersediaan dataset citra yang memiliki jumlah dan kualitas memadai untuk proses pelatihan dan evaluasi model.
4. Evaluasi klasifikasi difokuskan pada metrik accuracy, precision, recall, dan F1-score, sedangkan evaluasi retrieval difokuskan pada relevansi hasil pencarian, seperti Precision@5.
5. Analisis hasil klasifikasi hanya mempertimbangkan tingkat akurasi motif, bukan makna simbolik atau filosofis yang terkandung dalam motif Tenun Samarinda.

1.4 Tujuan Penelitian

Tujuan yang ingin dicapai dalam penelitian ini adalah:

1. Membangun sistem klasifikasi motif Tenun Samarinda menggunakan CNN sebagai feature extractor dan SVM sebagai classifier.
2. Mengimplementasikan sistem Content-Based Image Retrieval (CBIR) untuk menampilkan lima citra teratas yang paling mirip berdasarkan kemiripan fitur visual.
3. Mengevaluasi performa sistem klasifikasi dan retrieval motif Tenun Samarinda.

1.5 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat pada berbagai pihak, khususnya:

1. Penulis

Penelitian ini dapat menambah wawasan dan pengalaman dalam menerapkan pengolahan citra, deep learning, machine learning, dan Content-Based Image Retrieval (CBIR) pada kasus nyata, khususnya dalam klasifikasi dan retrieval motif Tenun Samarinda.

2. Mahasiswa

Penelitian ini dapat menjadi referensi dalam pengembangan penelitian di bidang computer vision, klasifikasi citra, dan CBIR, khususnya yang berkaitan dengan objek budaya dan tekstil tradisional Indonesia.

3. Pengrajin Tenun Samarinda

Penelitian ini diharapkan dapat membantu pengrajin dalam proses pengenalan, dokumentasi, dan pencarian motif Tenun Samarinda secara digital. Sistem yang dikembangkan dapat digunakan sebagai alat bantu untuk menampilkan informasi motif serta citra-citra serupa, sehingga dapat mendukung proses identifikasi motif dan pelestarian Tenun Samarinda.

1.6 Kontribusi Penelitian

Penelitian ini memberikan kontribusi dalam pengembangan sistem pengenalan motif Tenun Samarinda berbasis citra digital dengan menggabungkan dua proses utama, yaitu klasifikasi dan *retrieval*. Kontribusi teknis utama terletak pada penerapan CNN sebagai *feature extractor*, SVM sebagai *classifier*, serta CBIR sebagai mekanisme pencarian citra serupa berdasarkan fitur visual. Secara metodologis, penelitian ini menerapkan proses klasifikasi untuk menentukan kelas motif, kemudian dilanjutkan dengan proses *retrieval* dengan membandingkan fitur citra *query* terhadap seluruh citra pada galeri tanpa membatasi pencarian berdasarkan hasil klasifikasi. Lima citra dengan jarak *Euclidean* terdekat ditampilkan sebagai hasil *retrieval*. Pendekatan ini memungkinkan sistem menemukan citra yang memiliki kemiripan visual tanpa bergantung pada kelas hasil klasifikasi. Secara praktis, penelitian ini diharapkan menghasilkan sistem yang tidak hanya mampu mengenali motif Tenun Samarinda, tetapi

juga memberikan referensi visual berupa citra-citra yang memiliki kemiripan dengan citra *query*. Selain itu, penelitian ini berkontribusi dalam mendukung digitalisasi dan pelestarian warisan budaya lokal melalui penerapan teknologi kecerdasan buatan serta memberikan pendekatan teknologi yang dapat mendukung proses dokumentasi digital motif Tenun Samarinda.

BAB II

TINJAUAN PUSTAKA

2.1 Penelitian Terkait

Penelitian terdahulu menjadi acuan penting dalam pengembangan sistem klasifikasi motif Tenun Samarinda. Beberapa penelitian relevan yang telah dilakukan sebelumnya adalah sebagai berikut:

1. **Metode yang digunakan:** *Deep learning* CNN dengan arsitektur VGG16 dan DenseNet121. **Temuan Penelitian:** Penelitian ini mengembangkan model klasifikasi tekstur sarung Samarinda berdasarkan jenis alat tenun, yaitu alat tenun mesin dan alat tenun bukan mesin. Dataset yang digunakan terdiri dari 2.000 citra tekstur kain yang diambil menggunakan mikroskop digital dengan resolusi tinggi. Penelitian menerapkan dua skenario split data yaitu (70:15:15) dan (80:10:10), untuk melihat pengaruh komposisi data terhadap performa model. Hasil pengujian menunjukkan bahwa arsitektur VGG16 dan DenseNet121 mampu menghasilkan performa klasifikasi yang sangat baik. Pada skenario pembagian data 80:10:10, kedua model mencapai akurasi sempurna 100%, sedangkan pada skenario 70:15:15 keduanya tetap menghasilkan akurasi tinggi sebesar 99,01%. VGG16 dinilai lebih sederhana dan efisien dalam proses pelatihan maupun inferensi, sedangkan DenseNet121 memiliki kemampuan ekstraksi fitur yang kuat melalui konsep *dense connections*. Penelitian ini relevan karena sama-sama menggunakan objek sarung Samarinda dan menerapkan CNN untuk klasifikasi citra. Namun, ruang lingkup penelitian tersebut masih terbatas pada klasifikasi tekstur berdasarkan jenis alat tenun, bukan pada klasifikasi motif Tenun Samarinda. Selain itu, penelitian tersebut belum mengombinasikan CNN dengan SVM sebagai classifier dan belum menerapkan Content-Based Image Retrieval (CBIR) untuk menampilkan citra serupa setelah proses klasifikasi (Muhartini et al., 2024).
2. **Metode yang digunakan:** SURF (Speeded Up Robust Feature) untuk ekstraksi fitur dengan representasi Bag of Visual Words (BoVW) dan Support Vector Machine (SVM) sebagai *classifier*. **Temuan Penelitian:** Penelitian ini bertujuan mengklasifikasikan tujuh kelas motif citra tenun Timor menggunakan kombinasi metode SURF sebagai ekstraksi fitur, BoVW sebagai representasi fitur, dan SVM

sebagai *classifier*. Dataset yang digunakan terdiri dari 420 citra tenun Timor dengan 7 motif berbeda yaitu Belu, Weulun, Naisa, Buna, Nunkolo, Kauniki, dan Biboki. Setiap kelas terdiri dari 60 sub gambar dengan ukuran 150 x 200 piksel. Pengujian dilakukan menggunakan 5-fold cross validation dengan beberapa skenario, yaitu pengujian jumlah cluster pada BoVW, pengujian jenis kernel SVM, serta pengujian metode multi-class SVM menggunakan One Versus One dan One Versus All. Hasil penelitian menunjukkan bahwa kombinasi metode OVA dengan kernel linear dan jumlah cluster 500 menghasilkan akurasi terbaik sebesar 98,10%, sedangkan metode OVO dengan kernel linear dan jumlah cluster yang sama memperoleh akurasi sebesar 97,62%. Hasil tersebut menunjukkan bahwa SVM mampu memberikan performa yang baik dalam klasifikasi motif tenun, terutama ketika didukung oleh pemilihan fitur, jumlah cluster, kernel, dan strategi multi-class yang tepat. Penelitian ini relevan karena sama-sama berfokus pada klasifikasi motif kain tenun dan menggunakan SVM sebagai classifier. Namun, penelitian tersebut masih menggunakan fitur manual berbasis SURF dan BoVW, sehingga belum memanfaatkan kemampuan CNN dalam mengekstraksi fitur visual secara otomatis dan mendalam. Selain itu, penelitian tersebut belum menerapkan CBIR untuk menampilkan citra serupa setelah kelas motif berhasil (Kelen & Baso, 2023).

3. **Metode yang digunakan:** Convolutional Neural Network (CNN) untuk klasifikasi warna kain tenun. **Temuan Penelitian:** Penelitian ini mengembangkan sistem klasifikasi warna kain tenun Lotis dari Kabupaten Timor Tengah Selatan, Nusa Tenggara Timur, yang berasal dari tiga suku besar, yaitu Amanuban, Amanatun, dan Mollo. Dataset yang digunakan terdiri dari 100 citra kain tenun Lotis, dengan pembagian 33 citra dari Suku Amanuban, 34 citra dari Suku Amanatun, dan 33 citra dari Suku Mollo. Citra diambil menggunakan kamera DSLR dengan dua teknik pengambilan gambar, yaitu close-up shot dan medium shot. Tahap preprocessing yang dilakukan meliputi resize citra menjadi 256×256 piksel, normalisasi nilai piksel, serta augmentasi data seperti rotasi, flipping, penyesuaian brightness, dan zoom. Model CNN yang digunakan terdiri dari beberapa lapisan konvolusi, max pooling, flatten, dense layer, dropout, dan output layer dengan aktivasi softmax. Evaluasi dilakukan menggunakan 5-fold cross validation, dengan hasil akurasi yang

bervariasi pada setiap fold. Rata-rata performa model menunjukkan nilai accuracy sebesar 89%, sensitivity sebesar 85,8%, dan specificity sebesar 91,2%. Hasil tersebut menunjukkan bahwa CNN mampu digunakan untuk mengenali karakteristik visual kain tenun, khususnya berdasarkan warna. Penelitian ini relevan karena sama-sama menggunakan CNN pada citra kain tenun. Namun, fokus penelitian tersebut masih terbatas pada klasifikasi warna kain tenun, bukan klasifikasi motif Tenun Samarinda. Selain itu, penelitian tersebut belum mengombinasikan CNN dengan SVM sebagai classifier dan belum menerapkan CBIR untuk menampilkan citra serupa berdasarkan kelas hasil klasifikasi (Nenometa, 2025).

4. **Metode yang digunakan:** Convolutional Neural Network (CNN) untuk klasifikasi pola motif dan warna kain tenun. **Temuan Penelitian:** Penelitian ini bertujuan mengklasifikasikan pola motif kain tenun Bumpak dari Desa Kampai Seluma, Bengkulu, menggunakan metode Convolutional Neural Network. Kain tenun Bumpak memiliki beberapa ragam motif yang berbeda, sehingga proses pengenalan motif tidak mudah dilakukan oleh masyarakat umum dan masih membutuhkan pengetahuan khusus. Dataset penelitian berupa citra kain tenun Bumpak yang diambil menggunakan kamera ponsel dengan kondisi pencahayaan yang baik. Proses klasifikasi diawali dengan penyeragaman ukuran citra menjadi 128×128 piksel, kemudian dilakukan preprocessing berupa konversi citra RGB menjadi grayscale untuk memperoleh pola motif kain. Penelitian ini juga menghitung karakteristik citra berdasarkan beberapa arah sudut, yaitu 0° , 45° , 90° , dan 135° , untuk memperoleh informasi visual seperti contrast, edge, dan pola kemiripan. Pengujian dilakukan menggunakan pengujian fungsional sistem dan pengujian data citra kain tenun. Hasil penelitian menunjukkan bahwa sistem mampu melakukan klasifikasi motif dan warna kain tenun Bumpak dengan akurasi mencapai 98%. Penelitian ini relevan karena sama-sama membahas klasifikasi motif kain tenun menggunakan pendekatan CNN. Namun, penelitian tersebut belum menggunakan arsitektur CNN pre-trained seperti VGG16 untuk ekstraksi fitur, belum mengombinasikan CNN dengan SVM sebagai classifier, dan belum menerapkan

proses retrieval citra serupa setelah kelas motif berhasil diklasifikasikan (Kumala et al., 2023).

5. **Metode yang digunakan:** SqueezeNet untuk ekstraksi fitur dan Decision Tree (DT) untuk klasifikasi. Metode yang digunakan: SqueezeNet untuk ekstraksi fitur dan Decision Tree (DT) untuk klasifikasi. **Temuan Penelitian:** Penelitian ini mengembangkan sistem pengenalan citra kain tenun khas Nusa Tenggara Timur menggunakan SqueezeNet sebagai feature extractor dan Decision Tree sebagai classifier. Dataset yang digunakan terdiri dari 400 citra kain tenun yang dikelompokkan ke dalam empat kelas berdasarkan pulau besar di Nusa Tenggara Timur, yaitu Flores, Rote, Sumba, dan Timor, dengan masing-masing kelas berjumlah 100 citra. Citra yang digunakan terlebih dahulu melalui proses penyesuaian ukuran untuk mengurangi beban komputasi, terutama karena keterbatasan perangkat pemrosesan. Proses ekstraksi fitur menggunakan SqueezeNet menghasilkan representasi fitur yang kemudian digunakan sebagai input pada model Decision Tree. Pemilihan SqueezeNet didasarkan pada kemampuannya menghasilkan fitur yang lebih ringkas dibandingkan arsitektur CNN lain, sehingga proses pelatihan menjadi lebih efisien. Evaluasi dilakukan menggunakan variasi n-fold cross validation, dan hasil penelitian menunjukkan akurasi keseluruhan sebesar 92,9%, dengan nilai precision 0,930, recall 0,929, F1-score 0,929, dan AUC 0,959. Hasil tersebut menunjukkan bahwa kombinasi CNN sebagai ekstraksi fitur dan algoritma machine learning sebagai classifier dapat digunakan secara efektif untuk klasifikasi citra kain tenun. Penelitian ini relevan karena sama-sama memanfaatkan CNN sebagai feature extractor pada citra kain tradisional. Namun, ruang lingkup penelitian tersebut masih terbatas pada pengenalan citra kain berdasarkan wilayah asal, bukan klasifikasi motif Tenun Samarinda secara spesifik. Selain itu, classifier yang digunakan adalah Decision Tree, bukan SVM, serta belum dilengkapi dengan mekanisme Content-Based Image Retrieval untuk menampilkan citra paling mirip setelah proses klasifikasi dilakukan (Sooai & Dwiandri, 2024).
6. **Metode yang digunakan:** Convolutional Neural Network (CNN) dan Recurrent Neural Network (RNN). **Temuan Penelitian:** Penelitian ini mengembangkan

sistem klasifikasi motif kain tenun di Pulau Flores, Nusa Tenggara Timur, menggunakan metode deep learning dengan membandingkan kinerja CNN dan RNN. Dataset yang digunakan berupa citra motif kain tenun dari beberapa kabupaten di Pulau Flores, seperti Sikka, Ende, Manggarai, dan Nagekeo. Setiap motif difoto beberapa kali sehingga menghasilkan kumpulan citra yang digunakan sebagai data pelatihan dan pengujian. CNN digunakan untuk mengekstraksi fitur visual dari citra motif kain, sedangkan RNN digunakan untuk mengenali pola berdasarkan urutan fitur. Evaluasi dilakukan menggunakan K-Fold Cross Validation dengan beberapa skenario pembagian data dan setiap model dilatih selama 50 epoch. Hasil penelitian menunjukkan bahwa CNN memberikan performa yang jauh lebih baik dibandingkan RNN dalam klasifikasi motif kain tenun. CNN memperoleh rata-rata akurasi sebesar 97,51%, sedangkan RNN menghasilkan akurasi yang jauh lebih rendah. Hal ini menunjukkan bahwa CNN lebih sesuai digunakan untuk klasifikasi citra statis seperti motif kain tenun, karena mampu menangkap karakteristik visual berupa pola, tekstur, dan bentuk motif. Sebaliknya, RNN kurang sesuai digunakan secara langsung untuk klasifikasi citra karena lebih optimal untuk data sekuensial seperti teks atau time series. Penelitian ini relevan karena sama-sama membahas klasifikasi motif kain tenun menggunakan pendekatan deep learning, khususnya CNN. Namun, penelitian tersebut belum menggunakan CNN sebagai feature extractor yang dikombinasikan dengan SVM sebagai classifier. Selain itu, penelitian tersebut belum menerapkan Content-Based Image Retrieval untuk menampilkan citra serupa setelah kelas motif berhasil diprediksi (Kembo & Kaesmetan, 2025).

7. **Metode yang digunakan:** K-Nearest Neighbor (K-NN) untuk klasifikasi dengan Gray Level Co-occurrence Matrix (GLCM) sebagai ekstraksi fitur. **Temuan Penelitian:** Penelitian ini mengembangkan sistem klasifikasi motif kain tenun Sumba Timur menggunakan metode K-Nearest Neighbor berbasis fitur tekstur Gray Level Co-occurrence Matrix. Dataset yang digunakan terdiri dari 60 citra kain tenun yang terbagi ke dalam dua kelas, yaitu kain Kawuru dan kain Kombu. Data tersebut dibagi menjadi data latih dan data uji, dengan masing-masing kelas memiliki 20 citra latih dan 10 citra uji. Proses klasifikasi diawali dengan konversi

citra ke bentuk grayscale karena GLCM bekerja pada citra satu channel. Setelah itu, dilakukan ekstraksi fitur tekstur menggunakan GLCM untuk memperoleh beberapa parameter utama, yaitu contrast, energy, dan homogeneity. Fitur-fitur tersebut kemudian digunakan sebagai dasar klasifikasi menggunakan algoritma K-NN. Pengujian dilakukan dengan beberapa nilai k, yaitu k=1, k=3, dan k=5. Hasil penelitian menunjukkan bahwa metode K-NN dengan fitur GLCM mampu menghasilkan akurasi klasifikasi sebesar 100% pada seluruh nilai k yang diuji. Hasil tersebut menunjukkan bahwa fitur tekstur dapat digunakan untuk membedakan motif kain tenun, terutama pada dataset dengan jumlah kelas yang terbatas. Penelitian ini relevan karena sama-sama berfokus pada klasifikasi motif kain tenun. Namun, penelitian tersebut masih menggunakan fitur manual berbasis GLCM dan belum memanfaatkan ekstraksi fitur mendalam berbasis CNN. Selain itu, penelitian tersebut masih terbatas pada dua kelas motif dengan jumlah dataset yang relatif kecil, belum menerapkan kombinasi CNN-SVM, dan belum membahas proses Content-Based Image Retrieval untuk menampilkan citra serupa setelah hasil klasifikasi diperoleh (Kaya & Umbu, 2022).

8. **Metode yang digunakan:** Content Based Image Retrieval (CBIR) dan Support Vector Machine (SVM). **Temuan Penelitian:** Penelitian ini mengembangkan sistem klasifikasi jenis daun jambu biji menggunakan kombinasi Content-Based Image Retrieval dan Support Vector Machine. Objek penelitian terdiri dari tiga jenis daun jambu biji, yaitu Jambu Kristal, Jambu Bangkok, dan Jambu Mutiara. CBIR digunakan untuk membandingkan kemiripan citra berdasarkan fitur visual, sedangkan SVM digunakan sebagai metode klasifikasi untuk menentukan jenis daun berdasarkan data latih. Proses pengenalan dilakukan dengan menghitung nilai histogram citra untuk memperoleh tingkat kemiripan antar gambar, kemudian hasil tersebut digunakan dalam proses klasifikasi menggunakan SVM. Pengujian dilakukan terhadap 30 data uji dan menghasilkan 27 data yang terklasifikasi dengan benar, sehingga diperoleh akurasi sebesar 90%. Hasil penelitian menunjukkan bahwa kombinasi CBIR dan SVM dapat digunakan untuk proses identifikasi citra berdasarkan karakteristik visual. Penelitian ini relevan karena menggunakan SVM sebagai classifier dan menerapkan konsep kemiripan citra melalui CBIR. Namun,

objek penelitian tersebut masih terbatas pada citra daun, bukan citra motif kain tradisional. Selain itu, fitur yang digunakan masih berbasis histogram dan belum memanfaatkan ekstraksi fitur mendalam menggunakan CNN. Penelitian tersebut juga belum menerapkan alur bertahap seperti pada penelitian ini, yaitu klasifikasi motif terlebih dahulu menggunakan CNN-SVM, kemudian proses retrieval citra serupa dilakukan terhadap seluruh galeri berdasarkan kemiripan fitur visual (Sriani et al., 2024).

9. **Metode yang digunakan:** Content-Based Image Retrieval (CBIR) dengan Color Histogram dan Euclidean Distance. **Temuan Penelitian:** Penelitian ini mengembangkan sistem Content-Based Image Retrieval untuk mencari gambar hewan serupa berdasarkan fitur warna. Objek penelitian yang digunakan adalah gambar hewan kelinci dan lumba-lumba. Sistem bekerja dengan mengekstraksi fitur warna menggunakan Color Histogram, kemudian membandingkan kemiripan antar citra menggunakan Euclidean Distance. Color Histogram digunakan untuk merepresentasikan distribusi warna pada citra, sedangkan Euclidean Distance digunakan untuk menghitung jarak antara fitur citra query dan citra pembanding. Semakin kecil nilai jarak yang diperoleh, semakin tinggi tingkat kemiripan antara dua citra. Hasil penelitian menunjukkan bahwa metode CBIR berbasis Color Histogram dan Euclidean Distance mampu menampilkan gambar hewan yang memiliki kemiripan visual berdasarkan warna. Penelitian ini relevan karena menggunakan konsep retrieval citra serupa dan pengukuran kemiripan menggunakan Euclidean Distance, yang juga digunakan dalam penelitian ini pada tahap CBIR. Namun, penelitian tersebut masih terbatas pada pencarian citra berdasarkan fitur warna, belum menggunakan fitur tekstur atau deep feature berbasis CNN. Selain itu, objek penelitian bukan citra motif kain tradisional, belum melibatkan proses klasifikasi, dan belum mengintegrasikan retrieval berbasis deep feature dengan tahap klasifikasi seperti pada penelitian motif Tenun Samarinda ini (Kurniawan et al., 2025).
10. **Metode yang digunakan:** Content-Based Image Retrieval (CBIR) berbasis Color Histogram, Euclidean Distance, dan Mean Square Error (MSE). **Temuan Penelitian:** Penelitian ini mengembangkan sistem Content-Based Image Retrieval

untuk mengidentifikasi ikan koi jenis Kohaku berdasarkan karakteristik warna tubuh. Fitur warna diekstraksi menggunakan Color Histogram pada ruang warna RGB, kemudian citra acuan dan citra uji dibandingkan untuk mengetahui tingkat kemiripannya. Pengukuran kemiripan dilakukan menggunakan Euclidean Distance, di mana nilai jarak yang lebih kecil menunjukkan tingkat kemiripan yang lebih tinggi. Selain itu, Mean Square Error digunakan sebagai metode pendukung untuk mengukur perbedaan piksel antara citra acuan dan citra uji. Dataset yang digunakan terdiri dari satu citra acuan dan beberapa citra uji dari berbagai jenis ikan koi, seperti Kohaku, Shiro Utsuri, Shusui, Showa Shansoku, dan Tancho. Hasil penelitian menunjukkan bahwa citra koi jenis Kohaku memiliki nilai Euclidean Distance dan MSE yang lebih kecil dibandingkan jenis koi lainnya, sehingga dikategorikan sebagai citra yang paling mirip dengan citra acuan. Penelitian ini relevan karena menerapkan konsep CBIR dan pengukuran kemiripan citra menggunakan Euclidean Distance, yang juga digunakan dalam penelitian ini pada tahap retrieval. Namun, penelitian tersebut masih berfokus pada fitur warna dan belum mempertimbangkan fitur tekstur maupun pola yang lebih kompleks. Selain itu, objek penelitian bukan citra motif kain tradisional, belum menggunakan deep feature berbasis CNN, dan belum diintegrasikan dengan tahap klasifikasi awal untuk membatasi ruang pencarian citra serupa berdasarkan kelas hasil klasifikasi seperti pada penelitian motif Tenun Samarinda ini, yang menggabungkan klasifikasi dan retrieval berbasis fitur visual pada seluruh galeri (Syarif & Andono, 2023).

Perbedaan dengan Penelitian Sebelumnya

Penelitian ini memiliki beberapa perbedaan mendasar dibandingkan penelitian-penelitian sebelumnya. Berdasarkan penelitian terdahulu, beberapa studi telah menerapkan CNN untuk klasifikasi citra kain tradisional, seperti klasifikasi tekstur sarung Samarinda, warna kain tenun, serta motif kain tenun dari berbagai daerah. Penelitian lain menggunakan metode ekstraksi fitur manual seperti SURF-BoVW, GLCM, *Color Histogram*, serta *classifier* seperti SVM, K-NN, dan *Decision Tree*. Selain itu, beberapa penelitian juga telah menerapkan *Content-Based Image Retrieval* (CBIR), tetapi

umumnya masih berbasis fitur warna dan belum dikombinasikan secara langsung dengan klasifikasi motif kain tradisional.

Berbeda dari penelitian terdahulu tersebut, penelitian ini berfokus secara khusus pada klasifikasi motif Tenun Samarinda, yaitu motif Hatta, Pucuk Rebung, dan Cumi. Metode yang digunakan adalah kombinasi CNN dan SVM, di mana CNN berperan sebagai *feature extractor* untuk mengekstraksi fitur visual citra, sedangkan SVM digunakan sebagai *classifier* untuk menentukan kelas motif. Pendekatan ini berbeda dari penelitian yang hanya menggunakan CNN sebagai *classifier* utama, fitur manual seperti GLCM dan SURF-BoVW, maupun CNN yang dikombinasikan dengan *classifier* selain SVM. Selain itu, penelitian ini tidak hanya menghasilkan label kelas motif, tetapi juga dilengkapi dengan tahap *Content-Based Image Retrieval* untuk menampilkan citra serupa. Proses CBIR dilakukan setelah citra *query* diklasifikasikan terlebih dahulu, kemudian fitur citra *query* dibandingkan dengan fitur seluruh citra pada galeri menggunakan jarak *Euclidean*. Lima citra dengan jarak terdekat ditampilkan sebagai hasil *retrieval*. Pendekatan ini berbeda dari penelitian CBIR sebelumnya yang umumnya melakukan pencarian berdasarkan fitur warna tanpa klasifikasi awal, sedangkan penelitian ini memanfaatkan fitur visual hasil ekstraksi CNN untuk melakukan pencarian citra serupa pada seluruh galeri.

Dengan demikian, kontribusi utama penelitian ini terletak pada penggabungan klasifikasi dan *retrieval* dalam satu alur kerja. Sistem yang dikembangkan tidak hanya mampu mengenali kelas motif Tenun Samarinda, tetapi juga memberikan referensi visual berupa citra-citra yang memiliki kemiripan dengan citra *query*. Proses *retrieval* yang dilakukan terhadap seluruh galeri memungkinkan sistem menemukan citra yang memiliki kemiripan visual berdasarkan representasi fitur, tanpa membatasi hasil berdasarkan kelas prediksi. Pendekatan ini mendukung proses dokumentasi digital dan pelestarian motif Tenun Samarinda.

2.2 Tenun Samarinda

Tenun Samarinda merupakan kain tradisional berbahan sutera yang menjadi identitas budaya masyarakat Samarinda, khususnya komunitas Bugis yang menetap di Samarinda Seberang. Kain ini diproduksi menggunakan alat tenun bukan mesin (ATBM) dan dikerjakan secara manual, sehingga menghasilkan kain dengan tekstur halus, rapat,

serta memiliki pola garis dan warna khas. Proses pembuatan Tenun Samarinda memerlukan ketelitian tinggi dan waktu pengerjaan yang relatif lama, bergantung pada tingkat kesulitan motif yang dibuat. Oleh karena itu, Tenun Samarinda tidak hanya memiliki nilai ekonomis, tetapi juga nilai budaya yang penting untuk dilestarikan. Dalam penelitian ini, motif yang dijadikan kelas klasifikasi adalah motif Hatta, Pucuk Rebung, dan Cumi/Bunga Dayak, karena motif-motif tersebut dikenal sebagai motif yang umum diproduksi dalam kajian pengrajin Tenun Samarinda (Paladan et al., 2024).

Dalam konteks pelestarian budaya dan penguatan ekonomi kreatif, pengembangan Tenun Samarinda juga diarahkan melalui digitalisasi. Salah satu bentuk digitalisasi yang telah dilaporkan adalah pemanfaatan aplikasi e-tenun berupa katalog daring berbasis web yang memuat informasi produk untuk memperluas jangkauan pemasaran dan meningkatkan literasi digital pengrajin (Rosmasari et al., 2026). Upaya digitalisasi tersebut menunjukkan bahwa Tenun Samarinda tidak hanya penting untuk dilestarikan secara tradisional, tetapi juga perlu didukung dengan teknologi informasi agar dokumentasi, promosi, dan pengenalannya dapat dilakukan secara lebih luas dan sistematis.

Sejalan dengan perkembangan penelitian modern, sarung Tenun Samarinda juga mulai dikaji menggunakan pendekatan pengolahan citra dan *deep learning*. Studi berbasis CNN telah diarahkan untuk membangun model klasifikasi pada citra sarung Samarinda, misalnya klasifikasi tekstur sarung berdasarkan perbedaan jenis alat tenun, sehingga mendukung upaya dokumentasi dan pengenalan kain tradisional secara lebih sistematis (Muhartini et al., 2024). Dalam penelitian ini, motif-motif Tenun Samarinda tersebut digunakan sebagai kelas pada tahap klasifikasi. Selanjutnya, fitur citra *query* digunakan dalam proses *Content-Based Image Retrieval* (CBIR) dengan membandingkannya terhadap fitur seluruh citra pada galeri untuk menampilkan citra-citra yang memiliki kemiripan visual berdasarkan jarak *Euclidean*.

2.3 Pengolahan Citra Digital

Pengolahan citra digital merupakan proses manipulasi dan analisis citra menggunakan komputer untuk memperoleh informasi yang lebih bermakna serta mempersiapkan citra agar dapat diproses lebih lanjut oleh sistem. Citra digital direpresentasikan sebagai matriks dua dimensi yang tersusun atas piksel dengan nilai

intensitas tertentu. Dalam konteks computer vision, pengolahan citra digital berperan penting sebagai tahap awal untuk meningkatkan kesesuaian data masukan sebelum dilakukan ekstraksi fitur atau klasifikasi (Fadjrie et al., 2020).

Pada penelitian ini, pengolahan citra digital difokuskan pada tahap preprocessing yang bertujuan untuk menyeragamkan citra motif Tenun Samarinda agar sesuai dengan kebutuhan model Convolutional Neural Network (CNN). Tahap preprocessing meliputi penyesuaian ukuran citra, normalisasi nilai piksel, dan penyesuaian format warna agar citra dapat diproses secara konsisten oleh model. Penyeragaman ukuran citra penting dilakukan karena model CNN membutuhkan dimensi input yang tetap, sedangkan normalisasi digunakan untuk mempercepat proses komputasi dan membantu kestabilan pelatihan model. Dengan demikian, pengolahan citra digital dalam penelitian ini tidak diarahkan pada segmentasi, thresholding, atau operasi morfologi, melainkan pada penyiapan data citra motif agar siap digunakan pada tahap ekstraksi fitur, klasifikasi, dan retrieval. Hasil dari tahap ini adalah citra yang telah memiliki format seragam sehingga dapat menghasilkan representasi fitur visual yang lebih konsisten pada proses berikutnya.

2.4 Ekstraksi Fitur Citra

Ekstraksi fitur merupakan proses mengubah citra menjadi representasi numerik yang dapat dipelajari oleh algoritma klasifikasi maupun digunakan dalam pencarian citra berdasarkan kemiripan visual. Pada citra tekstil tradisional, fitur yang penting umumnya berkaitan dengan pola, tekstur, warna, dan susunan elemen visual yang membedakan satu motif dengan motif lainnya. Oleh karena itu, kualitas fitur yang diekstraksi sangat menentukan kemampuan sistem dalam mengenali maupun menemukan citra yang serupa. Dalam pendekatan modern, *Convolutional Neural Network* (CNN) banyak digunakan sebagai *feature extractor* karena kemampuannya membangun representasi hierarkis yang stabil, mulai dari fitur sederhana seperti tepi dan tekstur pada lapisan awal hingga pola visual yang lebih kompleks dan abstrak pada lapisan yang lebih dalam. Fitur mendalam (*deep feature*) tersebut dapat diambil, baik dari lapisan konvolusi maupun dari *fully connected layer*. Fitur dari lapisan konvolusi cenderung merepresentasikan pola visual-spasial yang bersifat umum dan lebih mudah ditransfer ke domain lain, sedangkan fitur dari *fully connected layer* lebih terarah pada tugas klasifikasi asal jaringan sehingga bersifat lebih spesifik. Representasi tersebut selanjutnya dapat digunakan sebagai dasar

untuk proses klasifikasi maupun pencarian citra serupa. Penelitian terdahulu menunjukkan bahwa kombinasi CNN-SVM mampu mengungguli CNN dengan *softmax classifier* pada beberapa kasus, karena SVM memiliki kemampuan *margin optimization* yang kuat dalam memisahkan kelas pada ruang fitur berdimensi tinggi (Ahlawat & Choudhary, 2020).

Pada penelitian ini, fitur hasil ekstraksi CNN tidak hanya digunakan sebagai masukan bagi *Support Vector Machine* (SVM) pada tahap klasifikasi, tetapi juga digunakan sebagai representasi visual pada tahap *Content-Based Image Retrieval* (CBIR). Setelah citra input diekstraksi fiturnya menggunakan CNN, vektor fitur tersebut pertama-tama digunakan oleh SVM untuk menentukan kelas motif. Selanjutnya, vektor fitur yang sama digunakan kembali untuk mengukur kemiripan antara citra *query* dan seluruh citra pada galeri. Pengukuran kemiripan dilakukan menggunakan jarak *Euclidean*, kemudian lima citra dengan jarak terdekat dipilih sebagai hasil *retrieval*. Dengan demikian, ekstraksi fitur CNN berfungsi sebagai inti dari dua proses utama dalam sistem, yaitu klasifikasi dan *retrieval*. Penggunaan fitur mendalam (*deep feature*) berbasis CNN pada penelitian ini bertujuan menghasilkan representasi visual motif Tenun Samarinda yang lebih diskriminatif dibandingkan fitur manual. Representasi ini penting karena motif kain tradisional memiliki pola yang kompleks dan kemiripan antarmotif yang cukup tinggi. Dengan fitur yang lebih representatif, sistem diharapkan tidak hanya mampu membedakan kelas motif secara akurat, tetapi juga mampu menemukan dan menampilkan citra yang memiliki kemiripan visual dari seluruh galeri pada tahap *retrieval*.

2.5 Data Mining dan Klasifikasi

2.5.1 Pengertian Data Mining

Data mining adalah proses mencari pola atau informasi yang menarik dalam sekumpulan data menggunakan teknik atau metode tertentu. Data mining berkembang menjadi salah satu pendekatan penting dalam pengolahan data karena mampu membantu menemukan pola tersembunyi yang sulit dikenali secara manual. Secara umum, data mining menggabungkan konsep dari machine learning, statistik, pengenalan pola, dan basis data untuk menghasilkan pengetahuan yang dapat dimanfaatkan dalam pengambilan keputusan (Amalia et al., 2021). Dalam penelitian ini, konsep data mining digunakan dalam konteks pengenalan pola visual pada citra motif Tenun Samarinda. Data citra yang

telah diproses dan diekstraksi fiturnya dianalisis untuk membentuk model klasifikasi yang mampu memetakan citra ke dalam kelas motif tertentu. Dengan demikian, fokus penerapan data mining pada penelitian ini lebih diarahkan pada klasifikasi citra dan analisis pola visual, bukan pada analisis data bisnis atau transaksi.

2.5.2 Teknik-Teknik Klasifikasi

Klasifikasi merupakan salah satu teknik utama dalam data mining dan machine learning yang bertujuan mengelompokkan data ke dalam kelas tertentu berdasarkan atribut atau fitur yang dimiliki. Proses ini dilakukan dengan membangun model dari data latih, kemudian model tersebut digunakan untuk memprediksi kelas dari data baru. Menurut (Sidik et al., 2020), klasifikasi merupakan proses pembagian data ke dalam kelompok tertentu berdasarkan batasan yang telah ditetapkan dan menjadi teknik yang semakin populer dalam data mining karena mampu menangani berbagai bentuk data, termasuk citra. Terdapat berbagai teknik klasifikasi yang umum digunakan, diantaranya:

1. *Decision Tree*: metode berbasis aturan yang mudah dipahami.
2. *Naïve Bayes*: algoritma probablistik sederhana, efektif untuk data teks.
3. *K-Nearest Neighbor* (KNN): menentukan kelas berdasarkan tetangga terdekat.
4. *Support Vector Machine* (SVM): memaksimalkan margin antar kelas, cocok untuk data berdimensi tinggi.
5. *Random Forest*: ensemble dari banyak pohon keputusan, lebih stabil dan akurat.
6. *Convolutional Neural Network* (CNN): meniru cara kerja otak manusia, efektif untuk data kompleks seperti citra dan suara.

Dalam penelitian ini, metode klasifikasi yang digunakan adalah kombinasi CNN dan SVM. CNN dimanfaatkan untuk menghasilkan fitur citra yang representatif, sedangkan SVM digunakan untuk menentukan kelas motif berdasarkan fitur tersebut. Pemilihan SVM didasarkan pada kemampuannya dalam menangani fitur berdimensi tinggi dan membentuk pemisahan kelas yang optimal, sehingga sesuai untuk klasifikasi motif Tenun Samarinda.

2.5.3 Evaluasi Klasifikasi

Evaluasi klasifikasi merupakan tahap penting dalam machine learning untuk menilai kualitas model yang dibangun. Menurut (Rainio et al., 2024) evaluasi dilakukan dengan menggunakan metrik yang diperoleh dari *confussion matrix*, seperti *accuracy*, *precision*, *recall*, dan *f1-score*, yang masing-masing memberikan perspektif berbeda terhadap performa model. *Accuracy* menunjukkan persentase prediksi yang benar secara keseluruhan, *precision* mengukur proporsi prediksi positif yang benar, *recall* menilai kemampuan model dalam mendeteksi data positif, sedangkan *f1-score* merupakan harmonisasi antara *precision* dan *recall*, dan meskipun populer dalam *machine learning*, (Colliot & Varoquaux, n.d.) menekankan bahwa metrik ini memiliki kelemahan substansial. *F1-score* dapat menyesatkan jika prevalensi tinggi dan sepenuhnya mengabaikan jumlah true negative, sehingga penggunaannya harus hati-hati dan disesuaikan dengan konteks penelitian.

Confusion matrix merupakan tabel yang menggambarkan performa model klasifikasi dengan empat komponen: True Positive (TP) yaitu prediksi benar untuk kelas positif, True Negative (TN) yaitu prediksi benar untuk kelas negatif, False Positive (FP) yaitu kesalahan prediksi negatif sebagai positif, dan False Negative (FN) yaitu kesalahan prediksi positif sebagai negatif. Dari komponen confusion matrix tersebut, dapat dihitung berbagai metrik evaluasi sebagai berikut:

1. Accuracy

Accuracy mengukur proporsi prediksi yang benar dari keseluruhan data, baik positif maupun negatif. Metrik ini memberikan gambaran umum tentang seberapa baik model melakukan prediksi secara keseluruhan.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \dots\dots\dots(2.1)$$

2. Precision

Precision mengukur proporsi prediksi positif yang benar dari seluruh prediksi positif yang dilakukan model. Metrik ini menunjukkan seberapa dapat dipercaya hasil prediksi positif, sehingga penting ketika kesalahan dalam memberikan label positif yang tidak tepat perlu dihindari.

$$\text{Precision} = \frac{TP}{TP + FP} \dots\dots\dots(2.2)$$

3. Recall

Recall mengukur kemampuan model dalam mendeteksi seluruh data positif yang sebenarnya dari total data positif aktual. Metrik ini penting ketika kegagalan mendeteksi data positif dapat menimbulkan dampak yang merugikan.

$$\text{Recall} = \frac{TP}{TP + FN} \dots\dots\dots(2.3)$$

4. F1-Score

F1-score digunakan untuk menilai seberapa baik model menjaga keseimbangan antara prediksi yang tepat dan kemampuan mengenali seluruh data positif. Metrik ini sangat berguna ketika terdapat trade-off antara precision dan recall, dimana peningkatan salah satu metrik dapat menyebabkan penurunan metrik lainnya. Dengan menggabungkan precision dan recall dalam satu nilai, F1-score memberikan gambaran kinerja model yang lebih menyeluruh.

$$F1 - \text{Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \dots\dots\dots(2.4)$$

2.6 Machine Learning

2.6.1 Pengertian Machine Learning

Machine learning adalah cabang dari artificial intelligence yang memungkinkan sistem komputer untuk belajar dari data dan pengalaman tanpa perlu diprogram secara eksplisit untuk setiap tugas yang spesifik. Menurut (Janiesch et al., 2021), machine learning menggambarkan kapasitas sistem untuk belajar dari data pelatihan yang spesifik terhadap masalah guna mengotomatisasi proses pembangunan model analitik dan menyelesaikan tugas-tugas terkait. Proses pembelajaran dalam machine learning dimulai dengan observasi atau data seperti contoh-contoh, pengalaman langsung, atau instruksi untuk mencari pola dalam data tersebut dan kemudian membuat keputusan yang lebih baik di masa mendatang berdasarkan contoh yang telah diberikan. Berbeda dengan pendekatan pemrograman konvensional yang membutuhkan aturan dan logika yang didefinisikan secara manual oleh programmer, machine learning memungkinkan

algoritma untuk secara otomatis menemukan pola tersembunyi dari data training dan mengaplikasikan pengetahuan tersebut untuk membuat prediksi atau keputusan pada data baru yang belum pernah ditemui sebelumnya. Machine learning telah berkembang pesat dan banyak diaplikasikan dalam berbagai bidang seperti computer vision, natural language processing, sistem rekomendasi, deteksi anomali, bioinformatika, dan analisis prediktif, dengan tiga kategori pembelajaran utama yaitu *supervised learning* yang melatih model menggunakan data berlabel, *unsupervised learning* yang bekerja dengan data tanpa label untuk menemukan struktur atau pola tersembunyi, dan reinforcement learning yang belajar melalui trial and error dengan mekanisme reward dan punishment dari lingkungan.

2.6.2 Deep learning

Deep learning merupakan subset dari machine learning yang menggunakan artificial neural network dengan banyak layer tersembunyi untuk mempelajari representasi data secara hierarkis. Menurut (Alzubaidi et al., 2021), *deep learning* telah merevolusi berbagai bidang dengan kemampuannya mengekstrak fitur secara otomatis dari data mentah tanpa memerlukan feature engineering manual, sehingga sangat efektif untuk menangani data kompleks seperti gambar, suara, dan teks. Arsitektur *deep learning* terdiri dari multiple hidden layers yang memungkinkan model untuk belajar representasi data dari tingkat rendah hingga tingkat tinggi, dimana layer awal menangkap fitur sederhana seperti tepi dan warna, sedangkan layer yang lebih dalam menangkap fitur abstrak dan kompleks. Keunggulan *deep learning* terletak pada kemampuannya menangani big data dan meningkatkan performa seiring bertambahnya jumlah data training, meskipun memerlukan computational resources yang besar dan waktu training yang lama.

Model *deep learning* populer mencakup Convolutional Neural Network untuk computer vision, Recurrent Neural Network untuk sequential data, dan Transformer untuk natural language processing. Dalam konteks penelitian ini, deep learning digunakan melalui arsitektur Convolutional Neural Network (CNN) untuk memperoleh representasi visual motif Tenun Samarinda secara otomatis dari citra input. Representasi visual tersebut menjadi dasar penting dalam proses klasifikasi dan retrieval citra serupa.

2.6.3 Convolutional Neural Network

Convolutional Neural Network merupakan arsitektur *deep learning* yang dirancang khusus untuk memproses data dengan struktur grid seperti gambar, dengan memanfaatkan operasi konvolusi untuk mengekstrak fitur *spatial* secara otomatis. Menurut (Khan et al., 2020), kemampuan pembelajaran yang kuat dari *deep CNN* terutama disebabkan oleh penggunaan *multiple feature extraction stages* yang dapat secara otomatis mempelajari representasi dari data, sehingga CNN telah menunjukkan performa yang luar biasa dalam berbagai kompetisi terkait *Computer Vision* dan *Image Processing*. CNN terdiri dari beberapa *layer* utama yaitu *convolutional layer* yang menerapkan filter untuk mendeteksi fitur lokal, *pooling layer* yang mengurangi dimensi *spatial* sambil mempertahankan informasi penting, dan *fully connected layer* yang melakukan klasifikasi berdasarkan fitur yang diekstrak. Operasi konvolusi bekerja dengan menggeser filter kecil di seluruh gambar input untuk menghasilkan *feature maps* yang merepresentasikan keberadaan fitur tertentu pada berbagai posisi dalam gambar. *Pooling layer* seperti *max pooling* atau *average pooling* kemudian mengurangi ukuran *feature maps* untuk mengurangi *computational cost* dan memberikan invariansi terhadap translasi kecil. Arsitektur CNN memiliki beberapa keunggulan seperti *parameter sharing* yang mengurangi jumlah parameter model, *sparse connectivity* yang membuat *training* lebih efisien, dan kemampuan menangkap *hierarchical patterns* dari fitur sederhana hingga kompleks, sehingga CNN menjadi *state-of-the-art* dalam berbagai aplikasi *computer vision* seperti klasifikasi gambar, *object detection*, dan *image segmentation*.

Dalam penelitian ini, CNN digunakan sebagai *feature extractor*, bukan sebagai *classifier* akhir. CNN berfungsi untuk mengekstraksi fitur visual dari citra motif Tenun Samarinda sehingga dihasilkan representasi fitur yang mewakili pola, tekstur, dan karakteristik visual tiap motif. Representasi fitur tersebut kemudian digunakan sebagai input bagi *Support Vector Machine* (SVM) pada tahap klasifikasi. Selain itu, fitur yang dihasilkan CNN juga dimanfaatkan kembali pada tahap *Content-Based Image Retrieval* (CBIR) untuk menghitung kemiripan antara citra *query* dan seluruh citra pada galeri. Dengan demikian, CNN dalam penelitian ini berperan sebagai pembentuk representasi visual untuk dua proses utama sistem, yaitu klasifikasi dan *retrieval*.

2.6.4 Arsitektur VGG16

VGG16 merupakan salah satu arsitektur *Convolutional Neural Network* (CNN) yang umum digunakan untuk klasifikasi citra karena mampu mengekstraksi fitur visual secara bertahap melalui susunan *layer* konvolusi dan *pooling*. Menurut (Zulfikar et al., 2025), VGG16 menggunakan filter konvolusi berukuran 3×3 yang ditumpuk untuk membentuk jaringan yang lebih dalam, dan arsitekturnya memuat 13 *convolutional layer*, 3 *fully connected layer*, serta 5 *pooling layer* sebagai bagian utama ekstraksi fitur dan klasifikasi. Dalam konteks penerapan, (Zulfikar et al., 2025) juga merekomendasikan untuk membandingkan VGG16 dengan arsitektur CNN lain seperti MobileNet, ResNet, dan GoogleNet guna melihat perbedaan performa pada kebutuhan tertentu.

Dalam pengembangan sistem klasifikasi modern, VGG16 sering digunakan melalui *transfer learning*, yaitu memanfaatkan bobot model yang sudah dilatih sebelumnya (*pre-trained*) sehingga proses pelatihan pada dataset baru tidak dimulai dari nol. Menurut (Sunyoto et al., 2022), arsitektur VGG16 terbukti menghasilkan performa yang *robust* pada berbagai dataset dengan ukuran dan jumlah label kelas yang berbeda-beda, yang mengonfirmasi bahwa pendekatan *transfer learning* pada VGG16 efektif diterapkan meskipun karakteristik dataset target bervariasi. Lebih lanjut, (Addisu et al., 2025) menjelaskan bahwa VGG16 menerima input citra berukuran standar $224 \times 224 \times 3$, dan mekanisme *transfer learning* dengan membekukan lapisan teratas (*frozen top layer*) VGG16 merupakan solusi ideal terutama ketika ukuran dataset yang tersedia terbatas.

Pada penelitian ini, VGG16 digunakan sebagai model CNN *pre-trained* untuk mengekstraksi *deep feature* dari citra motif Tenun Samarinda. Penggunaan VGG16 sebagai *feature extractor* pada citra yang memiliki karakteristik pola dan tekstur juga telah diterapkan dalam penelitian sebelumnya, salah satunya untuk deteksi pola batik (Kusanti et al., 2026). Pemilihan VGG16 pada penelitian ini didasarkan pada kemampuannya menghasilkan representasi fitur visual yang kuat dan stabil, serta kesesuaiannya dengan ukuran input citra yang telah diseragamkan. Fitur hasil ekstraksi VGG16 digunakan pada dua proses utama dalam sistem. Pertama, fitur tersebut digunakan sebagai masukan bagi SVM untuk menentukan kelas motif pada tahap klasifikasi. Kedua, fitur yang sama dimanfaatkan kembali pada tahap CBIR untuk

menghitung kemiripan antara citra *query* dan seluruh citra pada galeri. Dengan demikian, penggunaan VGG16 pada penelitian ini mendukung proses klasifikasi sekaligus *retrieval* citra serupa berdasarkan representasi fitur visual.

2.6.5 Support Vector Machine

Support Vector Machine merupakan algoritma *supervised learning* yang *powerful* untuk klasifikasi dan regresi dengan mencari *hyperplane* optimal yang memaksimalkan *margin* antar kelas yang berbeda dalam *feature space*. Menurut (Rodríguez-pérez & Bajorath, 2022), SVM bekerja dengan memproyeksikan *training data* ke dalam *feature space* yang telah ditentukan untuk membentuk model prediksi kualitatif atau kuantitatif dengan mencari *hyperplane* yang paling baik memisahkan *instance training* positif dan negatif. Karakteristik unik dari SVM adalah kemampuannya beroperasi dalam *feature space* dengan dimensi tinggi untuk mencari *hyperplane* yang secara linier memisahkan data *training* positif dan negatif. Prinsip dasar SVM adalah menggunakan *kernel function* seperti *linear kernel*, *polynomial kernel*, atau *Radial Basis Function* (RBF) kernel untuk menentukan bentuk pemisah antar kelas. Parameter penting dalam SVM adalah parameter C yang mengontrol *trade-off* antara maksimalisasi *margin* dan minimalisasi kesalahan klasifikasi, serta parameter gamma pada RBF kernel yang menentukan seberapa jauh pengaruh suatu *training example*. SVM memiliki beberapa keunggulan seperti efektif pada *high-dimensional spaces*, *memory efficient* karena hanya menggunakan sebagian data *training* sebagai *support vectors*, dan *versatile* dengan berbagai *kernel functions*, meskipun memiliki kelemahan dalam hal *computational cost* yang tinggi untuk dataset yang besar dan sensitif terhadap pemilihan kernel serta parameter.

Dalam penelitian ini, SVM digunakan sebagai *classifier* untuk menentukan kelas motif Tenun Samarinda berdasarkan vektor fitur hasil ekstraksi CNN. Setelah citra input diproses oleh CNN dan diubah menjadi representasi fitur numerik, SVM bertugas membentuk batas keputusan antar kelas motif. Pemilihan konfigurasi parameter SVM dilakukan melalui *Grid Search* dengan *5-fold cross-validation*. Hasil prediksi SVM digunakan untuk menentukan kelas motif citra *query*, sedangkan fitur CNN yang sama digunakan secara terpisah pada tahap CBIR untuk melakukan pencarian citra serupa pada seluruh galeri.

2.6.6 CNN-SVM Hybrid Model

CNN-SVM Hybrid Model merupakan pendekatan yang mengombinasikan kemampuan CNN dalam *automatic feature extraction* dengan kemampuan klasifikasi SVM yang *robust*. Menurut (Unlarsen et al., 2022), dalam model *hybrid* ini *deep feature* diekstrak dari gambar menggunakan model CNN yang telah dilatih sebelumnya, kemudian fitur-fitur *deep* tersebut digunakan untuk melakukan klasifikasi menggunakan *classifier* SVM, di mana CNN berfungsi sebagai *feature extractor* sementara SVM bertindak sebagai *classifier* yang melakukan klasifikasi akhir. Pendekatan *hybrid* ini menggabungkan kemampuan CNN dalam membentuk representasi fitur visual dengan kemampuan SVM dalam menentukan batas keputusan antar kelas. Dalam arsitektur *hybrid*, CNN berfungsi mempelajari representasi hierarkis dari *raw pixel* hingga *high-level features*, sedangkan SVM dengan prinsip *margin maximization* digunakan untuk membentuk *decision boundary* pada ruang fitur. Implementasi CNN-SVM *hybrid* dapat dilakukan dengan berbagai cara, seperti menggunakan *pre-trained* CNN melalui *transfer learning* kemudian melatih SVM pada *extracted features* dengan berbagai *kernel functions*, atau melatih CNN dari awal dan mengganti *softmax layer* dengan SVM.

Dalam penelitian ini, kombinasi CNN-SVM digunakan pada tahap klasifikasi untuk menentukan kelas motif Tenun Samarinda. CNN bertugas mengekstraksi fitur visual dari citra motif, sedangkan SVM digunakan untuk memetakan fitur tersebut ke dalam kelas motif yang sesuai. Fitur hasil ekstraksi CNN juga dimanfaatkan kembali pada tahap *Content-Based Image Retrieval* (CBIR) untuk menghitung kemiripan antara citra *query* dan seluruh citra pada galeri. Dengan demikian, model *hybrid* CNN-SVM dalam penelitian ini mendukung proses klasifikasi, sementara representasi fitur CNN yang sama menjadi dasar dalam proses *retrieval* citra serupa menggunakan jarak *Euclidean*.

2.7 Content-Based Image Retrieval (CBIR)

Content-Based Image Retrieval (CBIR) merupakan teknik pencarian citra dalam basis data berdasarkan konten visual yang terkandung pada citra, seperti warna, tekstur, bentuk, maupun representasi fitur lainnya. Menurut (Tena et al., 2021), CBIR menjadi pendekatan yang relevan untuk citra kain atau tekstil karena objek tekstil memiliki karakteristik visual yang kompleks, sehingga pencarian berbasis konten visual lebih sesuai dibandingkan pencarian berbasis teks. (Zhang & Liu, 2023) juga menjelaskan

bahwa *image retrieval* menjadi salah satu arah penelitian penting dalam bidang *computer vision* karena meningkatnya jumlah data visual yang dihasilkan dan dibagikan secara digital. Secara umum, sistem CBIR terdiri atas beberapa komponen utama, yaitu *citra query*, ekstraksi fitur, pengukuran kemiripan, dan perankingan hasil *retrieval*. *Citra query* merupakan citra masukan yang digunakan sebagai acuan pencarian. Selanjutnya, sistem mengekstraksi fitur dari *citra query* dan membandingkannya dengan fitur citra-citra yang tersimpan dalam basis data atau galeri. Tingkat kemiripan antar citra kemudian dihitung menggunakan ukuran jarak atau *similarity measure* tertentu. Hasil pengukuran tersebut diurutkan berdasarkan nilai jarak atau tingkat kemiripan sehingga sistem dapat menampilkan citra-citra yang paling relevan atau paling mirip dengan *citra query*.

Pada penelitian terdahulu, pendekatan CBIR telah digunakan pada berbagai objek visual seperti tekstil tradisional, citra daun, gambar hewan, hingga ikan koi. Namun, sebagian besar penelitian tersebut berdiri sebagai sistem *retrieval* tersendiri atau menggunakan fitur visual sederhana seperti *color histogram* tanpa dikombinasikan dengan proses klasifikasi. Pada citra tekstil tradisional yang memiliki pola dan tekstur kompleks, *retrieval* citra dapat didukung oleh representasi fitur yang lebih kuat, seperti *deep feature* hasil ekstraksi CNN (Tena et al., 2021; Varshney et al., 2024). Dalam konteks penelitian ini, CBIR tidak digunakan untuk menentukan kelas motif, melainkan digunakan sebagai tahap lanjutan setelah proses klasifikasi selesai. Sistem terlebih dahulu mengklasifikasikan citra *query* menggunakan CNN sebagai *feature extractor* dan SVM sebagai *classifier*. Setelah proses klasifikasi selesai, fitur citra *query* digunakan untuk melakukan pencarian terhadap seluruh citra yang terdapat pada galeri. Dengan demikian, proses *retrieval* dilakukan berdasarkan kemiripan fitur visual tanpa membatasi ruang pencarian berdasarkan kelas hasil klasifikasi.

Fitur yang digunakan pada tahap CBIR dalam penelitian ini adalah *deep feature* hasil ekstraksi CNN. Pemanfaatan fitur mendalam ini dipilih karena CNN mampu menghasilkan representasi visual yang dapat menangkap pola, tekstur, dan karakteristik motif kain. Setelah fitur citra *query* diperoleh, fitur tersebut dibandingkan dengan fitur seluruh citra pada galeri menggunakan jarak Euclidean. Nilai jarak yang lebih kecil menunjukkan bahwa dua citra memiliki representasi fitur yang lebih dekat. Seluruh citra kemudian diurutkan berdasarkan nilai jarak tersebut, dan lima citra dengan jarak

Euclidean terdekat dipilih sebagai hasil *retrieval*. Output ini berfungsi sebagai referensi visual bagi pengguna, sehingga sistem tidak hanya memberikan label motif, tetapi juga menampilkan citra-citra yang memiliki kemiripan visual dengan citra *query*.

Penerapan CBIR pada penelitian ini berfungsi sebagai pelengkap tahap klasifikasi dengan menyediakan referensi visual berdasarkan kemiripan fitur citra. Berbeda dengan pendekatan *retrieval* yang membatasi pencarian berdasarkan kelas hasil klasifikasi, penelitian ini melakukan pencarian pada seluruh galeri sehingga citra yang memiliki kemiripan visual dapat ditemukan tanpa bergantung pada kelas prediksi. Dengan demikian, kombinasi klasifikasi dan CBIR memungkinkan sistem memberikan dua jenis informasi kepada pengguna, yaitu kelas motif hasil klasifikasi dan lima citra yang memiliki kemiripan visual tertinggi. Pendekatan tersebut diharapkan dapat mendukung proses identifikasi, dokumentasi, dan penyajian referensi visual motif Tenun Samarinda.

2.8 Pengukuran Kemiripan Citra

Pengukuran kemiripan citra merupakan tahap penting dalam sistem *Content-Based Image Retrieval* (CBIR) karena menentukan seberapa dekat hubungan visual antara citra *query* dan citra-citra dalam basis data. Setelah fitur visual diekstraksi, sistem memerlukan suatu metode untuk membandingkan vektor fitur tersebut sehingga dapat diketahui citra mana yang paling mirip dengan citra masukan. Dalam sistem *retrieval*, citra dengan nilai jarak terkecil atau nilai *similarity* tertinggi dianggap sebagai citra yang paling relevan dengan *query*. Salah satu metode yang umum digunakan untuk mengukur kemiripan citra adalah *Euclidean Distance*. Metode ini mengukur jarak lurus antara dua vektor fitur dalam ruang berdimensi n . Semakin kecil nilai *Euclidean Distance*, maka semakin tinggi tingkat kemiripan antara dua citra. Dalam berbagai penelitian CBIR, *Euclidean Distance* sering digunakan karena sederhana, mudah diimplementasikan, dan efektif untuk membandingkan fitur numerik hasil ekstraksi citra (Kurniawan et al., 2025; Syarif & Andono, 2023). *Euclidean Distance* digunakan untuk mengukur jarak antara dua vektor fitur dalam ruang berdimensi n . Semakin kecil nilai jarak yang dihasilkan, semakin tinggi tingkat kemiripan antara dua citra. Secara matematis, *Euclidean Distance* dirumuskan sebagai berikut:

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2} \dots\dots\dots(2.5)$$

Keterangan:

$d(x, y)$ = jarak antara dua vektor fitur

x_i = nilai fitur ke-i dari citra query

y_i = nilai fitur ke-i dari citra pembanding

n = jumlah dimensi fitur

Pada penelitian ini, pengukuran kemiripan dilakukan terhadap fitur hasil ekstraksi CNN. Setelah fitur citra *query* diperoleh, sistem menghitung jarak antara vektor fitur citra *query* dan vektor fitur seluruh citra pada galeri. Hasil perhitungan jarak kemudian diurutkan dari nilai terkecil hingga terbesar untuk memperoleh lima citra dengan jarak Euclidean terdekat sebagai hasil *retrieval*. Dengan demikian, pemilihan citra hasil *retrieval* didasarkan pada kedekatan representasi fitur visual, tanpa membatasi pencarian berdasarkan kelas hasil klasifikasi.

2.9 Evaluasi Retrieval

Evaluasi retrieval merupakan tahap untuk menilai seberapa relevan hasil pencarian citra yang ditampilkan oleh sistem Content-Based Image Retrieval (CBIR). Berbeda dengan evaluasi klasifikasi yang menggunakan *confusion matrix*, *accuracy*, *precision*, *recall*, dan *f1-score*, evaluasi retrieval berfokus pada kualitas hasil ranking citra terhadap suatu *query image*. Dalam literatur *image retrieval*, metrik evaluasi yang umum digunakan meliputi *Average Precision* (AP), *Recall@k*, dan *Precision@k*, yang digunakan untuk menilai seberapa baik sistem menempatkan item yang relevan pada posisi teratas hasil retrieval (Patel et al., 2022; Ramzi et al., 2022).

Pada penelitian ini, sistem menampilkan lima citra teratas (Top-5) yang paling mirip dengan citra query berdasarkan kemiripan fitur. Pencarian dilakukan terhadap seluruh galeri citra dan tidak dibatasi pada kelas hasil klasifikasi. Oleh karena itu, metrik evaluasi retrieval yang digunakan adalah *Precision@5*, yaitu proporsi citra relevan di antara lima hasil teratas. Semakin tinggi *Precision@5*, semakin baik kualitas retrieval karena semakin banyak citra relevan yang muncul pada posisi teratas. Secara matematis, *Precision@5* dirumuskan pada persamaan 2.6:

$$Precision@5 = \frac{\text{Jumlah citra relevan pada Top-5}}{5} \dots\dots\dots(2.6)$$


Pada penelitian ini, suatu citra dianggap relevan apabila citra tersebut termasuk dalam motif yang sama dengan citra query dan muncul pada lima hasil retrieval teratas. Karena pencarian dilakukan terhadap seluruh galeri tanpa pembatasan kelas, *Precision@5* digunakan untuk mengukur seberapa baik sistem menempatkan citra bermotif pada posisi teratas di antara seluruh citra berdasarkan tingkat kemiripan visual. Selain dinilai secara kuantitatif menggunakan *Precision@5*, hasil retrieval juga dapat diamati secara deskriptif melalui kualitas visual ranking yang dihasilkan. Pada citra tekstil tradisional, relevansi tidak hanya dipengaruhi oleh warna, tetapi juga oleh pola, tekstur, dan susunan motif. Hal ini sejalan dengan penelitian (Choe et al., 2024) yang mengevaluasi retrieval accuracy dan visual similarity pada sistem CBIR, sehingga menunjukkan bahwa kualitas hasil retrieval juga dapat ditinjau dari kemiripan visual yang dihasilkan, tidak hanya dari ranking numeriknya. Selain itu, dalam studi evaluasi CBIR pada penggunaan nyata, penilaian sistem tidak hanya dilihat dari hasil retrieval, tetapi juga dapat dikaitkan dengan manfaatnya terhadap pengguna, seperti peningkatan kepercayaan dalam pengambilan keputusan dan efisiensi waktu. (Böttcher et al., 2025) menunjukkan bahwa evaluasi CBIR dapat dilihat dari akurasi hasil, confidence pengguna, serta waktu interpretasi.

BAB III

METODOLOGI PENELITIAN

3.1 Tahapan Pelaksanaan Penelitian

Penelitian ini dilaksanakan melalui tahapan-tahapan yang disusun secara sistematis, dimulai dari identifikasi permasalahan hingga proses evaluasi performa sistem. Secara umum, sistem yang dibangun pada penelitian ini terdiri dari dua tahap utama, yaitu klasifikasi motif Tenun Samarinda dan retrieval citra serupa menggunakan *Content-Based Image Retrieval* (CBIR). Pada tahap klasifikasi, citra motif diproses menggunakan *Convolutional Neural Network* (CNN) untuk mengekstraksi fitur visual, kemudian fitur tersebut diklasifikasikan menggunakan *Support Vector Machine* (SVM) untuk menentukan kelas motif. Adapun retrieval citra serupa dilakukan dengan membandingkan fitur citra *query* terhadap fitur seluruh citra pada galeri untuk menampilkan citra-citra yang paling mirip secara visual. Rangkaian tahapan pelaksanaan penelitian ini disajikan pada Gambar 3.1.



Gambar 3.1 Diagram Tahapan Pelaksanaan

Penjelasan mengenai tahapan-tahapan pada penelitian ini adalah sebagai berikut:

1. Identifikasi Masalah

Tahap ini dilakukan dengan mengamati permasalahan pada proses pengenalan motif Tenun Samarinda yang masih banyak dilakukan secara manual. Hasil identifikasi menunjukkan bahwa diperlukan sistem berbasis pengolahan citra untuk membantu mengenali motif secara otomatis serta menampilkan citra serupa sebagai referensi visual.

2. Studi Literatur

Tahap studi literatur dilakukan dengan mengumpulkan dan mempelajari referensi yang berkaitan dengan metode yang digunakan dalam penelitian. Literatur yang dikaji meliputi *Convolutional Neural Network (CNN)*, *transfer learning* menggunakan VGG16, *Support Vector Machine (SVM)*, dan *Content-Based Image Retrieval (CBIR)* sebagai dasar dalam perancangan sistem.

3. Pengumpulan Data

Data yang digunakan berupa citra motif Tenun Samarinda yang diperoleh melalui pemotretan langsung pada kain sarung tenun. Motif yang digunakan dalam penelitian ini terdiri dari tiga kelas, yaitu Hatta, Pucuk Rebung, dan Cumi. Pengambilan citra dilakukan dengan memperhatikan variasi sudut pengambilan, jarak, dan kondisi pencahayaan agar data yang diperoleh memiliki variasi visual.

4. Pelabelan Data

Setiap citra diberikan label berdasarkan kelas motifnya, yaitu Hatta, Pucuk Rebung, dan Cumi. Proses pelabelan dilakukan secara otomatis berdasarkan folder penyimpanan masing-masing citra sehingga setiap data memiliki kelas yang sesuai untuk digunakan pada proses selanjutnya.

5. Preprocessing Data

Citra yang telah dikumpulkan diproses terlebih dahulu sebelum digunakan pada tahap ekstraksi fitur. Proses *preprocessing* meliputi penyesuaian ukuran citra menjadi 224×224 piksel, penyeragaman format citra menjadi RGB, serta normalisasi nilai piksel dengan membagi nilai piksel menggunakan 255. Proses tersebut dilakukan agar citra sesuai dengan kebutuhan input model VGG16.

6. Ekstraksi Fitur Menggunakan CNN

Citra hasil *preprocessing* dimasukkan ke dalam model VGG16 *pre-trained* dalam kondisi beku (*frozen*) untuk memperoleh representasi fitur visual. Fitur yang dihasilkan merepresentasikan karakteristik citra, seperti pola, tekstur, bentuk, dan warna. Pada tahap ini, setiap citra direpresentasikan dalam bentuk vektor fitur berdimensi 512 yang selanjutnya digunakan sebagai masukan untuk proses klasifikasi dan *retrieval*.

7. Data Splitting

Dataset dibagi menjadi data latih dan data uji dengan proporsi 60:40, yaitu sebanyak 180 citra untuk data latih dan 120 citra untuk data uji. Pembagian dilakukan secara *stratified* per citra dengan mempertahankan proporsi kelas pada masing-masing subset. Data latih digunakan untuk proses pelatihan model, sedangkan data uji digunakan untuk mengukur kemampuan model terhadap citra yang tidak digunakan dalam proses pelatihan.

8. Training Model Menggunakan SVM

Fitur hasil ekstraksi CNN dari data latih digunakan sebagai masukan untuk melatih model SVM. Pemilihan parameter model dilakukan menggunakan *Grid Search Cross-Validation* untuk memperoleh kombinasi *hyperparameter* yang sesuai. Seluruh proses yang mempelajari parameter model dilakukan hanya menggunakan data latih untuk menghindari penggunaan informasi dari data uji.

9. Klasifikasi Citra

Citra *query* diproses melalui tahap *preprocessing* dan ekstraksi fitur menggunakan VGG16 dengan konfigurasi yang sama seperti pada data latih. Fitur yang diperoleh kemudian dimasukkan ke dalam model SVM yang telah dilatih untuk memprediksi kelas motif. Selain label kelas, sistem juga menghasilkan *confidence score* sebagai informasi tingkat keyakinan terhadap hasil klasifikasi.

10. Retrieval Citra Serupa Menggunakan CBIR

Fitur citra *query* dibandingkan dengan fitur seluruh citra pada galeri menggunakan pengukuran *Euclidean Distance*. Proses *retrieval* dilakukan terhadap seluruh galeri tanpa membatasi citra berdasarkan hasil klasifikasi, sehingga citra dari seluruh kelas tetap dapat dipertimbangkan berdasarkan tingkat kemiripannya. Lima citra dengan jarak terdekat atau tingkat kemiripan tertinggi kemudian ditampilkan sebagai hasil *retrieval*.

11. Evaluasi Model

Evaluasi dilakukan terhadap kinerja klasifikasi dan *retrieval*. Evaluasi klasifikasi menggunakan *confusion matrix*, *accuracy*, *precision*, *recall*, dan *F1-score* untuk mengetahui kemampuan model dalam mengenali setiap kelas motif. Sementara

itu, evaluasi *retrieval* menggunakan *Precision@5* untuk mengukur tingkat relevansi lima citra teratas yang ditampilkan oleh sistem.

3.2 Pengumpulan Data

Pengumpulan data pada penelitian ini dilakukan untuk memperoleh dataset citra motif Tenun Samarinda yang akan digunakan dalam proses pengolahan, klasifikasi, dan retrieval citra serupa. Data yang digunakan berupa citra kain sarung Tenun Samarinda yang diambil secara langsung melalui proses pemotretan. Pengambilan citra dilakukan di lingkungan pengrajin atau lokasi penyimpanan kain tenun dengan menggunakan kamera ponsel pintar. Proses pengambilan data dilakukan dengan memperhatikan variasi sudut pandang, jarak pengambilan, dan kondisi pencahayaan guna memperoleh citra yang representatif serta mencerminkan kondisi nyata di lapangan.

Dataset yang dikumpulkan terdiri dari tiga kelas motif Tenun Samarinda, yaitu Hatta, Pucuk Rebung, dan Cumi. Setiap kelas motif direpresentasikan oleh sejumlah citra dengan variasi tampilan visual kain. Variasi tersebut mencakup perbedaan posisi pengambilan gambar, pencahayaan, dan tampilan pola motif pada kain. Data citra yang telah dikumpulkan selanjutnya disimpan dalam format digital dan dikelompokkan berdasarkan kelas motif. Pengelompokan dilakukan dengan menempatkan citra ke dalam folder sesuai nama motif, yaitu folder Hatta, Pucuk Rebung, dan Cumi. Struktur penyimpanan ini digunakan untuk memudahkan proses pelabelan, preprocessing, ekstraksi fitur, klasifikasi, dan retrieval pada tahap berikutnya.


3.3 Perancangan Data

Perancangan data pada penelitian ini dilakukan untuk mengatur dataset citra motif Tenun Samarinda agar siap digunakan dalam proses preprocessing, ekstraksi fitur, klasifikasi, dan retrieval citra serupa. Perancangan data mencakup struktur penyimpanan dataset, spesifikasi citra yang digunakan, distribusi jumlah data, pembagian data latih dan data uji, serta pelabelan data berdasarkan kelas motif. Dataset pada penelitian ini terdiri dari tiga kelas motif Tenun Samarinda, yaitu Hatta, Pucuk Rebung, dan Cumi.

3.3.1 Struktur Dataset

Dataset citra motif tenun Samarinda disusun dalam struktur direktori yang terorganisir berdasarkan kelas motif. Struktur penyimpanan data dirancang sedemikian

rupa agar memudahkan proses pembacaan dan pelabelan data secara otomatis oleh sistem. Struktur direktori dataset ditunjukkan pada Gambar 3.2.



Gambar 3.2 Struktur Direktori

Setiap folder mewakili satu kelas motif tenun Samarinda, dan setiap file citra di dalam folder tersebut merupakan sampel citra dari motif yang bersangkutan. Nama folder menggunakan penamaan yang deskriptif sesuai dengan nama motif untuk memudahkan identifikasi.

3.3.2 Spesifikasi Data Citra

Data citra yang digunakan dalam penelitian ini memiliki spesifikasi sebagai berikut:

1. Format File: JPEG (Joint Photographic Experts Group)
2. Resolusi awal: Bervariasi, sesuai dengan hasil pemotretan di lapangan
3. Resolusi setelah preprocessing: 224×224 piksel
4. Color space: RGB (Red, Green, Blue)
5. Jumlah channel: 3 (Red, Green, Blue)
6. Kedalaman bit: 8-bit per channel

Penyeragaman resolusi citra 224×224 piksel dilakukan pada tahap preprocessing untuk menyesuaikan dengan arsitektur CNN yang umum digunakan dalam ekstraksi fitur, serta untuk memastikan konsistensi input data.

3.3.3 Distribusi Data

Dataset citra motif tenun Samarinda terdiri dari 300 citra yang terbagi ke dalam tiga kelas motif. Distribusi jumlah citra pada setiap kelas ditunjukkan pada Tabel 3.1

Tabel 3.1 Distribusi Data

Kelas	Jumlah Data (Citra)	Persentase (%)
Hatta	100	33,3
Pucuk Rebung	100	33,3
Cumi	100	33,3



Gambar 3.3 Citra Tiap Kelas: (a) Hatta, (b) Pucuk Rebung, (c) Cumi

3.3.4 Pelabelan Data

Setiap citra dalam dataset diberi label sesuai dengan kelas motifnya. Pelabelan dilakukan secara otomatis berdasarkan nama folder tempat citra tersebut disimpan. Sistem pelabelan dirancang dengan menggunakan encoding label numerik sebagai berikut:

1. Motif Hatta → Label: 0
2. Motif Pucuk Rebung → Label: 1
3. Motif Cumi → Label: 2

Label numerik ini digunakan dalam proses ekstraksi fitur menggunakan CNN dan pelatihan model SVM. Untuk keperluan interpretasi hasil dan visualisasi confusion matrix, label numerik dapat dikonversi kembali ke nama motif aslinya menggunakan mapping yang telah ditentukan.

3.3.5 Data Splitting

Pembagian data dilakukan untuk memisahkan dataset menjadi data latih (*training data*) dan data uji (*testing data*). Pada penelitian ini, pembagian data dilakukan menggunakan metode split tetap dengan rasio 60:40 secara stratified berdasarkan kelas. Dari total 300 citra yang terdiri atas 100 citra pada setiap kelas motif, diperoleh sebanyak 180 citra sebagai data latih dan 120 citra sebagai data uji. Setiap kelas terdiri atas 60 citra data latih dan 40 citra data uji. Pembagian dilakukan menggunakan fungsi *train_test_split* dengan parameter *test_size=0.4*, *stratify=label*, dan nilai *random_state* yang tetap agar proses pembagian data dapat direproduksi. Penggunaan *stratified split* bertujuan untuk memastikan distribusi setiap kelas tetap proporsional pada data latih maupun data uji. Rincian pembagian data ditampilkan pada Tabel 3.2.

Tabel 3.2 Splitting data

Motif	Jumlah Data	Data Latih	Data Uji
Hatta	100	60	40
Pucuk Rebung	100	60	40
Cumi	100	60	40
Total	300	180	120

VGG16 yang digunakan dalam penelitian ini merupakan model pre-trained dengan bobot hasil pelatihan pada dataset ImageNet dan berperan sebagai feature extractor tanpa dilakukan proses fine-tuning. Oleh karena itu, arsitektur CNN tidak dilatih ulang menggunakan dataset motif Tenun Samarinda. Data latih diproses menggunakan VGG16 untuk menghasilkan vektor fitur, kemudian vektor fitur tersebut digunakan sebagai masukan untuk melatih model Support Vector Machine (SVM). Selanjutnya, data uji juga diproses menggunakan VGG16 yang sama untuk menghasilkan representasi fitur. Vektor fitur dari data uji kemudian digunakan untuk mengevaluasi kemampuan model SVM dalam mengklasifikasikan citra yang tidak digunakan pada proses pelatihan model.


Dengan demikian, pemisahan data dilakukan untuk memastikan evaluasi dilakukan menggunakan data yang tidak digunakan dalam proses pelatihan SVM.

3.4 Perancangan Proses/Algoritma

Perancangan proses atau algoritma pada penelitian ini dilakukan untuk menjelaskan alur kerja sistem klasifikasi dan retrieval motif Tenun Samarinda. Proses yang dirancang mencakup tahapan preprocessing citra, ekstraksi fitur menggunakan CNN, pelatihan model SVM, klasifikasi citra query, retrieval citra serupa menggunakan CBIR, serta evaluasi sistem. Setiap tahapan dirancang agar saling terhubung, sehingga sistem dapat menerima citra masukan, menentukan kelas motif, dan menampilkan citra-citra yang memiliki kemiripan visual dengan citra tersebut.

3.4.1 Perancangan Sistem Klasifikasi dan Retrieval

Perancangan sistem pada penelitian ini digambarkan menggunakan use case diagram untuk menunjukkan interaksi antara pengguna dan sistem. Use case diagram digunakan untuk memberikan gambaran umum mengenai fungsi-fungsi utama yang tersedia pada sistem. Diagram use case ditunjukkan pada Gambar 3.3.




Gambar 3.4 Use Case Diagram Sistem Klasifikasi Motif Tenun Samarinda

Pada sistem ini, aktor utama adalah user yang berinteraksi langsung dengan aplikasi. Interaksi awal yang dilakukan user adalah mengunggah citra motif tenun ke dalam sistem melalui fitur upload citra. Citra yang telah diunggah kemudian diproses oleh sistem pada tahap klasifikasi citra untuk menentukan kelas motif Tenun Samarinda yang sesuai. Setelah proses klasifikasi selesai, sistem menampilkan hasil klasifikasi kepada user dalam bentuk label motif yang diprediksi. Selanjutnya, sistem melakukan retrieval citra untuk menampilkan citra-citra yang memiliki kemiripan visual dengan citra input. Proses retrieval dilakukan setelah klasifikasi dan hasilnya ditampilkan kepada user dalam bentuk hasil retrieval citra. Dengan demikian, sistem tidak hanya memberikan keluaran berupa label kelas motif, tetapi juga memberikan referensi visual berupa citra-citra yang mirip. Berdasarkan use case diagram, relasi *include* digunakan untuk menunjukkan bahwa proses klasifikasi citra mencakup upload citra motif tenun dan lihat hasil klasifikasi, sedangkan proses retrieval citra mencakup lihat hasil retrieval. Selain itu,

relasi *extend* digunakan pada use case lihat *confidence score* terhadap lihat hasil klasifikasi, karena informasi *confidence score* merupakan fitur tambahan yang dapat ditampilkan sebagai pelengkap hasil klasifikasi. Melalui rancangan ini, use case diagram menggambarkan bahwa sistem yang dibangun pada penelitian ini mengintegrasikan dua fungsi utama, yaitu klasifikasi motif dan retrieval citra serupa, dalam satu aplikasi berbasis Streamlit yang dapat digunakan secara interaktif oleh pengguna.

3.4.2 Perancangan Alur Proses Sistem

Perancangan alur proses sistem bertujuan untuk menjelaskan tahapan kerja sistem dalam mengolah citra motif Tenun Samarinda mulai dari citra masukan hingga menghasilkan keluaran berupa hasil klasifikasi dan hasil retrieval citra serupa. Alur proses ini menggambarkan integrasi antara dua tahap utama dalam sistem, yaitu tahap klasifikasi motif menggunakan CNN dan SVM, serta tahap retrieval citra menggunakan pendekatan Content-Based Image Retrieval (CBIR). Flowchart alur proses sistem ditunjukkan pada Gambar 3.5.



Gambar 3.5 Flowchart Alur Proses Sistem

Berdasarkan flowchart pada Gambar 3.5, sistem bekerja dengan alur sebagai berikut:

1. User memasukkan citra motif tenun Samarinda ke dalam sistem melalui fitur unggah citra.

2. Sistem melakukan preprocessing citra yang meliputi penyesuaian ukuran dan normalisasi piksel.
3. Citra hasil preprocessing diekstrak fiturnya menggunakan CNN pre-trained VGG16 untuk memperoleh representasi fitur visual.
4. Fitur hasil ekstraksi diproses menggunakan model SVM yang telah dilatih sebelumnya untuk melakukan klasifikasi motif.
5. Sistem menentukan kelas motif dari citra input berdasarkan hasil prediksi model SVM.
6. Fitur citra query digunakan untuk proses retrieval dengan membandingkannya terhadap fitur seluruh citra yang terdapat pada galeri.
7. Sistem menghitung jarak antara fitur citra query dan fitur citra pada galeri menggunakan Euclidean Distance.
8. Hasil perhitungan kemiripan kemudian diurutkan berdasarkan nilai jarak terkecil hingga terbesar untuk memperoleh citra-citra yang paling mirip.
9. Sistem menampilkan hasil klasifikasi berupa label motif dan confidence score, serta menampilkan Top-5 citra paling mirip sebagai hasil retrieval.

3.4.3 Perancangan Preprocessing

Tahap preprocessing bertujuan untuk mempersiapkan data citra agar sesuai dengan kebutuhan model CNN yang digunakan. Preprocessing dilakukan pada seluruh citra sebelum proses ekstraksi fitur.

Tahapan preprocessing yang diterapkan meliputi:

1. Resize citra ke ukuran 224×224 piksel untuk menyeragamkan dimensi input CNN.
2. Normalisasi nilai piksel dari rentang $[0, 255]$ menjadi $[0, 1]$ dengan membagi nilai piksel dengan 255.
3. Format warna RGB dengan tiga channel warna dipertahankan untuk menjaga informasi warna pada motif tenun.

Proses tersebut dilakukan berulang hingga seluruh citra pada dataset selesai diproses. Penyeragaman ukuran citra diperlukan karena arsitektur CNN membutuhkan dimensi input yang tetap, sedangkan normalisasi dilakukan untuk menyesuaikan rentang nilai piksel agar sesuai dengan kebutuhan proses ekstraksi fitur. Setelah seluruh proses

preprocessing selesai, setiap citra kemudian diberi label sesuai kelas motif berdasarkan struktur folder dataset. Dataset yang telah berlabel selanjutnya dibagi menjadi data latih dan data uji menggunakan metode *Stratified Split*, yaitu pembagian data dengan mempertahankan proporsi setiap kelas pada masing-masing subset. Dari total 300 citra, diperoleh 180 citra sebagai data latih dan 120 citra sebagai data uji. Pembagian ini dilakukan agar setiap kelas motif tetap terwakili pada data latih dan data uji. Hasil dari tahapan ini berupa dataset yang telah melalui proses *preprocessing*, memiliki label sesuai kelas motif, serta terbagi menjadi data latih dan data uji yang siap digunakan pada proses ekstraksi fitur CNN, pelatihan model SVM, dan evaluasi *Content-Based Image Retrieval* (CBIR).

3.4.4 Perancangan Ekstraksi Fitur Menggunakan CNN

Ekstraksi fitur merupakan tahap penting dalam sistem klasifikasi dan retrieval citra untuk memperoleh representasi visual citra motif tenun dalam bentuk vektor numerik. Pada penelitian ini digunakan arsitektur CNN *pre-trained* VGG16 yang telah dilatih pada dataset *ImageNet*. Model VGG16 dimanfaatkan sebagai *feature extractor* dengan menghilangkan layer klasifikasi akhir (*fully connected* dan *softmax*), sehingga model hanya berfungsi mengekstraksi fitur visual tanpa melakukan klasifikasi secara langsung. Output fitur diambil dari layer *Block4_pool*, kemudian diproses menggunakan *Global Average Pooling (GAP)* sehingga setiap citra direpresentasikan menjadi vektor fitur berdimensi 512. Pemilihan layer *Block4_pool* didasarkan pada studi ablasi (*ablation study*) yang membandingkan beberapa kedalaman layer VGG16 (Block4, dan Block5), beberapa strategi pooling (*Global Average Pooling/GAP*, *Global Max Pooling/GMP*, serta gabungan keduanya), dan layer *fully connected* (FC1, dan FC2).

Seluruh konfigurasi menghasilkan akurasi klasifikasi yang tinggi, sehingga pemilihan konfigurasi fitur tidak hanya didasarkan pada akurasi klasifikasi, tetapi juga mempertimbangkan performa *retrieval* yang diukur menggunakan *Mean Precision@5*. Hasil perbandingan antar konfigurasi secara lengkap disajikan pada BAB IV.

Penggunaan fitur konvolusional dari *Block4_pool* dengan *Global Average Pooling (GAP)*, dibandingkan dengan fitur dari *fully connected layer*, juga sejalan dengan tujuan penelitian yang membagi fungsi CNN dan SVM secara komplementer. Dalam penelitian ini, VGG16 berperan sebagai *feature extractor* yang mengubah citra menjadi

representasi numerik, sedangkan SVM berperan sebagai pengklasifikasi yang membentuk batas keputusan untuk membedakan setiap kelas motif berdasarkan representasi fitur tersebut. Pengambilan fitur baik dari lapisan konvolusional maupun dari lapisan fully connected pada VGG16 sama-sama memungkinkan untuk digunakan sebagai masukan bagi SVM. Namun, fitur Block4_pool dengan GAP dipilih pada penelitian ini berdasarkan hasil pengujian dan karakteristik representasi fitur yang dihasilkan.

Fitur dari *fully connected layer* VGG16 merupakan representasi tingkat tinggi yang dibentuk sebagai bagian dari arsitektur klasifikasi VGG16 yang sebelumnya dilatih pada 1000 kelas ImageNet. Sementara itu, penggunaan fitur konvolusional tingkat menengah (*mid-level*) memungkinkan VGG16 tetap berfungsi sebagai ekstraktor representasi visual yang menangkap karakteristik seperti pola dan tekstur, sedangkan proses pemisahan kelas motif secara khusus dilakukan oleh SVM. Dengan pembagian tersebut, CNN dan SVM memiliki fungsi yang berbeda namun saling melengkapi dalam proses klasifikasi.

Selain itu, penerapan GAP pada output *Block4_pool* menghasilkan vektor fitur berdimensi 512, sedangkan fitur dari FC1 dan FC2 memiliki dimensi sebesar 4096. Representasi dengan dimensi yang lebih ringkas memberikan keuntungan dari sisi efisiensi penyimpanan dan komputasi, terutama karena vektor fitur yang sama juga digunakan dalam proses *Content-Based Image Retrieval* (CBIR) untuk menghitung jarak Euclidean antar citra. Dimensi fitur yang lebih rendah juga membantu mengurangi kompleksitas representasi ketika digunakan pada dataset dengan jumlah data yang relatif terbatas.

Pemilihan konfigurasi *Block4_pool + GAP* juga didukung oleh hasil studi ablasi yang dilakukan pada penelitian ini. Berdasarkan hasil evaluasi *retrieval* pada Tabel 4.7, konfigurasi *Block4_pool + GAP* menghasilkan nilai *Mean Precision@5* sebesar 96,33%, lebih tinggi dibandingkan penggunaan fitur FC1 sebesar 85,50% dan FC2 sebesar 89,67%. Di sisi lain, konfigurasi yang diuji tetap menghasilkan performa klasifikasi yang tinggi, sehingga performa *retrieval* digunakan sebagai salah satu pertimbangan utama dalam menentukan konfigurasi fitur yang digunakan. Hasil tersebut menunjukkan bahwa, pada dataset dan skenario penelitian ini, representasi fitur konvolusional dari *Block4_pool*

yang diringkas menggunakan GAP lebih efektif dalam merepresentasikan kemiripan visual motif Tenun Samarinda dibandingkan representasi dari FC1 dan FC2.


Penggunaan fitur konvolusional sebagai representasi visual juga relevan dengan karakteristik objek penelitian yang memiliki pola dan tekstur sebagai ciri pembeda utama. Penerapan ekstraksi fitur konvolusional pada citra dengan karakteristik pola tekstil atau motif kain juga telah digunakan dalam penelitian sebelumnya, termasuk pada deteksi pola batik (Kusanti et al., 2026).

Proses ekstraksi fitur dilakukan dengan memasukkan citra hasil *preprocessing* ke dalam model VGG16. Selanjutnya, fitur yang dihasilkan dari layer *Block4_pool* diproses melalui *Global Average Pooling*, lalu disimpan sebagai representasi numerik berdimensi 512 untuk setiap citra. Representasi ini kemudian digunakan pada tahap klasifikasi motif dan tahap *retrieval* citra serupa. Arsitektur CNN yang digunakan untuk ekstraksi fitur ditampilkan secara visual pada Gambar 3.6, sedangkan rincian teknis setiap layer disajikan pada Tabel 3.3 Arsitektur CNN untuk Ekstraksi Fitur.

Tabel 3.3 Arsitektur VGG16 untuk Ekstraksi Fitur

No	Layer	Tipe Layer	Ukuran	Jumlah	Output Shape
1	Input	Input Layer	-	-	$224 \times 224 \times 3$
2	Block1	Conv2D $\times 2$	3×3	64	$224 \times 224 \times 64$
3	Block1	MaxPooling2D	2×2	-	$112 \times 112 \times 64$
4	Block2	Conv2D $\times 2$	3×3	128	$112 \times 112 \times 128$
5	Block2	MaxPooling2D	2×2	-	$56 \times 56 \times 128$
6	Block3	Conv2D $\times 3$	3×3	256	$56 \times 56 \times 256$
7	Block3	MaxPooling2D	2×2	-	$28 \times 28 \times 256$

8	Block4	Conv2D $\times$ 3	3×3	512	$28 \times 28 \times 512$
9	Block4_pool	MaxPooling2D	2×2	-	$14 \times 14 \times 512$
10	GAP	Global Average Pooling	Rata-rata spasial	-	512
11	Output Fitur	Feature Vector	-	-	512



Gambar 3.6 Diagram Proses Arsitektur VGG16 Untuk Ekstraksi Fitur CNN

3.4.5 Perancangan Training Model SVM

Setelah fitur citra diperoleh dari proses ekstraksi menggunakan CNN, tahap selanjutnya adalah pelatihan model Support Vector Machine (SVM) untuk melakukan klasifikasi motif Tenun Samarinda. Pada penelitian ini, SVM digunakan sebagai classifier yang menerima input berupa vektor fitur hasil ekstraksi CNN dan menghasilkan prediksi kelas motif. Pemilihan SVM didasarkan pada kemampuannya dalam menangani data berdimensi tinggi serta kemampuannya membentuk batas keputusan (*decision boundary*) yang optimal antar kelas. Karena penelitian ini melibatkan tiga kelas motif, maka digunakan pendekatan klasifikasi multi-kelas One-vs-Rest (OvR). Pada strategi ini, SVM membangun tiga *binary classifier*, di mana setiap *classifier* dilatih untuk membedakan

satu kelas terhadap seluruh kelas lainnya. Pada saat prediksi, setiap *classifier* menghasilkan skor, kemudian kelas dengan skor tertinggi dipilih sebagai hasil prediksi.

Untuk memperoleh model SVM dengan performa terbaik, penelitian ini melakukan pengujian terhadap beberapa jenis kernel, yaitu linear, Radial Basis Function (RBF), dan polynomial. Kernel linear digunakan untuk data yang cenderung dapat dipisahkan secara linier dan memiliki komputasi yang lebih cepat. Kernel RBF digunakan karena mampu menangani pola data non-linier dan merupakan kernel yang umum digunakan pada klasifikasi citra. Sementara itu, kernel polynomial digunakan untuk menangkap hubungan yang lebih kompleks antar fitur. Agar diperoleh kombinasi parameter yang optimal, dilakukan proses hyperparameter tuning menggunakan metode Grid Search Cross-Validation. Parameter yang diuji meliputi jenis kernel, parameter regularisasi C, dan parameter gamma untuk kernel RBF dan polynomial. Daftar parameter yang diuji ditunjukkan pada Tabel 3.4.

Tabel 3.4 Parameter Grid untuk Hyperparameter Tuning

Parameter	Nilai yang Diuji	Keterangan
Kernel	['linear', 'rbf', 'poly']	Jenis kernel yang digunakan
C (Regularization)	[0.001, 0.01, 0.1, 1, 10, 100]	Parameter regularisasi
Gamma (Untuk RBF & Poly)	[0.001, 0.01, 'scale', 'auto']	Parameter kernel


Proses *Grid Search Cross-Validation* menguji seluruh kombinasi parameter pada Tabel 3.4 menggunakan 5-fold cross-validation. Dengan tiga pilihan kernel, tujuh nilai C, dan lima nilai gamma, terdapat $3 \times 6 \times 4$ kombinasi parameter yang dievaluasi. Kombinasi parameter dengan nilai rata-rata akurasi validasi tertinggi dipilih sebagai konfigurasi akhir model. Berdasarkan hasil *tuning*, diperoleh konfigurasi terbaik berupa kernel linear dengan nilai $C = 0.001$. Parameter gamma tidak berpengaruh terhadap hasil pada konfigurasi tersebut karena gamma tidak digunakan pada kernel linear. Hasil ini menunjukkan bahwa kernel linear memberikan performa validasi terbaik pada fitur hasil

ekstraksi CNN, sehingga tidak diperlukan penggunaan kernel non-linear dalam konfigurasi akhir model.

Metode *Grid Search* menguji seluruh kombinasi parameter yang telah ditentukan dan memilih kombinasi yang menghasilkan nilai rata-rata akurasi validasi tertinggi berdasarkan 5-fold cross-validation. Dengan pendekatan ini, konfigurasi SVM dipilih berdasarkan performanya pada data latih sehingga dapat digunakan untuk melakukan klasifikasi terhadap data uji. Secara umum, proses *training* model SVM pada penelitian ini dilakukan melalui tahapan berikut:

1. Memuat vektor fitur hasil ekstraksi CNN beserta label kelas.
2. Menentukan parameter *grid* yang digunakan dalam proses *tuning*.
3. Melakukan *Grid Search* dengan 5-fold cross-validation pada data latih.
4. Memilih konfigurasi model dengan nilai rata rata akurasi validasi tertinggi.
5. Melatih model SVM akhir menggunakan konfigurasi parameter terbaik.
6. Menyimpan model ke dalam file .pkl untuk digunakan pada tahap klasifikasi.

Flowchart proses training SVM ditunjukkan pada Gambar 3.7.



Gambar 3.7 Flowchart Proses Training SVM

3.4.6 Perancangan Proses Klasifikasi

Setelah model Support Vector Machine (SVM) berhasil dilatih, tahap selanjutnya adalah menggunakan model tersebut untuk melakukan klasifikasi terhadap citra motif tenun yang baru. Proses klasifikasi bertujuan untuk menentukan kelas motif Tenun Samarinda berdasarkan fitur visual citra yang telah diekstraksi. Hasil klasifikasi pada


tahap ini akan digunakan sebagai informasi untuk proses *retrieval* citra serupa. Proses klasifikasi dilakukan melalui beberapa tahapan, yaitu:

1. Input citra query: User mengunggah citra motif tenun
2. Preprocessing: Citra disesuaikan ukurannya menjadi 224×224 piksel dan dilakukan normalisasi nilai piksel dengan membagi nilai piksel menggunakan 255.
3. Ekstraksi fitur: Citra hasil *preprocessing* dimasukkan ke dalam CNN *pre-trained* VGG16 untuk menghasilkan vektor fitur dengan 512 elemen.
4. Load model SVM: Sistem memuat model SVM yang telah dilatih menggunakan konfigurasi parameter terbaik hasil *Grid Search Cross-Validation*.
5. Prediksi kelas: Vektor fitur citra *query* dimasukkan ke dalam model SVM untuk memprediksi kelas motif Tenun Samarinda.
6. Hitung confidence score: Sistem menghitung nilai probabilitas prediksi untuk setiap kelas berdasarkan model SVM yang telah dilatih.
7. Output hasil: Sistem menampilkan label motif hasil prediksi, *confidence score*, dan distribusi probabilitas untuk setiap kelas.

Sistem menghasilkan output berupa:

1. Label motif: Nama kelas motif yang diprediksi oleh model SVM.
2. Confidence score: Tingkat kepercayaan dalam bentuk persentase (0-100%)
3. Probabilitas per kelas: Distribusi probabilitas untuk ketiga kelas motif


Flowchart proses klasifikasi ditunjukkan pada Gambar 3.8.



Gambar 3.8 Flowchart Proses Klasifikasi

3.4.7 Perancangan Proses Retrieval

Setelah proses klasifikasi dilakukan, sistem melanjutkan proses *retrieval* citra serupa menggunakan pendekatan *Content-Based Image Retrieval* (CBIR). Pada penelitian ini, *retrieval* dilakukan untuk menampilkan citra-citra motif Tenun Samarinda yang memiliki kemiripan visual dengan citra *query*. Berbeda dengan klasifikasi yang menghasilkan label kelas, tahap *retrieval* bertujuan memberikan referensi visual berupa citra-citra yang memiliki kemiripan berdasarkan fitur hasil ekstraksi CNN. Proses *retrieval* menggunakan fitur citra *query* yang dibandingkan dengan fitur seluruh citra pada galeri, tanpa membatasi pencarian berdasarkan kelas hasil klasifikasi. Dengan demikian, hasil klasifikasi dan *retrieval* merupakan dua proses yang menggunakan representasi fitur CNN yang sama, tetapi hasil klasifikasi tidak digunakan sebagai filter dalam proses *retrieval*. Flowchart proses *retrieval* menggunakan pendekatan *Content-Based Image Retrieval* (CBIR) ditunjukkan pada Gambar 3.9.



Gambar 3.9 Flowchart Proses Retrieval Menggunakan CBIR

Berdasarkan flowchart pada Gambar 3.9, tahapan proses *retrieval* dilakukan sebagai berikut:

1. Sistem menerima citra *query* yang telah melalui proses *preprocessing* dan ekstraksi fitur CNN.
2. Sistem memuat vektor fitur citra *query* dan vektor fitur seluruh citra pada galeri.
3. Vektor fitur citra *query* dibandingkan dengan vektor fitur setiap citra pada galeri menggunakan *Euclidean Distance*.
4. Sistem menghitung nilai jarak antara fitur citra *query* dan masing-masing citra pembandingan.
5. Nilai jarak yang dihasilkan diurutkan dari yang terkecil hingga terbesar.
6. Sistem memilih lima citra dengan nilai jarak terkecil sebagai hasil *retrieval*.
7. Sistem menampilkan Top-5 citra yang memiliki jarak Euclidean terdekat kepada pengguna sebagai referensi visual.

Pengukuran kemiripan pada penelitian ini menggunakan *Euclidean Distance* karena metode ini sederhana dan efektif untuk membandingkan vektor fitur numerik hasil ekstraksi CNN. Semakin kecil nilai jarak yang diperoleh, semakin dekat representasi fitur antara citra *query* dan citra pembandingan. Secara matematis, *Euclidean Distance* dirumuskan sebagai berikut:

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

Keterangan:

$d(x, y)$ = jarak antara citra query dan citra pembanding

x_i = nilai fitur ke- i dari citra query

y_i = nilai fitur ke- i dari citra pembanding

n = jumlah dimensi fitur

Hasil *retrieval* yang diperoleh pada tahap ini ditampilkan bersama dengan hasil klasifikasi, sehingga pengguna dapat melihat label motif, *confidence score*, dan Top-5 citra dengan jarak terdekat dalam satu tampilan sistem. Dengan demikian, proses *retrieval* menggunakan CBIR pada penelitian ini berfungsi sebagai pelengkap tahap klasifikasi dengan memberikan referensi visual berdasarkan kemiripan fitur citra tanpa membatasi pencarian berdasarkan kelas hasil klasifikasi.

3.4.8 Perancangan Evaluasi Sistem

Perancangan evaluasi sistem dilakukan untuk menilai performa sistem yang dibangun pada penelitian ini, baik pada tahap klasifikasi motif maupun pada tahap *retrieval* citra serupa. Karena sistem terdiri dari dua proses utama, maka evaluasi juga dilakukan dalam dua aspek, yaitu evaluasi klasifikasi dan evaluasi *retrieval*. Dengan pemisahan ini, performa sistem dapat dianalisis secara lebih jelas sesuai fungsi masing-masing tahap.

1 Evaluasi Klasifikasi

Evaluasi klasifikasi bertujuan untuk menilai kemampuan model dalam menentukan kelas motif Tenun Samarinda berdasarkan citra input. Pada penelitian ini, evaluasi klasifikasi dilakukan menggunakan confusion matrix, accuracy, precision, recall, dan F1-score. Confusion matrix digunakan untuk melihat distribusi hasil prediksi model terhadap kelas sebenarnya, sedangkan accuracy digunakan untuk mengukur proporsi prediksi yang benar terhadap seluruh data uji. Precision digunakan untuk mengukur ketepatan model dalam memprediksi suatu kelas, recall digunakan untuk mengukur kemampuan model dalam menemukan seluruh data yang termasuk dalam kelas tertentu, dan F1-score digunakan untuk melihat keseimbangan antara precision dan recall. Secara umum, rumus evaluasi klasifikasi yang digunakan adalah sebagai berikut:

$$a. \text{ Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

$$b. Precision = \frac{TP}{TP+FP}$$

$$c. Recall = \frac{TP}{TP+FN}$$

$$d. F1-Score = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

Keterangan:

TP (True Positive) = jumlah data yang diprediksi benar sebagai kelas positif

TN (True Negative) = jumlah data yang diprediksi benar sebagai kelas negatif

FP (False Positive) = jumlah data yang diprediksi salah sebagai kelas positif

FN (False Negative) = jumlah data yang diprediksi salah sebagai kelas negatif

Evaluasi klasifikasi dilakukan menggunakan data uji yang telah dipisahkan pada tahap pembagian dataset. Hasil evaluasi ini digunakan untuk mengetahui seberapa baik model CNN-SVM dalam mengenali dan membedakan motif Tenun Samarinda.

2 Evaluasi Retrieval

Selain tahap klasifikasi, penelitian ini juga mengevaluasi performa sistem pada tahap retrieval citra serupa. Evaluasi retrieval bertujuan untuk menilai seberapa relevan citra-citra yang ditampilkan sistem terhadap citra query. Pada penelitian ini, karena sistem menampilkan lima citra teratas yang paling mirip, maka metrik evaluasi yang digunakan adalah Precision@5. Precision@5 digunakan untuk mengukur proporsi citra relevan di antara lima hasil retrieval teratas yang ditampilkan sistem. Semakin tinggi nilai Precision@5, semakin baik kualitas retrieval yang dihasilkan karena semakin banyak citra relevan yang muncul pada posisi teratas. Secara matematis, Precision@5 dirumuskan sebagai berikut:

$$Precision@5 = \frac{\text{Jumlah citra relevan pada Top-5}}{5}$$

Pada penelitian ini, suatu citra dianggap relevan apabila citra tersebut memiliki kelas motif yang sama dengan citra query dan termasuk dalam lima hasil retrieval teratas. Proses retrieval dilakukan dengan membandingkan vektor fitur citra query terhadap seluruh citra pada galeri menggunakan Euclidean Distance. Seluruh citra galeri kemudian diurutkan berdasarkan nilai jarak dari yang terkecil hingga terbesar, sehingga lima citra dengan jarak terkecil menjadi hasil retrieval. Dengan demikian, Precision@5 digunakan untuk mengukur kemampuan representasi fitur dalam menempatkan citra dengan motif

yang relevan pada posisi teratas tanpa membatasi kandidat retrieval berdasarkan hasil klasifikasi.

3 Pengamatan Visual Hasil Retrieval

Selain evaluasi kuantitatif, hasil retrieval juga diamati secara visual untuk menilai kesesuaian pola, tekstur, warna, dan susunan motif antara citra query dan citra-citra hasil retrieval. Pengamatan ini penting karena pada citra tekstil tradisional, kemiripan visual tidak hanya ditentukan oleh warna, tetapi juga oleh pola motif dan karakteristik tekstur yang khas. Oleh karena itu, evaluasi visual digunakan sebagai pelengkap evaluasi numerik agar hasil analisis sistem menjadi lebih komprehensif.


4 Tujuan Evaluasi Sistem

Melalui rancangan evaluasi ini, penelitian dapat menilai performa sistem dari dua sisi yang saling melengkapi. Pertama, evaluasi klasifikasi digunakan untuk mengetahui kemampuan sistem dalam menentukan kelas motif secara benar. Kedua, evaluasi retrieval digunakan untuk mengetahui kemampuan sistem dalam menampilkan citra-citra yang paling relevan sebagai referensi visual. Dengan demikian, evaluasi sistem pada penelitian ini tidak hanya menilai ketepatan klasifikasi, tetapi juga menilai kualitas retrieval yang menjadi bagian penting dari pendekatan yang diusulkan.

3.5 Perancangan Tampilan

Perancangan tampilan pada sistem klasifikasi dan retrieval motif Tenun Samarinda bertujuan untuk memudahkan pengguna dalam melakukan proses identifikasi motif tenun secara interaktif. Tampilan dirancang dengan mempertimbangkan aspek kemudahan penggunaan (*usability*) dan kenyamanan pengguna (*user experience*) agar sistem dapat dioperasikan dengan mudah oleh berbagai kalangan pengguna. Aplikasi dikembangkan menggunakan Streamlit, yaitu framework Python yang memungkinkan pembuatan aplikasi web interaktif secara cepat dan sederhana. Tampilan sistem dirancang agar pengguna dapat melakukan seluruh proses utama dalam satu halaman, mulai dari mengunggah citra, melihat hasil klasifikasi, hingga melihat hasil retrieval citra serupa. Dengan rancangan ini, pengguna tidak hanya memperoleh hasil prediksi kelas motif, tetapi juga memperoleh referensi visual berupa citra-citra yang paling mirip dengan citra input.

Rancangan tampilan utama aplikasi klasifikasi motif tenun Samarinda ditampilkan pada Gambar 3.10. Tampilan dirancang dengan struktur yang sederhana dan intuitif agar pengguna dapat dengan mudah megoperasikan sistem.



Gambar 3.10 Rancangan Tampilan Utama Aplikasi

Gambar 3.10 menunjukkan bahwa tampilan aplikasi terdiri dari beberapa komponen utama, yaitu:

1. Header Aplikasi: Bagian atas halaman yang menampilkan judul sistem "Sistem Klasifikasi dan Retrieval Motif Tenun Samarinda" beserta deskripsi singkat tentang fungsi aplikasi
2. Area Upload Citra: Komponen file uploader yang memungkinkan pengguna untuk mengunggah citra motif tenun dalam format JPG, JPEG, atau PNG. Pengguna dapat mengunggah citra dengan cara drag and drop atau mengklik tombol "Browse files"
3. Area Preview Citra: Setelah citra berhasil diunggah, sistem akan menampilkan preview citra pada area ini beserta informasi dasar seperti nama file dan dimensi citra
4. Tombol klasifikasi: Tombol "Klasifikasi Motif" yang akan memulai proses klasifikasi ketika diklik. Tombol ini hanya aktif jika citra berhasil diunggah

5. Area Hasil Klasifikasi: Menampilkan hasil prediksi berupa nama motif, confidence score dalam bentuk persentase, dan distribusi probabilitas untuk setiap kelas motif dalam bentuk grafik batang
6. Area Hasil Retrieval: yaitu bagian yang menampilkan Top-5 citra paling mirip berdasarkan hasil pencarian citra serupa pada kelas hasil klasifikasi. Area ini berfungsi sebagai referensi visual yang melengkapi hasil klasifikasi.

Melalui rancangan tampilan ini, pengguna dapat melakukan interaksi dengan sistem secara langsung dalam satu halaman, mulai dari input citra hingga melihat hasil klasifikasi dan retrieval. Dengan demikian, tampilan aplikasi tidak hanya berfungsi untuk menyajikan hasil prediksi kelas motif, tetapi juga untuk menampilkan referensi visual yang mendukung interpretasi hasil sistem.

3.6 Perancangan Pengujian

Perancangan pengujian bertujuan untuk memastikan bahwa sistem klasifikasi dan retrieval motif Tenun Samarinda dapat berjalan dengan baik serta memenuhi kriteria keberhasilan yang telah ditetapkan. Pengujian dilakukan untuk menilai dua aspek utama dalam sistem, yaitu fungsionalitas sistem dan performa model, baik pada tahap klasifikasi maupun pada tahap retrieval citra serupa. Pengujian pada penelitian ini terdiri dari beberapa bagian sebagai berikut:

1. Pengujian Fungsional

Pengujian fungsional dilakukan untuk memastikan seluruh proses dalam sistem berjalan tanpa kesalahan. Proses yang diuji meliputi upload citra, preprocessing citra, ekstraksi fitur menggunakan CNN, klasifikasi menggunakan SVM, retrieval citra menggunakan CBIR, serta penampilan hasil klasifikasi dan Top-5 citra retrieval. Pengujian ini bertujuan memastikan bahwa setiap komponen sistem dapat berjalan sesuai alur yang dirancang.

2. Pengujian Performa Klasifikasi

Pengujian performa klasifikasi dilakukan menggunakan 40% data testing untuk mengukur kemampuan model dalam menentukan kelas motif Tenun Samarinda. Evaluasi klasifikasi dilakukan menggunakan metrik accuracy, precision, recall, F1-score, serta confusion matrix dengan pendekatan weighted average untuk klasifikasi

multi-kelas. Pengujian ini bertujuan mengetahui seberapa baik model dalam membedakan setiap kelas motif berdasarkan citra input.

3. Pengujian Performa Retrieval

Pengujian performa retrieval dilakukan untuk menilai kualitas hasil pencarian citra serupa menggunakan Precision@5. Pengujian bertujuan mengetahui tingkat relevansi lima citra teratas terhadap citra *query*. Citra hasil retrieval dianggap relevan apabila memiliki kelas motif yang sama dengan ground truth citra *query*. Retrieval dilakukan dengan membandingkan fitur *query* dengan seluruh citra galeri menggunakan *Euclidean Distance*, kemudian mengurutkannya berdasarkan jarak terkecil.

4. Pengujian Citra Baru dan Variasi Kondisi Citra

Selain menggunakan data testing, pengujian juga dilakukan pada beberapa citra baru di luar data uji untuk melihat kemampuan sistem dalam menangani data yang belum pernah diproses sebelumnya. Pengujian ini mencakup variasi kondisi citra, seperti perbedaan pencahayaan dan sudut pengambilan gambar, guna melihat kestabilan sistem terhadap perubahan kondisi visual.

5. Pengukuran Waktu Pemrosesan

Pengujian waktu pemrosesan dilakukan untuk mengetahui efisiensi sistem dalam memproses satu citra, mulai dari input citra hingga menampilkan hasil klasifikasi dan retrieval. Pengukuran ini dilakukan untuk memastikan bahwa sistem dapat digunakan secara interaktif dengan waktu respons yang masih dapat diterima.

Sistem dinyatakan berhasil apabila memenuhi kriteria sebagai berikut:

- a. accuracy klasifikasi $\geq 85\%$
- b. precision, recall, dan F1-score $\geq 80\%$
- c. Precision@5 menunjukkan mayoritas hasil retrieval relevan terhadap citra query
- d. waktu pemrosesan ≤ 5 detik per citra
- e. sistem berjalan stabil tanpa error selama proses pengujian

BAB IV

HASIL DAN PEMBAHASAN

4.1 Pengolahan Data

Pengolahan data merupakan tahap awal dalam pembangunan sistem klasifikasi dan *Content-Based Image Retrieval* (CBIR) motif Tenun Samarinda. Pada tahap ini dilakukan penyusunan dataset, preprocessing citra, serta pembagian data menjadi data latih dan data uji. Seluruh proses tersebut bertujuan untuk menghasilkan dataset yang terstruktur dan siap digunakan pada tahap implementasi sistem. Hasil pengolahan data selanjutnya digunakan sebagai masukan pada proses ekstraksi fitur, klasifikasi, dan retrieval citra.

4.1.1 Dataset Penelitian

Dataset yang berhasil disusun pada penelitian ini terdiri atas 300 citra motif Tenun Samarinda yang terbagi ke dalam tiga kelas, yaitu Hatta, Pucuk Rebung, dan Cumi/Bunga Dayak. Masing-masing kelas memiliki 100 citra sehingga distribusi data antar kelas bersifat seimbang. Seluruh dataset diperoleh dari tujuh lembar sarung tenun yang berbeda, terdiri atas dua sarung motif Hatta, tiga sarung motif Pucuk Rebung, dan dua sarung motif Cumi/Bunga Dayak. Distribusi dataset penelitian disajikan pada Tabel 4.1.

Tabel 4.1 Distribusi Dataset Penelitian

Motif	Jumlah Citra	Jumlah Sarung
Hatta	100	2
Pucuk Rebung	100	3
Cumi/Bunga Dayak	100	2
Total	300	7

Distribusi jumlah citra yang seimbang pada setiap kelas bertujuan untuk mengurangi potensi bias model terhadap kelas tertentu sehingga proses pelatihan dapat berlangsung lebih optimal.

4.1.2 Preprocessing Citra

Tahap preprocessing dilakukan terhadap seluruh citra dataset dengan mengonversi format warna menjadi RGB, melakukan crop secara proporsional, serta mengubah ukuran citra menjadi 224 x 224 piksel sesuai dengan spesifikasi masukan model VGG16. Hasil preprocessing menghasilkan citra dengan ukuran dan format yang seragam sehingga siap digunakan pada tahap klasifikasi. Perbandingan citra sebelum dan sesudah preprocessing disajikan pada Tabel 4.2.

Tabel 4.2 Perbandingan Citra Sebelum dan Sesudah Preprocessing

Motif	Sebelum Preprocessing	Sesudah Preprocessing
Hatta	 2812 x 3750 piksel	 224 x 224 piksel
Pucuk Rebung	 2812 x 3750 piksel	 224 x 224 piksel
Cumi	 2812 x 3750 piksel	 224 x 224 piksel

a. Pembagian Data (Training dan Testing)

Pembagian data dilakukan untuk memisahkan dataset menjadi data latih (*training data*) dan data uji (*testing data*). Pada penelitian ini, pembagian data dilakukan

menggunakan rasio 60:40 secara *stratified* berdasarkan kelas. Dari total 300 citra yang terdiri atas 100 citra untuk setiap kelas motif, diperoleh sebanyak 180 citra sebagai data latih dan 120 citra sebagai data uji. Pembagian data dilakukan dengan mempertahankan proporsi setiap kelas pada data latih dan data uji. Dengan demikian, setiap kelas motif terdiri atas 60 citra data latih dan 40 citra data uji. Rincian pembagian data ditampilkan pada Tabel 4.3.

Tabel 4.3 Pembagian Data Latih dan Data Uji

Motif	Data Latih	Data Uji
Hatta	60	40
Pucuk Rebung	60	40
Cumi	60	40

Pembagian data dilakukan menggunakan metode *stratified split* untuk memastikan setiap kelas motif memiliki distribusi yang proporsional pada data latih maupun data uji. Dengan pembagian tersebut, data latih digunakan untuk menghasilkan fitur dan melatih model SVM, sedangkan data uji digunakan untuk mengevaluasi performa model menggunakan citra yang tidak digunakan dalam proses pelatihan model.

4.2 Implementasi Sistem

Setelah proses pengolahan data selesai dilakukan, tahap berikutnya adalah implementasi sistem klasifikasi dan *Content-Based Image Retrieval* (CBIR) motif Tenun Samarinda. Implementasi sistem dilakukan berdasarkan rancangan yang telah dijelaskan pada Bab III, meliputi proses ekstraksi fitur menggunakan arsitektur VGG16, klasifikasi menggunakan Support Vector Machine (SVM), proses retrieval citra menggunakan metode Euclidean Distance, serta implementasi antarmuka pengguna berbasis Streamlit. Pada tahap ini dijelaskan bagaimana setiap komponen sistem diimplementasikan sehingga mampu menghasilkan proses klasifikasi dan pencarian citra yang terintegrasi.

4.2.1 Implementasi CNN-SVM

Pada penelitian ini, ekstraksi fitur dilakukan menggunakan model VGG16 *pretrained* ImageNet dengan parameter `include_top=False`. Fitur diambil dari layer

block4_pool kemudian diproses menggunakan *Global Average Pooling* sehingga setiap citra direpresentasikan menjadi vektor fitur berdimensi 512. Pemilihan layer Block4 dilakukan setelah beberapa percobaan menggunakan beberapa layer VGG16, yaitu Block4, Block5, FC1, dan FC2. Berdasarkan hasil pengujian awal, layer Block4 memberikan performa terbaik sehingga digunakan sebagai *feature extractor* pada implementasi sistem. Hasil perbandingan performa antar layer dibahas lebih lanjut pada Subbab 4.4. Vektor fitur yang dihasilkan selanjutnya digunakan secara langsung sebagai masukan untuk proses klasifikasi menggunakan *Support Vector Machine* (SVM). Penentuan parameter terbaik dilakukan menggunakan *Grid Search CV* sehingga diperoleh kernel linier dengan nilai parameter C sebesar 0.001 sebagai konfigurasi terbaik.

4.2.2 Implementasi Content-Based Image Retrieval

Setelah proses klasifikasi selesai dilakukan, sistem menggunakan fitur citra *query* untuk menghitung Euclidean Distance terhadap seluruh fitur citra pada basis data. Nilai jarak kemudian diurutkan dari yang terkecil hingga terbesar. Lima citra dengan nilai jarak terkecil ditampilkan sebagai hasil Content-Based Image Retrieval.

4.2.3 Implementasi Antarmuka Streamlit

Antarmuka sistem diimplementasikan menggunakan pustaka Streamlit dengan tata letak dua kolom (*wide layout*) agar proses klasifikasi dan retrieval dapat ditampilkan secara berdampingan dalam satu halaman. Antarmuka ini berfungsi sebagai penghubung antara pengguna dengan model CNN-SVM dan modul retrieval yang telah dibangun, sehingga pengguna cukup mengunggah satu citra motif tenun untuk memperoleh hasil klasifikasi sekaligus citra-citra yang paling mirip.

Pada tahap awal, sistem memuat tiga komponen utama, yaitu model feature extractor VGG16, model klasifikasi SVM, dan indeks kelas (*class indices*). Ketiga komponen ini dimuat menggunakan mekanisme caching Streamlit (*@st.cache_resource* dan *@st.cache_data*) agar hanya dimuat satu kali selama sesi aplikasi berjalan, sehingga proses tidak diulang setiap kali pengguna melakukan interaksi. Sebelum model dimuat, sistem terlebih dahulu memvalidasi ketersediaan berkas model SVM, basis data fitur, dan berkas indeks kelas. Apabila salah satu berkas belum tersedia, sistem menampilkan pesan


kesalahan beserta petunjuk menjalankan tahapan pipeline (preprocessing, ekstraksi fitur, splitting, dan training) dan menghentikan eksekusi.

Antarmuka dibagi menjadi dua kolom. Kolom kiri berfungsi sebagai panel masukan, berisi komponen pengunggah berkas (file uploader) yang menerima format JPG, JPEG, PNG, BMP, dan WEBP, serta slider untuk menentukan jumlah hasil retrieval (Top-K) yang ditampilkan, dengan nilai bawaan lima citra. Citra yang diunggah kemudian ditampilkan sebagai pratinjau lengkap dengan informasi nama berkas dan dimensi asli citra. Saat citra dibuka, sistem menerapkan koreksi orientasi berdasarkan metadata EXIF (ImageOps.exif_transpose) dan mengonversi citra ke ruang warna RGB agar konsisten dengan format masukan model.

Proses inti dijalankan ketika pengguna menekan tombol "Klasifikasi dan Retrieval". Pada tahap ini sistem melakukan empat langkah secara berurutan. Pertama, citra masukan disimpan sementara ke dalam direktori temp_uploads dengan nama berkas unik. Kedua, citra diekstraksi fiturnya menggunakan VGG16 pada blok konvolusi keempat (Block4) yang dilanjutkan dengan Global Average Pooling sehingga menghasilkan vektor fitur berdimensi 512. Ketiga, vektor fitur tersebut diklasifikasikan oleh model SVM untuk memperoleh label motif, nilai confidence, dan distribusi probabilitas antar-kelas. Keempat, vektor fitur yang sama digunakan untuk melakukan retrieval citra serupa berdasarkan jarak Euclidean. Perlu ditegaskan bahwa proses retrieval dilakukan terhadap seluruh citra pada basis data galeri tanpa dibatasi oleh label hasil klasifikasi, sehingga citra paling mirip dicari dari keseluruhan koleksi, bukan hanya dari kelas prediksi.

Kolom kanan berfungsi menampilkan hasil klasifikasi, meliputi label motif, nilai confidence score dalam bentuk persentase, serta diagram batang distribusi probabilitas untuk setiap kelas. Di bagian bawah halaman, sistem menampilkan hasil retrieval berupa deretan citra paling mirip sejumlah nilai Top-K yang dipilih. Setiap citra dilengkapi keterangan peringkat (rank), nama kelas, nilai jarak (distance), dan nama berkas. Untuk menjaga stabilitas tampilan, hasil klasifikasi dan retrieval disimpan pada session state sehingga tetap tampil meskipun terjadi interaksi ulang pada antarmuka. Dengan rancangan ini, antarmuka Streamlit mampu menyajikan keseluruhan alur sistem, mulai

dari unggah citra, ekstraksi fitur, klasifikasi, hingga penyajian citra serupa, dalam satu tampilan yang terpadu dan mudah digunakan.



Gambar 4.1 Tampilan Antarmuka Sistem

4.3 Hasil Pengujian Sistem

Setelah proses implementasi sistem selesai dilakukan, tahap berikutnya adalah pengujian untuk mengevaluasi kinerja sistem klasifikasi dan *Content-Based Image Retrieval* (CBIR). Pengujian dilakukan menggunakan data uji yang dipisahkan dari data latih melalui pembagian data dengan rasio 60:40 secara *stratified* berdasarkan kelas. Dengan pembagian tersebut, setiap kelas motif memiliki proporsi data yang sama pada data latih dan data uji, sehingga data uji dapat digunakan untuk mengevaluasi performa model terhadap citra yang tidak digunakan dalam proses pelatihan SVM.

Pengujian sistem meliputi dua tahap, yaitu pengujian klasifikasi menggunakan kombinasi VGG16 sebagai *feature extractor* dan Support Vector Machine (SVM) sebagai *classifier*, serta pengujian sistem *retrieval* menggunakan pendekatan *Content-Based Image Retrieval* (CBIR). Evaluasi klasifikasi dilakukan menggunakan metrik *accuracy*, *precision*, *recall*, *F1-score*, dan *confusion matrix*, sedangkan evaluasi *retrieval* dilakukan menggunakan metrik *Precision@5*. Hasil dari setiap pengujian disajikan pada subbab berikutnya.

4.3.1 Hasil Klasifikasi CNN-SVM

Pengujian klasifikasi dilakukan untuk mengetahui kemampuan model CNN-SVM dalam mengenali motif Tenun Samarinda berdasarkan fitur yang diekstraksi menggunakan arsitektur VGG16 pada layer Block4 dengan *Global Average Pooling* (GAP). Seluruh pengujian dilakukan menggunakan data uji yang diperoleh melalui metode *Stratified Split*, dengan mempertahankan proporsi setiap kelas pada data latih dan data uji. Evaluasi kinerja model dilakukan menggunakan metrik *Accuracy*, *Precision*, *Recall*, dan *F1-score* yang perhitungannya mengacu pada Persamaan 2.1, Persamaan 2.2, Persamaan 2.3, dan Persamaan 2.4. Hasil pengujian menunjukkan bahwa model memperoleh nilai akurasi sebesar 100% pada data uji. Nilai *Precision*, *Recall*, dan *F1-score* untuk masing-masing kelas motif disajikan pada Tabel 4.4.

Tabel 4.4 Hasil Analisis Model CNN-SVM pada Data Uji

Kelas Motif	Precision	Recall	F1-Score	Jumlah Data
Hatta	1,00	1,00	1,00	40
Pucuk Rebung	1,00	1,00	1,00	40
Cumi	1,00	1,00	1,00	40

Berdasarkan Tabel 4.4, model CNN-SVM memperoleh nilai *accuracy* sebesar 100% pada 120 citra data uji. Seluruh kelas motif, yaitu Hatta, Pucuk Rebung, dan Cumi/Bunga Dayak, memperoleh nilai *Precision*, *Recall*, *F1-score* sebesar 1,00. Nilai *precision* sebesar 1,00 menunjukkan bahwa seluruh citra yang diprediksi oleh model ke dalam suatu kelas benar-benar berasal dari kelas tersebut. Sementara itu, nilai *recall* sebesar 1,00 menunjukkan bahwa seluruh citra pada masing-masing kelas berhasil dikenali dan diklasifikasikan ke kelas yang sesuai. Nilai *F1-score* sebesar 1,00 pada seluruh kelas menunjukkan bahwa model memiliki keseimbangan yang sempurna antara nilai *precision* dan *recall* pada data uji.

Secara keseluruhan, hasil tersebut menunjukkan bahwa model CNN-SVM mampu mengklasifikasikan seluruh 120 citra data uji dengan benar tanpa adanya kesalahan klasifikasi. Nilai weighted F1-score sebesar 100% juga mengonfirmasi bahwa performa klasifikasi model sangat baik pada seluruh kelas motif yang diuji.

Selain menggunakan metrik evaluasi tersebut, hasil klasifikasi juga disajikan dalam bentuk confusion matrix untuk menunjukkan distribusi prediksi pada setiap kelas. Confusion matrix memberikan informasi mengenai jumlah citra yang diklasifikasikan dengan benar maupun citra yang mengalami kesalahan klasifikasi pada masing-masing kelas. Hasil confusion matrix ditunjukkan pada Tabel 4.5.


Tabel 4.5 Confusion Matrix Model CNN-SVM pada Data Uji

Aktual/Prediksi	Hatta	Pucuk Rebung	Cumi
Hatta	40	0	0
Pucuk Rebung	0	40	0
Cumi	0	0	40


4.3.2 Hasil Pengujian Retrieval

Setelah proses klasifikasi, sistem melakukan *Content-Based Image Retrieval* (CBIR) untuk menampilkan citra motif Tenun Samarinda yang memiliki kemiripan dengan citra *query*. Proses retrieval menggunakan fitur hasil ekstraksi VGG16 pada layer Block4, sedangkan tingkat kemiripan dihitung menggunakan *Euclidean Distance*. Citra dengan nilai jarak terkecil dianggap memiliki tingkat kemiripan tertinggi. Proses pencarian dilakukan terhadap seluruh citra pada basis data, kemudian lima citra dengan nilai *Euclidean Distance* terkecil (Top-5) ditampilkan sebagai hasil retrieval.


Pengujian dilakukan menggunakan beberapa citra uji yang tidak termasuk dalam data latih. Untuk setiap citra *query*, sistem menampilkan lima citra dengan nilai *Euclidean Distance* terkecil. Contoh hasil retrieval ditunjukkan pada Gambar 4.1, Gambar 4.2, dan Gambar 4.3.



Gambar 4.2 Hasil Retrieval Citra Query Motif Hatta



Gambar 4.3 Hasil Retrieval Citra Query Motif Pucuk Rebung



Gambar 4.4 Hasil Retrieval Citra Query Motif Cumi/Bunga Dayak

Selain menampilkan citra hasil retrieval, sistem juga menampilkan nilai Euclidean Distance untuk setiap citra sehingga tingkat kemiripan antara citra query dan citra hasil retrieval dapat diketahui. Semakin kecil nilai Euclidean Distance yang diperoleh, maka semakin tinggi tingkat kemiripan antara kedua citra tersebut.

4.3.3 Evaluasi Precision@5

Evaluasi terhadap kinerja sistem *Content-Based Image Retrieval* (CBIR) dilakukan menggunakan metrik *Precision@5*. Metrik ini digunakan untuk mengukur tingkat relevansi lima citra teratas (*Top-5*) yang berhasil dikembalikan oleh sistem terhadap citra query. Pada penelitian ini, proses evaluasi dilakukan menggunakan seluruh data uji yang berjumlah 120 citra, yang terdiri atas 40 citra motif Hatta, 40 citra motif Pucuk Rebung, dan 40 citra motif Cumi/Bunga Dayak. Untuk setiap citra query, sistem menampilkan lima citra dengan nilai *Euclidean Distance* terkecil sebagai hasil retrieval.

Nilai *Precision@5* untuk setiap citra query dihitung menggunakan persamaan 2.6, kemudian seluruh nilai *Precision@5* dirata-ratakan untuk memperoleh *Mean Precision@5* ditunjukkan pada Tabel 4.5.

Tabel 4.6 Hasil Evaluasi *Precision@5* Sistem CBIR

Parameter	Nilai
Jumlah Query	120
Top-K	5
Mean <i>Precision@5</i>	96,33%

Berdasarkan hasil pengujian, sistem memperoleh nilai *Mean Precision@5* sebesar 96,33%. Nilai tersebut menunjukkan bahwa sebagian besar citra yang ditampilkan pada lima hasil retrieval pertama merupakan citra yang memiliki motif yang sama dengan citra query. Dengan demikian, sistem mampu menampilkan citra dengan tingkat kemiripan yang tinggi terhadap citra masukan.

4.3.4 Hasil Pengujian Robustness

Pengujian robustness dilakukan untuk mengukur ketahanan model CNN-SVM ketika citra uji diberi berbagai variasi kondisi, sebagaimana dirancang pada sub-bab 3.6. Variasi tersebut meliputi rotasi (90° dan 180°), flip horizontal, Gaussian blur, perubahan kecerahan (+30% dan -30%), Gaussian noise, serta penurunan resolusi menjadi seperempat resolusi asli. Setiap variasi diterapkan pada seluruh 120 citra uji, kemudian akurasi klasifikasinya dibandingkan dengan akurasi baseline (citra asli tanpa variasi). Hasil selengkapnya disajikan pada Tabel 4.7.

Tabel 4.7 Hasil Pengujian Robustness terhadap Variasi Kondisi Citra

Transformasi	Akurasi (%)	Benar	Total	Selisih vs Baseline (%)
Asli (Baseline)	100,00	120	120	0,00
Rotasi 90 derajat	100,00	120	120	0,00
Rotasi 180 derajat	100,00	120	120	0,00
Flip Horizontal	100,00	120	120	0,00
Gaussian Blur	72,50	87	120	-27,50
Kecerahan +30%	100,00	120	120	0,00
Kecerahan -30%	100,00	120	120	0,00
Gaussian Noise	99,17	119	120	-0,83
Resolusi Rendah (1/4)	72,50	87	120	-27,50

Berdasarkan Tabel 4.7, model menunjukkan ketahanan yang sangat baik terhadap sebagian besar variasi kondisi citra. Pada transformasi rotasi 90° , rotasi 180° , flip horizontal, serta perubahan kecerahan (+30% dan -30%), akurasi klasifikasi tetap bertahan pada 100,00%, sama dengan baseline. Hal ini menunjukkan bahwa fitur tekstur motif tenun yang diekstraksi oleh VGG16 bersifat konsisten terhadap perubahan orientasi dan intensitas pencahayaan, sehingga variasi tersebut tidak memengaruhi keputusan klasifikasi SVM. Pada pemberian Gaussian noise, akurasi hanya turun tipis menjadi 99,17% (satu citra salah klasifikasi dari 120 citra), yang mengindikasikan model masih tahan terhadap derau tingkat rendah.

Penurunan akurasi yang signifikan terjadi pada dua kondisi, yaitu Gaussian blur dan penurunan resolusi ($1/4$), yang keduanya turun menjadi 72,50% (87 dari 120 citra benar) atau selisih -27,50% terhadap baseline. Kedua kondisi ini sama-sama mengaburkan detail tekstur halus motif tenun. Motif tenun Samarinda dibedakan terutama oleh pola garis dan tekstur berulang yang rapat, sehingga ketika detail tersebut hilang akibat pemburaman maupun kehilangan resolusi, informasi diskriminatif yang menjadi dasar pembeda antar-kelas ikut berkurang. Akibatnya, kemampuan model dalam membedakan motif Hatta, Pucuk Rebung, dan Cumi menurun. Temuan ini menegaskan bahwa ketajaman tekstur merupakan faktor penting bagi kinerja model.

4.3.5 Hasil Pengukuran Waktu Pemrosesan

Pengukuran waktu pemrosesan dilakukan untuk mengetahui efisiensi sistem dalam memproses satu citra masukan, mulai dari ekstraksi fitur hingga proses retrieval, sesuai rancangan pada sub-bab 3.6. Pengujian dijalankan pada perangkat dengan spesifikasi pemrosesan berbasis CPU (tanpa akselerasi GPU) dan memori (RAM) sebesar 15,40 GB, menggunakan pustaka TensorFlow versi 2.20.0. Waktu diukur untuk setiap tahap pipeline, yaitu ekstraksi fitur VGG16, klasifikasi SVM, dan retrieval Top-5, kemudian dihitung nilai rata-rata, standar deviasi, minimum, dan maksimum dari seluruh citra uji. Hasil pengukuran disajikan pada Tabel 4.8.

Tabel 4.8 Hasil Pengukuran Waktu Pemrosesan per Citra

Tahap	Rata-rata (ms)	Std (ms)	Min (ms)	Maks (ms)
Ekstraksi Fitur VGG16	152,253	6,314	140,866	172,211
Klasifikasi SVM	0,655	0,128	0,591	2,017
Retrieval (Top-5)	0,158	0,147	0,128	1,748
TOTAL per citra	153,066	6,297	141,621	173,077

Berdasarkan Tabel 4.8, total waktu pemrosesan rata-rata untuk satu citra adalah 153,066 ms atau sekitar 0,15 detik, dengan waktu tercepat sebesar 141,621 ms dan waktu terlama sebesar 173,077 ms. Nilai tersebut menghasilkan throughput rata-rata sekitar 6,53 citra per detik. Dengan demikian, waktu pemrosesan sistem berada jauh di bawah kriteria keberhasilan yang ditetapkan pada Subbab 3.6, yaitu waktu pemrosesan ≤ 5 detik per citra, sehingga kriteria tersebut terpenuhi.

Dari ketiga tahap pemrosesan, ekstraksi fitur menggunakan VGG16 merupakan tahap yang paling banyak menyita waktu, dengan rata-rata 152,253 ms atau sekitar 99,5% dari keseluruhan waktu pemrosesan. Kondisi ini menunjukkan bahwa beban komputasi utama sistem berada pada proses ekstraksi fitur, yang melibatkan operasi konvolusi pada beberapa lapisan VGG16. Pengujian dilakukan menggunakan CPU tanpa akselerasi GPU, sehingga seluruh proses ekstraksi fitur dijalankan oleh CPU. Sementara itu, tahap klasifikasi SVM hanya membutuhkan rata-rata 0,655 ms, sedangkan proses retrieval Top-5 membutuhkan rata-rata 0,158 ms. Kedua tahap tersebut memiliki waktu pemrosesan yang jauh lebih kecil dibandingkan ekstraksi fitur. Hasil ini menunjukkan bahwa optimasi kinerja sistem terutama dapat difokuskan pada tahap ekstraksi fitur, misalnya melalui penggunaan akselerasi GPU. Meskipun demikian, konfigurasi berbasis CPU yang digunakan pada pengujian telah mampu menghasilkan waktu pemrosesan rata-rata sekitar 0,15 detik per citra, sehingga sistem tetap memenuhi kriteria waktu pemrosesan yang telah ditetapkan.

4.4 Pembahasan

Pembahasan pada penelitian ini bertujuan untuk menganalisis hasil pengujian yang telah diperoleh serta menjelaskan faktor-faktor yang memengaruhi kinerja sistem klasifikasi dan *Content-Based Image Retrieval* (CBIR) motif Tenun Samarinda. Analisis dilakukan terhadap pemilihan fitur hasil ekstraksi menggunakan beberapa layer VGG16, performa klasifikasi menggunakan Support Vector Machine (SVM), serta performa

retrieval berdasarkan metode Euclidean Distance. Selain itu, pembahasan juga menguraikan penyebab terjadinya kesalahan klasifikasi dan pengaruhnya terhadap hasil retrieval sehingga dapat diketahui kelebihan maupun keterbatasan sistem yang dibangun.

4.4.1 Analisis Pemilihan Layer VGG16

Berdasarkan hasil pengujian yang telah dilakukan, sistem klasifikasi dan *Content-Based Image Retrieval* (CBIR) yang dibangun mampu memberikan performa yang baik. Hal ini ditunjukkan oleh nilai akurasi klasifikasi sebesar 100% serta nilai Mean Precision@5 sebesar 96,33% pada proses retrieval. Hasil tersebut menunjukkan bahwa fitur yang diekstraksi menggunakan model VGG16 pada layer Block4 mampu merepresentasikan karakteristik visual motif Tenun Samarinda dengan baik sehingga proses klasifikasi maupun retrieval dapat dilakukan secara efektif. Pemilihan fitur pada layer Block4 didasarkan pada hasil beberapa percobaan yang telah dilakukan menggunakan beberapa layer VGG16, yaitu Block4, Block5, FC1, dan FC2. Hasil perbandingan performa masing-masing layer ditunjukkan pada Tabel 4.7.

Tabel 4.9 Perbandingan Performa Layer VGG16 sebagai Feature Extractor

Layer VGG16	Dimensi Fitur	Akurasi	Mean Precision@5
Block4 + GAP	512	100%	96,33%
Block4 + GMP	512	100%	96,00%
Block4 + Avg + Max	1024	100%	96,00%
Block5 + GAP	512	98,33%	93,33%
Block5 + GMP	512	100%	86,83%
Block5 + Avg + Max	1024	100%	87,17%
FC1	4096	99,17%	85,50%
FC2	4096	98,33%	89,67%

Berdasarkan Tabel 4.7, di antara seluruh layer yang diuji, *Block4* memberikan performa terbaik sehingga dipilih sebagai *feature extractor* pada sistem yang dibangun. Layer yang lebih dalam *Block5* serta layer *Fully Connected* (FC1 dan FC2), menghasilkan fitur yang cenderung lebih spesifik terhadap objek pada dataset ImageNet, sehingga kemampuan generalisasinya terhadap citra motif Tenun Samarinda menjadi lebih rendah. Dengan demikian, fitur pada layer *Block4* dinilai mampu menghasilkan representasi

tekstur dan pola motif yang paling sesuai untuk kebutuhan klasifikasi dan *retrieval* pada penelitian ini.

4.4.2 Analisis Hasil Retrieval

Pada proses retrieval, tingkat kemiripan antar citra dihitung menggunakan metode *Euclidean Distance*. Metode ini menghitung jarak antara vektor fitur citra *query* dengan vektor fitur seluruh citra pada basis data. Semakin kecil nilai *Euclidean Distance*, maka semakin tinggi tingkat kemiripan antara citra *query* dan citra pada basis data. Seluruh citra kemudian diurutkan berdasarkan nilai jarak dari yang terkecil hingga terbesar, sehingga lima citra dengan nilai jarak terkecil ditampilkan sebagai hasil retrieval. Proses pencarian terhadap seluruh citra pada basis data memungkinkan sistem menentukan citra yang paling mirip berdasarkan karakteristik fitur visual tanpa membatasi hasil pencarian berdasarkan kelas prediksi CNN-SVM.

Berdasarkan hasil pengujian, seluruh citra data uji berhasil diklasifikasikan dengan benar sehingga diperoleh nilai akurasi klasifikasi sebesar 100%. Namun, hasil klasifikasi tersebut tidak digunakan sebagai pembatas dalam proses retrieval. Setiap citra *query* tetap dibandingkan dengan seluruh citra pada basis data berdasarkan jarak fitur. Dengan demikian, kualitas retrieval tidak hanya bergantung pada keberhasilan klasifikasi, tetapi juga pada kemampuan fitur VGG16 dalam merepresentasikan karakteristik visual citra serta kemampuan *Euclidean Distance* dalam mengurutkan citra berdasarkan tingkat kemiripannya. Hasil evaluasi *Content-Based Image Retrieval* (CBIR) menggunakan metrik Mean Precision@5 menunjukkan nilai sebesar 96,33%. Nilai tersebut menunjukkan bahwa secara rata-rata sebagian besar citra yang berada pada lima peringkat teratas merupakan citra yang relevan dengan citra *query*. Meskipun nilai tersebut belum mencapai 100%, hasil yang diperoleh menunjukkan bahwa fitur yang digunakan mampu menempatkan citra dengan motif yang sama pada posisi teratas meskipun proses pencarian dilakukan terhadap seluruh citra dalam basis data. Citra yang kurang relevan pada beberapa hasil *Top-5* dapat terjadi karena terdapat karakteristik visual yang serupa antar motif, seperti pola, warna, tekstur, atau susunan motif, sehingga citra dari kelas berbeda dapat memiliki jarak fitur yang relatif dekat dengan citra *query*.

Secara keseluruhan, hasil pengujian menunjukkan bahwa sistem mampu menghasilkan performa klasifikasi dan retrieval yang tinggi. Kombinasi VGG16 layer

Block4 sebagai *feature extractor*, Support Vector Machine (SVM) sebagai metode klasifikasi, serta *Euclidean Distance* sebagai pengukur tingkat kemiripan mampu menghasilkan akurasi klasifikasi sebesar 100% dan Mean Precision@5 sebesar 96,33%. Hasil tersebut menunjukkan bahwa fitur yang dihasilkan dari layer Block4 VGG16 mampu merepresentasikan karakteristik visual motif Tenun Samarinda dengan baik, sehingga dapat dimanfaatkan untuk proses klasifikasi maupun pencarian citra berdasarkan kemiripan visual secara lebih independen.

4.4.3 Analisis Ketahanan Model terhadap Variasi Kondisi Citra

Analisis ketahanan (robustness) dilakukan untuk mengetahui sejauh mana model CNN-SVM mampu mempertahankan kinerjanya ketika citra uji diberi berbagai variasi kondisi, sebagaimana hasil yang disajikan pada Tabel 4.7. Secara umum, model menunjukkan ketahanan yang tinggi terhadap sebagian besar variasi. Pada transformasi rotasi (90° dan 180°), flip horizontal, serta perubahan kecerahan (+30% dan -30%), akurasi tetap bertahan pada 100%, sama dengan baseline. Hal ini menunjukkan bahwa fitur tekstur motif yang diekstraksi VGG16 bersifat konsisten terhadap perubahan orientasi maupun intensitas pencahayaan. Ketahanan terhadap perubahan kecerahan mengindikasikan fitur yang digunakan lebih menekankan pola struktur dan tekstur dibanding nilai intensitas piksel absolut, sedangkan ketahanan terhadap rotasi dan flip pada kasus ini dipengaruhi oleh sifat motif tenun yang cenderung berpola berulang sehingga tetap dapat dikenali meski orientasinya berubah.

Penurunan akurasi yang signifikan hanya terjadi pada dua kondisi, yaitu Gaussian blur dan resolusi rendah, yang keduanya turun menjadi 72,50%. Kedua kondisi tersebut sama-sama mengaburkan detail tekstur halus motif. Motif tenun Samarinda dibedakan terutama oleh pola garis dan tekstur berulang yang rapat, sehingga ketika detail tersebut hilang akibat pemburaman maupun penurunan resolusi, informasi diskriminatif yang menjadi dasar pembeda antar-kelas ikut berkurang. Akibatnya, kemampuan model dalam membedakan motif Hatta, Pucuk Rebung, dan Cumi menurun. Adapun pada pemberian Gaussian noise, akurasi hanya turun tipis menjadi 99,17%, yang menandakan model masih tahan terhadap derau tingkat rendah. Temuan ini menegaskan bahwa ketajaman tekstur merupakan faktor paling menentukan bagi kinerja model, sehingga kualitas citra masukan perlu diperhatikan ketika sistem diterapkan pada kondisi nyata.

4.4.4 Analisis Waktu Pemrosesan

Analisis waktu pemrosesan dilakukan untuk menilai efisiensi sistem dalam memproses satu citra masukan secara menyeluruh, dari ekstraksi fitur hingga retrieval, sebagaimana hasil pada Tabel 4.8. Total waktu pemrosesan rata-rata adalah 153,066 ms atau sekitar 0,15 detik per citra, setara dengan throughput 6,03 citra per detik. Nilai ini jauh berada di bawah kriteria keberhasilan yang ditetapkan pada sub-bab 3.6, yaitu waktu pemrosesan ≤ 5 detik per citra, sehingga kriteria tersebut terpenuhi.

Bila ditinjau per tahap, ekstraksi fitur VGG16 merupakan tahap yang paling banyak menyita waktu, yaitu rata-rata 164,880 ms atau sekitar 99,5% dari total waktu pemrosesan. Sebaliknya, tahap klasifikasi SVM (0,655 ms) dan retrieval Top-5 (0,158 ms) hanya membutuhkan waktu yang sangat kecil sehingga kontribusinya terhadap total waktu dapat diabaikan. Dominasi waktu pada tahap ekstraksi fitur ini wajar mengingat arsitektur VGG16 yang dalam dengan jumlah operasi konvolusi yang besar, ditambah pengujian dijalankan pada perangkat berbasis CPU (tanpa akselerasi GPU) dengan memori 15,40 GB menggunakan TensorFlow versi 2.20.0. Temuan ini menunjukkan bahwa beban komputasi utama sistem terletak pada proses ekstraksi fitur, dan penggunaan akselerasi GPU berpotensi mempercepat proses tersebut secara signifikan. Meskipun demikian, dengan konfigurasi berbasis CPU pun sistem telah mampu memproses citra dengan cepat dan tetap memenuhi kriteria waktu yang ditetapkan, sehingga sistem layak digunakan secara praktis.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Kesimpulan disusun berdasarkan hasil implementasi dan pengujian sistem yang telah dilakukan pada penelitian ini. Berdasarkan hasil penelitian, dapat diperoleh beberapa kesimpulan sebagai berikut.

1. Penelitian ini berhasil membangun sistem klasifikasi motif Tenun Samarinda menggunakan kombinasi VGG16 sebagai *feature extractor* dan *Support Vector Machine* (SVM) sebagai *classifier*. Fitur citra diekstraksi menggunakan layer *Block4* yang diikuti *Global Average Pooling* (GAP) sehingga setiap citra direpresentasikan dalam bentuk vektor fitur dengan 512 elemen. Selanjutnya, vektor fitur tersebut digunakan sebagai masukan pada proses klasifikasi menggunakan SVM.
2. Sistem *Content-Based Image Retrieval* (CBIR) berhasil diimplementasikan dengan memanfaatkan fitur hasil ekstraksi VGG16 dan *Euclidean Distance* sebagai pengukur tingkat kemiripan antar citra. Proses retrieval dilakukan dengan membandingkan vektor fitur citra *query* terhadap seluruh citra pada basis data, kemudian mengurutkannya berdasarkan nilai *Euclidean Distance* dari yang terkecil hingga terbesar. Lima citra dengan nilai jarak terkecil ditampilkan sebagai hasil retrieval.

Berdasarkan hasil pengujian menggunakan metode *Stratified Split*, sistem memperoleh nilai akurasi klasifikasi sebesar 100% pada data uji. Selain itu, evaluasi sistem retrieval menggunakan metrik Mean Precision@5 menghasilkan nilai sebesar 96,33%, yang menunjukkan bahwa sebagian besar citra yang ditampilkan pada lima hasil retrieval teratas memiliki motif yang sesuai dengan citra *query*. Hasil tersebut menunjukkan bahwa kombinasi VGG16, SVM, dan *Euclidean Distance* mampu memberikan performa yang baik dalam proses klasifikasi maupun retrieval motif Tenun Samarinda.

5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran yang dapat menjadi pengembangan pada penelitian selanjutnya, yaitu sebagai berikut.

1. Menambah jumlah dataset dengan menggunakan lebih banyak variasi sarung Tenun Samarinda sehingga kemampuan generalisasi sistem terhadap motif yang beragam dapat ditingkatkan.
2. Menambahkan lebih banyak jenis motif Tenun Samarinda selain motif Hatta, Pucuk Rebung, dan Cumi/Bunga Dayak agar sistem mampu melakukan klasifikasi terhadap variasi motif yang lebih luas.
3. Mengembangkan proses ekstraksi fitur menggunakan arsitektur CNN lain, seperti ResNet, EfficientNet, atau DenseNet, kemudian membandingkan performanya dengan VGG16.
4. Mencoba metode pengukuran kemiripan lain pada proses retrieval, seperti *Cosine Similarity*, *Mahalanobis Distance*, atau metode berbasis *metric learning*, untuk mengetahui metode yang paling sesuai terhadap karakteristik motif Tenun Samarinda.
5. Mengembangkan sistem agar mampu melakukan klasifikasi dan retrieval secara real-time menggunakan kamera perangkat bergerak sehingga dapat dimanfaatkan sebagai media identifikasi dan pengenalan motif Tenun Samarinda.

DAFTAR PUSTAKA

1. Addisu, E. G., Yirga, T. G., Yirga, H. G., & Yehuala, A. D. (2025). *Transfer learning-based hybrid VGG16-machine learning approach for heart disease detection with explainable artificial intelligence*. February, 1–18. <https://doi.org/10.3389/frai.2025.1504281>
2. Agusma, R. (2021). Upaya Pelestarian Kerajinan Tenun Oleh Masyarakat Kampung Wisata Tenun Kecamatan Samarinda Seberang Kota Samarinda. *Jurnal Sosiatri - Sosiologi*, 9(3), 1–11.
3. Ahlawat, S., & Choudhary, A. (2020). ScienceDirect ScienceDirect Hybrid CNN-SVM Classifier for Handwritten Digit Recognition Hybrid CNN-SVM Classifier for Handwritten Digit Recognition. *PROCS*, 167(2019), 2554–2560. <https://doi.org/10.1016/j.procs.2020.03.309>
4. Alzubaidi, L., Zhang, J., Humaidi, A. J., Dujaili, A. Al, Duan, Y., Shamma, O. Al, Santamaría, J., Fadhel, M. A., Amidie, M. Al, & Farhan, L. (2021). Review of deep learning : concepts , CNN architectures , challenges , applications , future directions. In *Journal of Big Data*. Springer International Publishing. <https://doi.org/10.1186/s40537-021-00444-8>
5. Amalia, F. S., Setiawansyah, & Darwis, D. (2021). *Analisis Data Penjualan Handphone dan Elektronik Menggunakan Algoritma Apriori (Studi Kasus : CV REY GASENDRA)*. 2(1), 1–6.
6. Biswas, A., & Islam, M. S. (2023). A Hybrid Deep CNN-SVM Approach for Brain Tumor Classification. *Journal of Information Systems Engineering and Business Intelligence*, 9(1), 1–15. <https://doi.org/10.20473/jisebi.9.1.1-15>
7. Böttcher, B., Assen, M. Van, Fari, R., Doeberitz, P. L. V. K., Kim, E. Y., Berkowitz, E. A., Meinel, F. G., & Cecco, C. N. De. (2025). Evaluation of a content-based image retrieval system for radiologists in high- resolution CT of interstitial lung diseases. *European Radiology Experimental*. <https://doi.org/10.1186/s41747-024-00539-w>
8. Choe, J., Choi, H. Y., Lee, S. M., Oh, S. Y., Hwang, H. J., Kim, N., Yun, J., Lee, J. S., Oh, Y. M., Yu, D., Kim, B., & Seo, J. B. (2024). Evaluation of retrieval accuracy and visual similarity in content - based image retrieval of chest CT for obstructive

- lung disease. *Scientific Reports*, 0123456789, 1–11. <https://doi.org/10.1038/s41598-024-54954-5>
9. Colliot, O., & Varoquaux, G. (n.d.). *Machine Learning for Brain Disorders Series Editor* (O. Colliot (ed.)). Springer.
 10. Fadjrie, A., Setyanto, A., & Kurniawan, M. P. (2020). *Pengolahan Citra Digital Untuk Menghitung Ekstraksi Ciri Greenbean Kopi*. 8(1), 8–13.
 11. Ikhsan, M., & Rahardi, M. (2025). *Image-Based Classification of Indonesian Traditional Houses Using a Hybrid CNN-SVM Algorithm*. 9(5), 2303–2309.
 12. Janiesch, C., Zschech, P., & Heinrich, K. (2021). *Machine learning and deep learning*. <https://arxiv.org/abs/2104.05314>
 13. Kaya, & Umbu, J. (2022). *Klasifikasi Motif Kain Tenun menggunakan K-Nearest Neighbor Berdasarkan Gray Level Co-occurrence Matrix*. 03(02), 73–76.
 14. Kelen, Y. P. K., & Baso, B. (2023). Klasifikasi Tenun Timor Menggunakan Metode SVM Berdasarkan Speeded Up Robust Features. *Jurnal Teknologi Informasi Dan Ilmu Komputer*, 10(6), 1353–1360. <https://doi.org/10.25126/jtiik.2023107625>
 15. Kembo, E. K., & Kaesmetan, Y. R. (2025). *Klasifikasi Motif Kain Tenun di Pulau Flores Menggunakan Metode CNN dan RNN*.
 16. Khan, A., Sohail, A., Zahoor, U., & Saeed, A. (2020). A survey of the recent architectures of deep convolutional neural networks. In *Artificial Intelligence Review* (Issue 0123456789). Springer Netherlands. <https://doi.org/10.1007/s10462-020-09825-6>
 17. Kumala, R., Darmi, Y., David, N., & Veronika, M. (2023). *Klasifikasi Pola Motif Kain Tenun Bumpak Desa Kampai Selama Menggunakan Metode CNN*. 7, 1917–1927.
 18. Kurniawan, M. A., Kartikasari, Y., R, N. Z., Informatika, T., Nusantara, U., & Kediri, P. (2025). *Deteksi Gambar Hewan Serupa Berdasarkan Warna Menggunakan Metode Content-Based Image Retrieval (CBIR)*. 4, 450–456.
 19. Kusanti, J., Noersasongko, E., & Soeleman, M. A. (2026). *A Mid-Level Feature Fusion Framework Integrating PHLF and VGG16 for Robust Batik Pattern Detection*. 17(5), 445–450.
 20. Li, X., & Zhu, Y. (2024). A real-time and accurate convolutional neural network for

- fabric defect detection. *Complex and Intelligent Systems*, 10(3), 3371–3387. <https://doi.org/10.1007/s40747-023-01317-8>
21. Muhartini, S., Sunyoto, A., & Muhammad, A. H. (2024). Implementasi Metode Deep Learning CNN Dalam Klasifikasi Tajong (Sarung) Samarinda. *Jurnal SENOPATI (Sustainability, Ergonomics, Optimization, and Application of Industrial Engineering)*, 6(1), 28–41. <https://ejurnal.itats.ac.id/senopati/article/view/6573/4170>
 22. Nenometa, E. A. (2025). *Klasifikasi Warna Kain Tenun Lotis Menggunakan Convolutional Neural Network*. 07(2), 1–29.
 23. Paladan, J., Rahayu, V. P., & Sutrisno. (2024). *Analisis Strategi Pemasaran Pada Pengrajin Sarung Tenun Di Samarinda*. 6(1). <https://doi.org/https://doi.org/10.30872/prospek.v6i1.4542>
 24. Patel, Y., Tolias, G., & Matas, J. (2022). *Recall @ k Surrogate Loss with Large Batches and Similarity Mixup*. 7502–7511.
 25. Rainio, O., Teuho, J., & Klen, R. (2024). Evaluation metrics and statistical tests for machine learning. *Scientific Reports*, 1–14. <https://doi.org/10.1038/s41598-024-56706-x>
 26. Ramzi, E., Audebert, N., Thome, N., Rambour, C., & Bitot, X. (2022). *Pertinent Image Retrieval*. 1–36.
 27. Rodríguez-pérez, R., & Bajorath, J. (2022). *Evolution of Support Vector Machine and Regression Modeling in Chemoinformatics and Drug Discovery*. 355–362. <https://doi.org/10.1007/s10822-022-00442-9>
 28. Rosmasari, Khoirunnita, A., Gunawan, S., Rahmawati, A., Nanda, A., Jannah, M., & Ince, M. F. A. (2026). *Pengembangan ekonomi UMKM lokal melalui digitalisasi dengan aplikasi e-tenun*. 7(10), 213–223. <https://doi.org/10.33474/jp2m.v7i1.24519>
 29. Serin, J., Vidhya, K. T., Mary Ivy Deepa, I. S., Ebenezer, V., & Jenefa, A. (2024). Gender Classification from Fingerprint Using Hybrid CNN-SVM. *Journal of Artificial Intelligence and Technology*, 4(1), 82–87. <https://doi.org/10.37965/jait.2023.0192>
 30. Sha, S., Li, Y., Wei, W., Liu, Y., Chi, C., Jiang, X., Deng, Z., & Luo, L. (2024). Image Classification and Restoration of Ancient Textiles Based on Convolutional Neural Network. *International Journal of Computational Intelligence Systems*, 17(1).

<https://doi.org/10.1007/s44196-023-00381-9>

31. Sidik, A. D. W. M., Kusumah, I. H., Suryana, A., Edwinanto, Artiyasa, M., & Junfithrana, A. P. (2020). *Gambaran Umum Metode Klasifikasi Data Mining*. 2(2), 34–38.
32. Sooi, A. G., & Dwiandri, F. A. A. (2024). *Pengenalan Citra Kain Tenun Nusa Tenggara Timur Menggunakan SqueezeNet dan Decision Tree*. 4(1), 136–145.
33. Sriani, Putri, R. A., & Annisa. (2024). *Klasifikasi Jenis Daun Jambu Biji Menggunakan Metode Content Based Image Retrieval (CBIR) DAN Support Vector Machine (SVM)*. 4307(May), 806–811.
34. Sunyoto, A., Pristyanto, Y., Setyanto, A., Alarfaj, F., Almusallam, N., & Alreshoodi, M. (2022). *The Performance Evaluation of Transfer Learning VGG16 Algorithm on Various Chest X-ray Imaging Datasets for COVID-19 Classification*. 13(9), 196–203.
35. Syarif, H., & Andono, P. N. (2023). *Content Based Image Retrieval Berbasis Color Histogram Untuk Pengklasifikasian Ikan KOI Jenis*. 8(2), 616–626.
36. Tang, Q., Zhang, Y., & Wang, B. (2024). Finite Smoothing Algorithm for High-Dimensional Support Vector Machines and Quantile Regression. *Proceedings of Machine Learning Research*, 235, 47865–47884.
37. Tena, S., Hartanto, R., & Ardiyanto, I. (2021). Content-based image retrieval for fabric images: A survey. *Indonesian Journal of Electrical Engineering and Computer Science*, 23(3), 1861–1872. <https://doi.org/10.11591/ijeecs.v23.i3.pp1861-1872>
38. Unlersen, M. F., Sonmez, M. E., Aslan, M. F., Demir, B., Aydin, N., Sabanci, K., & Ropelewska, E. (2022). CNN – SVM hybrid model for varietal classification of wheat based on bulk samples. *European Food Research and Technology*, 248(8), 2043–2052. <https://doi.org/10.1007/s00217-022-04029-4>
39. Varshney, S., Singh, S., Lakshmi, C. V., & Patvardhan, C. (2024). Content-based image retrieval of Indian traditional textile motifs using deep feature fusion. *Scientific Reports*, 14(1), 1–17. <https://doi.org/10.1038/s41598-024-56465-9>
40. Wu, Y., He, Y., & Wang, Y. (2023). Multi-Class Weed Recognition Using Hybrid CNN-SVM Classifier. *Sensors*, 23(16). <https://doi.org/10.3390/s23167153>
41. Zhang, C., & Liu, J. (2023). *Content Based Deep Learning Image Retrieval : A Survey*. *Content Based Deep Learning Image Retrieval : A Survey*. January.

<https://doi.org/10.1145/3638884.3638908>

42. Zulfikar, W. B., Angelyna, Irfan, M., Atmadja, A. R., & Jumadi. (2025). *A Deep Learning Approach Using VGG16 to Classify Beef and Pork Images*. 9(March), 568–574.